

性能基线驱动的发动机气路故障 诊断与寿命预测研究

(申请清华大学工学博士学位论文)

培 养 单 位	航空发动机研究院
学 科	航空宇航科学与技术
研 究 生	王 昆
指 导 教 师	胡 忠 志 研究员
联合指导教师	孔 详 兴 研究员

二〇二六年六月

Performance Baseline-Driven Gas Path Fault Diagnosis and Remaining Useful Life Prediction for Aero-Engines

Dissertation Submitted to

Tsinghua University

in partial fulfillment of the requirement

for the degree of

Doctor of Philosophy

in

Aerospace Science and Technology

by

Wang Kun

Dissertation Supervisor: Professor Hu Zhongzhi

June, 2026

关于学位论文使用授权的说明

本人完全了解清华大学有关保留、使用学位论文的规定，即：

清华大学拥有在著作权法规定范围内学位论文的使用权，其中包括：（1）已获学位的研究生必须按学校规定提交学位论文，学校可以采用影印、缩印或其他复制手段保存研究生上交的学位论文；（2）为教学和科研目的，学校可以将公开的学位论文作为资料在图书馆、资料室等场所供校内师生阅读，或在校园网上供校内师生浏览部分内容；（3）根据《中华人民共和国学位条例暂行实施办法》，向国家图书馆报送可以公开的学位论文。

本人保证遵守上述规定。

（保密的论文在解密后遵守此规定）

作者签名： _____

导师签名： _____

日 期： _____

日 期： _____

摘 要

航空发动机作为飞机核心动力装置,是国家科技水平、工业基础和国防实力的重要体现。随着我国航空发动机保有量持续增长,传统健康管理方法在状态感知、故障诊断和剩余寿命预测等方面仍存在精度不足、鲁棒性弱和工程适应性有限等问题。对于气路系统而言,构建能够表征健康状态下运行条件、控制输入与性能参数映射关系的性能基线,是开展性能偏移识别、故障诊断和退化预测的基础。基于此,本文面向航空发动机预测与健康管理的(Prognostics and Health Management, PHM)需求,围绕气路性能监视、故障诊断和剩余使用寿命预测开展研究,主要内容如下:

针对航空发动机个性化长周期性能监视问题,提出双旁路自适应性能监视方法。该方法从物理机理和数据驱动角度构建性能基线模型,并引入未建模旁路和退化旁路,分别补偿个体差异与模型失配,跟踪全寿命周期性能退化。验证结果表明,该方法能够构建高精度个性化性能模型,提高目标发动机长期状态监视能力。

针对多源不确定性下气路故障诊断鲁棒性不足的问题,提出基于个性化残差与双任务自编码器的故障诊断方法。该方法利用个性化性能模型构建正常参考,通过残差提取故障敏感特征,并结合重构约束、分类约束和加噪掩码机制学习鲁棒故障表示,采用先检测、后隔离策略实现诊断。验证结果表明,该方法能够削弱个体差异、正常退化和噪声干扰影响,提高故障检测与隔离性能。

针对目标域故障样本稀缺和跨域分布差异问题,提出结合高斯混合变分自编码器与迁移学习的故障样本增强方法。该方法利用正常样本学习健康状态下气路参数潜在分布,再利用少量目标域故障样本进行迁移微调,生成具有目标域故障特征的扩展样本。仿真结果表明,该方法能够生成具有较好真实性和覆盖能力的虚拟故障样本,并提升小样本条件下的诊断性能。

针对剩余使用寿命预测中退化信息难以显式提取、多尺度时序建模不足等问题,提出基于退化特征增强与融合互补注意力的 RUL 预测方法。该方法以健康基准为参考,通过残差提取退化特征,并设计退化阶段触发机制确定预测启动时机;在此基础上,构建融合时序注意力和通道注意力的金字塔时间卷积网络,强化关键退化阶段和敏感监测变量表达。基于 N-CMAPSS 数据集的验证结果表明,该方法能够提高复杂退化场景下 RUL 预测精度、稳定性和可解释性。

关键词: 航空发动机; 性能基线; 性能监视; 故障诊断; 剩余寿命预测

Abstract

As the core power system of an aircraft, the aero-engine is an important indicator of a nation's scientific and technological capability, industrial foundation, and defense strength. With the continuous growth of China's aero-engine fleet, conventional health management methods still face limitations in state awareness, fault diagnosis, and remaining useful life prediction, particularly in terms of accuracy, robustness, and engineering adaptability. For gas path systems, establishing a performance baseline that characterizes the mapping relationship among operating conditions, control inputs, and performance parameters under healthy conditions is fundamental to performance deviation identification, fault diagnosis, and degradation prediction. Therefore, to meet the requirements of aero-engine Prognostics and Health Management (PHM), this dissertation focuses on gas path performance monitoring, fault diagnosis, and remaining useful life prediction. The main research contents are as follows.

To address the problem of personalized long-term performance monitoring for aero-engines, a dual-bypass adaptive performance monitoring method is proposed. In this method, performance baseline models are constructed from both physics-based and data-driven perspectives according to different data availability conditions. On this basis, an unmodeled bypass and a degradation bypass are introduced to compensate for individual performance differences and model mismatch, and to track performance degradation over the full life cycle, respectively. Validation results show that the proposed method can construct a high-accuracy personalized performance model and improve the long-term state monitoring capability for the target engine.

To improve the robustness of gas path fault diagnosis under multi-source uncertainties, a fault diagnosis method based on personalized residuals and a dual-task autoencoder is proposed. The personalized performance model is used to construct a normal performance reference, and fault-sensitive features are extracted from the residuals between measured parameters and model predictions. A dual-task autoencoder is then introduced to learn robust fault representations through reconstruction constraints, classification constraints, and noise-mask mechanisms. A two-stage strategy of fault detection followed by fault isolation is adopted for diagnosis. Validation results

demonstrate that the proposed method can reduce the influence of individual differences, normal degradation, and noise disturbances, thereby improving fault detection and isolation performance.

To address the scarcity of target-domain fault samples and cross-domain distribution discrepancies, a fault sample augmentation method combining a Gaussian mixture variational autoencoder and transfer learning is proposed. The method first learns the latent distribution of gas path parameters under healthy operating conditions from normal samples, and then fine-tunes the pretrained generative model using a small number of target-domain fault samples to generate augmented samples with target-domain fault characteristics. Simulation results show that the proposed method can generate virtual fault samples with good fidelity and coverage, and improve diagnostic performance under small-sample conditions.

To solve the problems of implicit degradation representation and insufficient multi-scale temporal modeling in remaining useful life prediction, an RUL prediction method based on degradation feature enhancement and fused complementary attention is proposed. Taking the personalized health baseline as a reference, degradation features are extracted from residuals, and a degradation-stage triggering mechanism is designed to determine the appropriate starting point for RUL prediction. On this basis, a pyramid temporal convolutional network integrating temporal attention and channel attention is constructed to enhance the representation of critical degradation stages and sensitive monitoring variables. Validation on the N-CMAPSS dataset shows that the proposed method improves the accuracy, stability, and interpretability of RUL prediction under complex degradation scenarios.

Keywords: aero-engine; performance baseline; performance monitoring; fault diagnosis; remaining useful life prediction

目 录

摘 要	I
Abstract.....	III
目 录	V
插图清单	IX
附表清单	XI
符号与缩略语说明	XIII
第 1 章 绪论	1
1.1 研究背景和意义	1
1.2 国内外研究现状	4
1.2.1 基于性能基线模型的航空发动机状态监视方法研究	4
1.2.2 多源不确定性气路故障诊断方法研究	7
1.2.3 域自适应方法的小样本故障诊断方法研究	8
1.2.4 航空发动机剩余使用寿命预测方法研究现状	9
1.3 研究现状分析	12
1.4 论文主要内容和章节安排	13
第 2 章 面向个性化长周期的双旁路自适应监视方法研究	17
2.1 本章引论	17
2.2 性能监视问题定义	18
2.2.1 连续时间下的 PPM	18
2.2.2 PPM 的加性解耦表达	19
2.3 PBM 构建方法	19
2.3.1 基于部件法的物理机理 PBM 构建方法	19
2.3.2 基于金字塔时间卷积网络的数据驱动 PBM 构建方法	20
2.4 基于双旁路自适应的模型修正方法框架	26
2.4.1 两阶段 PPM 建模框架	26
2.4.2 持续增量学习下的数据池构建	27
2.4.3 双旁路自适应流程	30

2.5 仿真案例 1: 小涵道比军用涡扇发动机	32
2.5.1 仿真数据描述与预处理	32
2.5.2 模型设置与仿真指标	36
2.5.3 仿真验证结果及分析	39
2.6 仿真案例 2: 大涵道比民用涡扇发动机	48
2.6.1 民航数据描述与预处理	48
2.6.2 数据驱动 PPM 模型设置	51
2.6.3 仿真验证结果及分析	52
2.7 本章小结	59
第 3 章 多源不确定性下的气路故障诊断方法研究	61
3.1 本章引论	61
3.2 气路故障诊断问题定义	62
3.2.1 故障检测	62
3.2.2 故障隔离	62
3.2.3 模型在线自适应	63
3.3 气路故障诊断方法	63
3.3.1 基于 DTAE 的故障诊断方法流程	63
3.3.2 双任务自编码器	66
3.4 仿真试验与分析	69
3.4.1 试验数据描述	69
3.4.2 模型设置与评价指标	70
3.4.3 连续 50 个飞行架次的故障诊断验证	72
3.4.4 连续 400 个飞行架次的故障诊断验证	74
3.4.5 DTAE 潜在特征可视化分析	76
3.4.6 噪声鲁棒性验证	78
3.5 本章小结	80
第 4 章 基于域自适应的小样本气路故障诊断方法研究	81
4.1 本章引论	81
4.2 小样本故障诊断方法问题定义	82
4.2.1 域与数据分布的数学描述	82
4.2.2 跨域小样本诊断的核心挑战	82
4.3 域自适应算法原理	83

4.3.1 基于迁移学习与高斯混合变分自编码器的目标域故障样本生成方法 ..	83
4.3.2 基于高斯混合分布的变分自编码器生成模型	84
4.3.3 迁移学习概念	88
4.4 仿真试验与分析	88
4.4.1 模型设置与评价指标	88
4.4.2 样本生成质量评估	91
4.4.3 基于生成故障样本的诊断性能验证分析	97
4.4.4 各类数据增强算法性能对比分析	99
4.5 本章小结	101
第 5 章 基于退化特征增强的剩余使用寿命预测方法研究	103
5.1 本章引论	103
5.2 航空发动机 RUL 预测问题定义	103
5.2.1 剩余使用寿命标签定义	104
5.2.2 基于健康基准的退化特征构建	104
5.2.3 基于退化特征序列的 RUL 预测问题形式化	105
5.3 基于退化特征增强的 RUL 预测算法原理	105
5.3.1 基于退化特征增强的 RUL 预测框架	106
5.3.2 退化趋势表征与 RUL 预测触发机制	107
5.3.3 融合互补注意机制的 RUL 预测模型	108
5.4 仿真试验与分析	110
5.4.1 试验数据描述	110
5.4.2 模型设置和评价指标	112
5.4.3 基于 N-CMAPSS 数据集的健康基准精度评估	113
5.4.4 退化特征的显式捕捉	115
5.4.5 RUL 预测结果和方法对比	116
5.4.6 消融试验	119
5.4.7 触发机制的可解释性分析	123
5.4.8 计算复杂度分析	123
5.5 本章小结	124
第 6 章 结论	127
6.1 主要结论	127
6.2 本文创新点	128

目 录

6.3 未来展望	129
参考文献	131
致 谢	141
声 明	143
个人简历、在学期间完成的相关学术成果	145

插图清单

图 1-1 全球民航领域维护、维修与大修的相关费用.....	1
图 1-2 PHM 系统架构.....	2
图 1-3 发动机状态监视流程.....	5
图 1-4 论文章节安排.....	14
图 2-1 因果卷积层.....	21
图 2-2 空洞卷积层.....	21
图 2-3 双层 TCN 计算流程示意图.....	22
图 2-4 PTCN 网络拓扑结构计算流程示意图.....	24
图 2-5 残差模块计算流程示意图.....	24
图 2-6 基于个性化性能模型的性能监视流程.....	27
图 2-7 双转子涡扇发动机构型示意图.....	32
图 2-8 不确定性注入方法.....	34
图 2-9 工况剖面示意图.....	35
图 2-10 未建模旁路修正前后对比.....	42
图 2-11 导叶角 α_1 和 α_2 的调节过程.....	43
图 2-12 PBM 和 PPM 对各气路参数预测偏差随在翼时长的演化过程.....	44
图 2-13 更新前后 PPM 对各气路参数预测偏差对比.....	46
图 2-14 样本池连续更新演化过程.....	47
图 2-15 序列样本构建示意图.....	50
图 2-16 测试架次的飞行剖面.....	53
图 2-17 数据驱动 PBM 与未建模旁路补偿后的 Tt_{25} 预测结果.....	53
图 2-18 数据驱动 PBM 与未建模旁路补偿后的 Tt_3 预测结果.....	54
图 2-19 数据驱动 PBM 与未建模旁路补偿后的 Ps_3 预测结果.....	54
图 2-20 数据驱动 PBM 与未建模旁路补偿后的 EGT 预测结果.....	54
图 2-21 各架次下各参数预测结果.....	55
图 2-22 基于退化旁路微调的 Tt_3 预测结果.....	56
图 2-23 基于退化旁路微调的 Ps_3 预测结果.....	56
图 2-24 基于退化旁路微调的 EGT 预测结果.....	56

图 3-1 故障诊断模型离线训练流程示意图.....	64
图 3-2 故障诊断模型在线诊断及自适应流程.....	65
图 3-3 DTAE 基本架构	68
图 3-4 连续 50 个飞行架次的诊断结果.....	72
图 3-5 50 个连续飞行架次中四种诊断方法的混淆矩阵.....	73
图 3-6 连续 400 个飞行架次的诊断结果.....	74
图 3-7 400 个连续飞行架次中四种诊断方法的混淆矩阵.....	75
图 3-8 原始特征数据主成分可视化结果.....	76
图 3-9 诊断模型潜空间可视化结果.....	77
图 3-10 不同噪声强度下 DTAE 模型性能变化	78
图 3-11 不同噪声强度下各方法故障检测性能对比.....	79
图 3-12 不同噪声强度下各方法故障隔离性能对比.....	79
图 4-1 基于 GMVAE-TL 的故障样本生成流程	84
图 4-2 GMVAE 结构	87
图 4-3 VAE 生成正常样本与真实正常样本对比	93
图 4-4 GMVAE 生成正常样本与真实正常样本对比	93
图 4-5 故障样本个数为 1 时 TL-GMVAE 生成 Fan 故障与真实故障样本对比 ..	95
图 4-6 故障样本个数为 100 时 TL-GMVAE 生成 Fan 故障与真实故障样本对比	96
图 4-7 故障样本个数为 100 时随机选择的真实故障样本分布.....	96
图 5-1 基于退化特征增强的 RUL 预测框架示意图.....	106
图 5-2 融合互补注意力的计算流.....	109
图 5-3 DS01 数据集 08 号发动机第 10 个循环的 PBM 预测结果	114
图 5-4 DS01 数据集 08 号发动机第 10 个循环的健康基准预测结果	114
图 5-5 DS01 数据集 08 号发动机第 60 个循环的健康基准预测结果	116
图 5-6 DS01 数据集中 08 号发动机各传感器 MAE 值随飞行循环数的变化趋势	116
图 5-7 DS01 中第 08 至 10 号发动机 RUL 预测结果	117
图 5-8 不同窗口尺寸和 PTCN 深度对 PBM 验证集的影响.....	122
图 5-9 不同窗口大小和 PTCN 深度对 RUL 预测模型测试集的影响	122
图 5-10 DS01 数据集中退化机制切换与退化模式的可视化分析	123

附表清单

表 2-1 部件级模型各气路传感器测量参数.....	33
表 2-2 目标发动机个体差异量化指标.....	34
表 2-3 目标发动机性能退化量化指标.....	35
表 2-4 故障边界量化指标.....	36
表 2-5 旁路模型的输入输出设置.....	37
表 2-6 旁路模型超参数设置.....	38
表 2-7 未建模旁路校正前后预测误差对比 (%)	42
表 2-8 退化旁路校正前后预测误差对比 (%)	45
表 2-9 用于训练与测试的 QAR 相关信息	48
表 2-10 数据驱动 PBM 模型的输入输出设置	51
表 2-11 PPM 中各子模型的输入输出设置.....	52
表 2-12 数据驱动 PBM 与未建模旁路补偿后初始 PPM 预测误差统计结果 (%)	53
表 2-13 采用不同方法预测的 MAPE (%)	57
表 2-14 采用不同方法预测的 MaxAPE (%)	57
表 2-15 时间窗长度消融试验结果 (%)	58
表 2-16 TCN 层数消融试验结果 (%)	59
表 2-17 FPN 模块消融试验结果 (%)	59
表 3-1 诊断模型中各子模型的输入输出设置.....	70
表 3-2 诊断模型中各子模型的超参数设置.....	70
表 4-1 GMVAE 模型超参数变设置	89
表 4-2 GMVAE 与 VAE 样本生成精度的欧氏距离统计特性比较.....	92
表 4-3 GMVAE 生成正常样本与真实正常样本统计特性比较	92
表 4-4 GMVAE 与 VAE 生成正常样本覆盖率对比.....	94
表 4-5 不同故障样本数量下生成样本的欧氏距离统计.....	94
表 4-6 不同故障样本数量下生成样本覆盖率.....	97
表 4-7 生成样本增强前后的故障诊断性能对比.....	98
表 4-8 不同数据增强模型的欧氏距离统计特性.....	100
表 5-1 健康基准模型的输入输出设置.....	111

表 5-2 预测框架中各子模型的超参数设置.....	112
表 5-3 健康基准模型预测精度.....	115
表 5-4 DS01 数据集不同方法的 RUL 预测结果对比	118
表 5-5 DS04 数据集不同方法的 RUL 预测结果对比	118
表 5-6 DS06 数据集不同方法的 RUL 预测结果对比	119
表 5-7 使用不同样本量进行未建模旁路自适应的预测结果对比.....	120
表 5-8 注意力机制对模型性能的影响.....	122

符号与缩略语说明

符号

Ma	马赫数(-)
Alt	高度(ft)
PLA	油门杆角度($^{\circ}$)
T_{step}	控制周期(s)
α_1	风扇导叶角度($^{\circ}$)
α_2	压气机导叶角度(%)
VBV	可调放气活门开度(-)
Wf	主燃油流量(kg/h)
Wfa	加力燃油流量(kg/h)
A8	喷口面积(cm^2)
N1	风扇转速(rpm)
N2	压气机转速(rpm)
Ps0	环境静压(kPa)
Pt15	外涵道总压(kPa)
Pt2	发动机进气总压(kPa)
Pt25	风扇内涵出口总压(kPa)
Pt3	压气机出口总压(kPa)
Ps3	压气机出口静压(kPa)
Pt4	燃烧室出口总压(kPa)
Pt6	低压涡轮出口总压(kPa)
Tt2	发动机进气总温(K)
Tt25	风扇内涵出口总温(K)
Tt3	压气机出口总温(K)
Tt45	高压涡轮出口总温(K)
Tt5	低压涡轮出口总温(K)
EGT	排气温度(K)

缩略语

AE	自编码器 (Auto Encoder)
ACARS	飞机通信寻址与报告系统 (Aircraft Communications Addressing and Reporting System)
APE	绝对百分比误差 (Absolute Percentage Error)
BIC	贝叶斯信息准则 (Bayesian Information Criterion)
BIT	机内测试 (Built-in Test)
C_A	基于通道注意力的预测模型 (Channel Attention Model)
CMAPSS	商用模块化航空推进系统仿真 (Commercial Modular Aero-Propulsion System Simulation)
CNN	卷积神经网络 (Convolutional Neural Network)
D_A	融合时序注意力和通道注意力的预测模型 (Dual Attention Model)
DA	域自适应 (Domain Adaptation)
DBM	深度玻尔兹曼机 (Deep Boltzmann Machines)
DCGAN	深度卷积生成对抗网络 (Deep Convolutional Generative Adversarial Network)
DIGTEM	数字化涡扇发动机模型 (DIGital Turbofan Engine Models)
DR	检测率 (Detection Rate)
DTAE	双任务自编码器 (Dual-task Autoencoder)
DYNGN	动态通用发动机 (DYNamic Generalized Engine)
ECM	发动机状态监视 (Engine Condition Monitoring)
E_D	欧氏距离 (Euclidean Distance)
EHM	发动机健康管理系统 (Engine Health Management)
ELM	极限学习机 (Extreme Learning Machine)
EM	期望最大化 (Expectation-Maximization)
Fan	风扇 (Fan)
FAR	虚警率 (False Alarm Rate)
FPN	特征金字塔融合 (Feature Pyramid Fusion)
GAN	生成对抗网络 (Generative Adversarial Networks)
GMM	高斯混合模型 (Gaussian Mixture Model)
GMVAE	高斯混合变分自编码器 (Gaussian Mixture Variational Autoencoder)

HPC	高压压气机 (High Pressure Compressor)
HPS	高压轴 (High Pressure Shaft)
HPT	高压涡轮 (High Pressure Turbine)
IBM	国际商业机器公司 (International Business Machines Corporation)
IR	隔离率 (Isolation Rate)
ISO	国际标准化组织 (International Organization for Standardization)
KELM	核极限学习机 (Kernel Extreme Learning Machine)
LPC	低压压气机 (Low Pressure Compressor)
LPS	低压轴 (Low Pressure Shaft)
LPT	低压涡轮 (Low Pressure Turbine)
LRU	航线可更换单元 (Line Replaceable Units)
LSTM	长短期记忆 (Long Short-Term Memory)
MAE	平均绝对误差 (Mean Absolute Error)
MAPE	平均绝对百分比误差 (Mean Absolute Percentage Error)
MaxAPE	最大绝对百分比误差 (Maximum Absolute Percentage Error)
MLP	多层感知机 (Multi-layer Perceptron)
MSE	均方误差 (Mean Squared Error)
M-RTCN	多层残差时间卷积网络 (Multi-layer Residual Temporal Convolutional Network)
MTL	多任务学习 (Multi-Task Learning)
NASA	美国国家航空航天局 (National Aeronautics and Space Administration)
N_A	不引入注意力机制的预测模型 (Non-Attention Model)
OEM	原始设备制造商 (Original Equipment Manufacturer)
OMA	机载监视告警 (On-board Monitoring Alarm)
PBM	性能基线模型 (Performance Baseline Model)
PHM	预测与健康管理 (Prognostics and Health Management)
PPM	个性化性能模型 (Personal Performance Model)
PTCN	金字塔时间卷积网络 (Pyramidal Temporal Convolutional Network)
P&W	普惠 (Pratt & Whitney)
QAR	快速存取记录器 (Quick Access Recorder)
RD-DTAE	原始气路参数-DTAE (Raw Data-DTAE)

RD-RF	原始气路参数-随机森林 (Raw Data-Random Forest)
RF	感受野 (Receptive Field)
RMSE	均方根误差 (Root Mean Square Error)
RUL	剩余使用寿命 (Remaining Useful Life)
R&R	罗尔斯·罗伊斯 (Rolls-Royce)
R-DTAE	残差-双任务自编码器 (Residual-DTAE)
STL	单任务学习 (Single-Task Learning)
T_A	基于时序注意力的预测模型 (Temporal Attention Model)
TBDA	基于变换的样本增强 (Transformation-based Data Augmentation)
TCN	时间卷积网络 (Temporal Convolutional Network)
TL	迁移学习 (Transfer Learning)
TMATS	热力学系统建模和分析工具箱 (Toolbox for the Modeling and Analysis of Thermodynamic Systems)
VAE	变分自编码器 (Variational Autoencoder)
VB	变分贝叶斯 (Variational Bayesian)

第 1 章 绪论

1.1 研究背景和意义

随着航空技术的不断发展，系统的复杂度越来越高，安全问题也日益突出。据国际航空运输协会统计，仅 2019 年全球民航飞机的维护、维修与大修市场规模可达 819 亿美元，其中发动机维修费用为 336 亿美元，占比高达 41%^[1]，如图 1-1 所示。随着航空发动机技术的不断演进，传统维护模式愈发难以满足其对安全性、可靠性、维修性与可用性（以下简称“四性”）的要求。以往，或是故障发生后才开展的事后维护，或是到既定时间便实施的定期维修，两类模式均存在显著缺陷^[2]。与之相对，基于状态的视情维修（即视情维修）彰显出巨大优势，它不仅能够缩减后勤保障规模、降低成本以增强经济可承受性，还可借助自动化手段达成高效作业，更为关键的是，能有效防范重大灾难性事故的发生，故而在当今乃至未来的发动机维护领域占据着关键地位^[3]。视情维修的实现，关键在于具备两大核心能力：一是对装备自身健康状态进行精准评估的能力，二是在系统出现失效迹象之前对其进行预测的能力^[4]。预测与健康管理的（Prognostics and Health Management, PHM）技术，正是为使发动机具备这两大能力而发展的，如今已成为提升发动机“四性”不可或缺的重要技术^[5]。




图 1-1 全球民航领域维护、维修与大修的相关费用

PHM 技术以传感器采集的设备运行数据为基础，通过融合推理模型与智能算法，构建覆盖设备状态监测、故障诊断、寿命预测及维护决策的一体化技术体系，

从多维度实现对航空发动机当前性能状态的实时监控与评估^[6]。国际标准化组织（International Organization for Standardization, ISO）在 13374 系列标准中，对 PHM 系统的架构做出明确界定，如图 1-2 所示^[7]。该架构包含数据采集、数据处理、状态监测、健康评估、预测评估及决策生成六大核心功能模块。其中，数据采集、数据处理与状态监测构成 PHM 系统的基础功能层，主要承担数据获取、预处理及初步状态感知的任务；而健康评估、预测评估与决策生成则属于核心应用层，需结合具体技术方案与工程需求，进一步转化为实际应用功能——通常表现为对设备故障类型与程度的诊断、对寿命的定量分析及预测，以及为运维人员提供具有指导性的维护策略建议，最终形成“数据-分析-决策”的闭环管理流程。




图 1-2 PHM 系统架构

机器及工业设备领域的预测与健康管理的 PHM 相关研究始于 20 世纪 60 年代，其技术演化呈现出从被动应对到主动预测的发展历程。初期研究聚焦于系统失效模式与影响分析，核心是通过解析失效机理实现对设备异常状态的监测与隔离，仅能完成检测部分故障的基础任务；随着技术需求深化，研究范畴逐步拓展至提高对于系统失效后的容错能力，目标是让设备在出现失效征兆后、正式维修前仍能维持短期安全运行，初步具备了主动维护的技术雏形^[8]。

20 世纪 80 年代初，数字航空电子计算机技术刚兴起，航空发动机领域便已出现简易数字化 PHM 的探索应用-通过机载机内测试（Built-in Test, BIT）实现系统故障检测。尽管该阶段系统的检测准确性、效率及可靠性尚未达到工程化标准，但设备自主健康监测的核心概念得以确立，为后续技术落地提供了方向指引^[9]。到 20 世纪 80 年代中期至 90 年代，联合攻击战斗机的自主后勤新需求成为关键驱动，直接推动四项基础技术实现突破性进展，进而促成“预测性维护”范式的形成。这四项技术分别是：人工智能、统计数据分析与机器学习的理论突破，为智能诊断提供算法支撑；信息与通信技术的快速迭代，构建数据传输共享的基础架构；传感器从模拟信号向数字信号的转型，实现数据高精度采集；数字控制系统与工业数据网

络的体系化发展，形成“数据采集-处理-分析”的技术闭环^[10]。

依托上述基础技术突破，PHM系统的核心能力进一步提升，具体表现为三方面：一是具备传感器与控制系统数据的数字化采集存储能力，为后续分析提供高质量数据基础；二是实现数据的本地实时处理、临时缓存及向中心节点远程传输，构建分布式采集至集中式分析的高效架构；三是能够通过人工智能与机器学习算法嵌入领域专业知识，自动化完成设备功能故障的诊断与失效趋势预测，并主动生成告警通知，为运维决策提供直接支撑^[11]。这一时期，民用航空发动机领域的PHM应用也进入工程化初期阶段，例如波音公司将中央维护计算机应用于波音747飞机，结合专家系统、人工智能技术实现对航线可更换单元（Line Replaceable Units, LRU）的故障诊断^[12]。

进入21世纪，航空运输业对发动机性能的要求愈发严苛，飞行频次提升、在翼时长增加、在地维护时间压缩等现实需求，使得发动机PHM技术的完善与升级迫在眉睫。根据NASA相关报告，2001—2004年商用航空公司年均飞机维修费用高达310亿美元，其中发动机维修费用占比超31%；而1987—2004年间，24%的机上死亡事故由部件故障或功能异常引发^[13]。追本溯源，当时PHM技术的不成熟与不完善是导致发动机运行安全性、可靠性不足的核心原因，也凸显出PHM技术产业化的迫切性。

在此背景下，全球主流航空发动机制造商纷纷加大PHM系统研发投入，推出各具特色的解决方案并构建产业生态。通用电气（General Electric, GE）公司推出资产性能管理系统^[14]，用于优化设备及机队的资产性能与维护效率，并顺应工业4.0趋势搭建工业互联网平台Predix，实现对数万至十几万台发动机的实时监测与诊断^[15]；罗尔斯·罗伊斯（Rolls-Royce, R&R）全球发动机健康监测中心构建发动机健康管理系统（Engine Health Management, EHM），提出“智能发动机”概念，还与微软合作成立数字化部门，借助Azure平台完成海量发动机运行数据分析^[16]；普惠（Pratt & Whitney, P&W）公司联合美国国家航空航天局（National Aeronautics and Space Administration, NASA）格林研究中心组建专项团队，为P&W F117发动机研制定制化PHM系统，同时与国际商业机器公司（International Business Machines Corporation, IBM）合作优化商用发动机数据流可视化方案，进一步提升性能监控能力^[16]；Safran公司为各型号发动机开发个性化PHM系统，并推进通用化技术环境建设，通过研发通用算法确保不同发动机PHM系统的一致性^[18]；Honeywell公司则推出飞行器综合健康管理系统，旨在降低系统总体运维成本，同时提升对故障特征的精准表达能力^[19]。在国内实践层面，中国南方航空公司已推出自主研发的飞机维护管理系统，该系统通过整合实时飞行信息监控、动态故障诊断、运营决策

生成、对空技术支援等核心功能，实现了维修工作的按需规划，以及人员、航材、设备等运维资源的精准调配，有效提升了飞机维护的时效性与经济性^[20]。

从航空产业发展的核心诉求来看，随着我国航空运输规模持续扩大和航空装备复杂度不断提升，开展高效故障诊断、精准寿命预测与全寿命周期健康管理的需求愈发迫切。这既是保障飞行安全、降低事故风险的重要基础，也是优化运维成本、提升装备使用效能的关键途径^[21]。然而，当前我国航空发动机 PHM 技术在状态感知、诊断精度、寿命预测和工程应用等方面仍与实际需求存在差距。基于此，本文以航空发动机气路系统为研究对象，围绕性能基线构建、故障诊断与剩余使用寿命预测开展研究，旨在为复杂运行条件下航空发动机健康管理提供理论与方法支撑。

1.2 国内外研究现状

1.2.1 基于性能基线模型的航空发动机状态监视方法研究

发动机状态监视（Engine Condition Monitoring, ECM）是监控发动机日常运行状态的一种技术，在提供正在发生或即将发生故障的早期预警信息方十分有效^[22]。ECM 通过与驾驶员和地面维护系统进行交互，及时修正发动机的工作状态，从而减少更严重的发动机故障发生概率和飞行计划外的延误^[24]。ECM 目标在于将性能参数作为一个可靠的指标，以显示正在发展中的缺陷和即将发生的故障，并在检查和大修期间对这些缺陷和故障进行检测和修复^[25]。

依据监视流程的差异，ECM 技术体系可明确划分为机载状态监视与地面状态监视两大分支，二者在应用场景、技术侧重点与功能目标上存在显著区分，发动机的监视流程如图 1-3 所示^[26]。其中，机载状态监视以实现机载监视告警（On-board Monitoring Alarm, OMA）为核心目标，首要任务是保障发动机在飞行过程中的持续正常运行，因此对实时性与安全性的要求极高。在具体监测逻辑上，OMA 通过对发动机关键参数的实时采集与超限判别，判断是否触发告警信号以提醒驾驶员调整工作状态^[27]。然而受限于机载系统的计算能力与实时性需求，机载监视无法采用复杂的告警算法与故障隔离流程，仅能对影响发动机正常工作的灾难性异常进行判断，难以实现精细化的故障诊断与趋势分析。与机载监视不同，地面状态监视的应用场景聚焦于发动机两次工作间隙，核心功能是通过气路、振动、滑油等特征参数的深度分析，判断发动机是否存在换件或维修需求，确保下次飞行前发动机处于正常状态。




图 1-3 发动机状态监视流程

从数据支撑来看，机载数据采集系统会通过飞机通信寻址与报告系统（Aircraft Communications Addressing and Reporting System, ACARS）等方式传输当次飞行的“飞行快照”，但受传输带宽、传输成本及数据存储成本的限制，这类数据量极为稀少，仅能满足基础状态判断，例如南方航空公司部分航线的单次传输数据仅包含两个起飞状态采样点与两个巡航状态采样点，无法支撑深度^[28]。而地面状态监视可依托快速存取记录器（Quick Access Recorder, QAR）获取当次飞行的完整数据，数据量远大于无线传输数据，且地面先进工作站具备更强的计算能力，能够支持复杂智能诊断和预测算法的应用，因此地面监视的分析结果通常更详细、更精确，从而辅助相关从业人员进行维护决策^[29]。

在 ECM 技术的发展过程中，性能基线模型（Performance Baseline Model, PBM）的准确性与有效性成为实现故障早期预警与健康评估的关键前提。PBM 的核心作用是描述发动机在无故障状态下，各项性能参数与控制量之间的函数关系，为实际监控数据的异常检测提供基准参考^[30]。从建模逻辑来看，PBM 通常以控制量及表征发动机功率输出的关键参数为输入变量，通过对近期飞行数据的统计分析实现模型的动态调整，确保 PBM 能够适应发动机的正常性能衰减，避免误报或漏报。

当前，PBM 的构建方法主要分为三类：基于物理机理的方法、基于数据驱动的方法，以及机理与数据融合的混合方法^[31]。基于物理机理的方法以航空发动机物理状态的数学描述为核心，通过空气动力学与热力学分析构建模型，这类模型通常由相关主机单位或原始设备制造商（Original Equipment Manufacturer, OEM）在发动机设计阶段开发，其构建依赖系统性的部件测试数据与详细的设计点数据，可形成准一维或多维的发动机性能仿真模型^[32]；该类模型的显著优势在于高可解释

性与强物理一致性,不仅能够有效估算难以直接测量的关键性能参数,还可对发动机状态进行全面评估,典型案例包括美国早期建立的单轴涡喷发动机与涡桨发动机模型、NASA 发布的动态通用发动机 (DYNamic Generalized Engine, DYNGN) 模型^[34]、数字化涡扇发动机模型 (DIGital Turbofan Engine Models, DIGTEM)^[35]以及热力学系统建模和分析工具箱 (Toolbox for the Modeling and Analysis of Thermodynamic Systems, TMATS)^[36],德国 MTU 公司推出的 GasTurb 模型^[37]、用于大涵道比涡扇发动机仿真的商用模块化航空推进系统仿真 (Commercial Modular Aero Propulsion System Simulation, CMAPSS) 模型^[38],还有采用面向对象方法、组态技术等建立的涡扇、加力涡扇等不同类型发动机模型。近些年,国内的相关研究更多聚焦于表征发动机的动态特性与实时性,以此持续提升模型的整体精度,如潘慕绚等^[39]基于转子动力学、容积动力学和热力学原理,提出涡扇发动机多动力学建模方法。殷锴等^[40]通过建立气体热力属性插值表并结合 Broyden 迭代方法,大幅提高了模型的单步运算速率。

基于数据驱动的 PBM 建立方法是近些年来研究热点,与机理模型不同,数据驱动模型无需依赖大量物理原理,而是通过端到端的方式直接从海量真实飞行数据中学习性能参数与控制量之间的复杂映射关系,具备强适应性与短开发周期的优势,尤其适用于在设计数据和部件特性未知的情形下^[41]。在数据驱动模型的应用中,时空特征的耦合对预测精度至关重要:时间特征既包含飞行过程中发动机的动态响应(如控制指令或瞬态过程引发的部件快速变化),也涵盖不同飞行阶段(起飞、爬升、巡航、下降)的长期趋势;空间特征则主要体现在各传感器间的关联性,受发动机气路流路与气流连续性的影响,不同传感器通道之间形成了复杂的耦合与协同作用,例如 Meng 等^[43]提出一种基于多层残差时间卷积网络 (Multi-layer Residual Temporal Convolutional Network, M-RTCN) 的推力估计器。Xiao 等^[44]则基于级联式的长短期记忆 (Long Short Term Memory, LSTM) 网络组构建了 PBM,并基于地面试车数据对所提方法的精度进行了验证。

混合建模方法通过引入数据驱动模型作为经验补偿模块,解决单一物理机理的局限性。这类补偿模块可依据目标发动机的实际运行数据,修正因参数不完整、部件特性不确定或存在未建模因素导致的模型误差,从而构建面向目标发动机的个性化性能模型 (Personal Performance Model, PPM)。如普惠公司^[45]引入基于神经网络的补偿模型,用于处理发动机个体差异产生的误差;此后, Xu 等^[46]进一步应用极限学习机 (Extreme Learning Machine, ELM) 作为补偿网络,对物理模型的输出结果进行校准,同时通过敏感性分析从候选变量中筛选最具影响力的参数,优化补偿模型的输入选择,提升模型效率与精度。

1.2.2 多源不确定性气路故障诊断方法研究

气路故障通常表现为发动机各核心部件的输出功或关键性能参数由于效率骤降出现的超限等状况,使发动机处于异常的工作状态,甚至威胁到发动机的安全运行^[47]。据相关研究成果表明:在发动机总体故障中,气路故障约占比 90%以上,其维护费用占发动机总体维护费用的 60%^[48]。在航空发动机气路故障诊断领域,多元不确定性是制约诊断系统准确性与可靠性的核心瓶颈:其一,工况不确定性源于飞行任务剖面的动态变化,导致发动机常处于非设计点运行状态,运行参数呈现复杂时变特性;其二,噪声不确定性涵盖传感器测量噪声、电磁干扰及数据传输误差,使采集信号与发动机真实运行状态产生偏差,甚至掩盖气路系统早期微弱的故障特征信号;其三,个体间差异不确定性由制造工艺偏差、部件装配精度及初始性能离散性导致,造成同型号发动机在相同工况下的性能输出存在显著个体差异;其四,退化不确定性表现为发动机在全寿命周期内受磨损、腐蚀、疲劳等因素影响,性能参数逐步偏离初始基线,其与故障的本质区别在于发动机短期性能变化的速率与幅度,这种同向差异易导致诊断结果出现高误警率,此外,这一问题还会因退化过程的特殊性进一步加剧,由于退化是长期渐进的过程,且故障多为小概率突发情况,因此退化过程中的故障样本往往存在稀缺性与不完备性,如何保障故障诊断模型在全寿命周期内的鲁棒性与可靠性,成为亟待解决的核心问题^[49]。

上述多元不确定性因素在实际诊断场景中相互耦合、叠加作用,大幅降低了气路故障诊断的精度与置信度,亟需构建针对性的不确定性量化与抑制方法以应对此类挑战。

针对工况不确定性引发的运行状态复杂、数据不可比问题,当前研究以 PBM 为核心解决方案,其核心逻辑是基于发动机在标准工况下的物理机理与性能参数,构建覆盖不同转速、负荷、环境条件的“工况-参数”映射基准,当发动机实际运行时,通过实时采集转速、截面压力、温度等核心参数,与 PBM 在对应工况下的输出值进行残差比对,识别由气路故障引发的异常偏差。例如 Liao 等^[50]基于 PBM 构建发动机在复杂工况下的输出。Huang 等^[51]使用两个深度玻尔兹曼机(Deep Boltzmann Machines, DBM)提取并融合发动机传感器参数和 PBM 的特征。

在噪声不确定性导致的信号失真、故障特征不明显的问题上,信号处理与智能算法结合的降噪策略是主流的解决策略。传统小波变换、自适应平滑等方法通过频域或时域滤波剥离随机噪声与电磁干扰,而近年来基于概率统计与深度学习的降噪技术展现出更强鲁棒性,如王启航等^[52]提出的变分贝叶斯(Variational Bayesian, VB)结合核极限学习机(Kernel Extreme Learning Machine, KELM)的边缘化粒子滤波方法,通过实时递归估计噪声统计特性实现动态降噪;黄郑等^[53]基于发动机

运行先验知识改进强跟踪卡尔曼滤波器，提升了非高斯噪声下的滤波精度；Wang 等^[54]则利用降噪自编码器（Denoising Autoencoder, DAE）的重构特性，在保留故障特征的同时实现了对于原始信号的降噪。

针对个体间差异不确定性导致的诊断模型泛化性不足问题，当前主流解决方案是结合 PBM 开展协同校正，其自适应校正方法大体可分为基于物理特性的修正方法与基于残差补偿的修正方法两类：其中，基于物理特性的修正方法面向物理机理 PBM，多通过对发动机部件特性图进行放缩、旋转等变换，并结合特定寻优或迁移算法实现目标发动机适配，例如郭庆等^[55]采用粒子群寻优算法，筛选增压比相近的成熟型号发动机部件特性图，完成对目标发动机 PBM 的自适应。而基于残差补偿的修正方法以 PBM 输出为基准，通过量化目标发动机实测数据与基准模型的性能偏差构建个体差异特征库，典型如孙浩等^[56]采用经验建模方式，补偿机载实时模型输出与发动机测量参数间的偏差，有效提升了机载自适应模型在全飞行包线内的参数跟踪与估计性能。

针对退化不确定性导致的高误警率问题，在线学习是当前常用的应对策略，其核心逻辑为通过动态调整诊断模型参数，适配发动机退化后的故障特征演变，进而保障模型全寿命周期的鲁棒性。然而，在线学习的有效实施高度依赖足量故障样本，而发动机退化过程中难以获取充足的实测故障样本，这一矛盾成为制约其应用的关键瓶颈。因此，基于退化后的正常数据分布，结合合理的映射方法生成用于在线学习的辅助故障样本，是突破该瓶颈的重要技术路径。例如 Wang 等^[57]提出基于物理-虚拟数据融合的数字孪生方法，通过在虚拟空间中引入故障影响因素，生成符合实际退化规律的故障模拟数据；Liao 等^[50]则引入特征过滤器，通过构建退化状态与故障特征的关联映射，实现对退化场景下故障数据的有效生成，为在线学习提供样本支撑。

1.2.3 域自适应方法的小样本故障诊断方法研究

在航空发动机等复杂装备的故障诊断工程场景中，小样本问题始终是制约诊断模型实用性落地的核心瓶颈。相较于发动机退化过程中面临的故障样本稀缺问题，若连初始健康状态下的发动机故障基础数据都难以保障，则会更具挑战性。传统数据驱动型故障诊断方法高度依赖大规模标注样本完成模型训练与参数优化，该固有特性直接导致其在小样本场景下的泛化能力急剧衰减，无法满足复杂装备对故障诊断精度与可靠性的实际工程需求。

域自适应（Domain Adaptation, DA）作为迁移学习（Transfer Learning, TL）的核心分支，凭借其跨越域分布差异、复用源域知识的独特能力，成为破解上述初始

故障数据不足难题的关键技术路径^[58]。其核心逻辑在于：通过构建源域与目标域的域间迁移机制，主动削减两类数据的分布差异，使基于源域数据训练的模型能够有效适配目标域的小样本数据，从而摆脱对于初始大量目标域数据的需求。

在此类场景中，传统数据增强方法存在显著局限性。传统的数据增强方法通过旋转、加噪、插值等数据变换生成更多样本，但生成数据往往难以完全匹配真实故障的物理特性，无法补充样本内部的关键故障特征，更无法解决目标域故障数据分布缺失导致的模型适配问题^[59]。相比之下，域自适应方法通过知识迁移与分布对齐的双重逻辑，既能够引导模型学习源域有效的故障特征，又能够逐步对齐源域与目标域的特征分布，从根本上提升模型对目标域小样本数据的适配能力，避免因数据分布差异导致的诊断偏差^[60]。

在小样本故障诊断的实践中，域自适应与生成模型结合形成优势互补的技术方案。常用的思路为数据补充+知识迁移的方式，即生成模型负责解决目标域初始故障样本量不足的问题，域自适应则负责消除生成样本与目标域真实数据的分布差异。如 Ding 等^[61]提出改进生成对抗网络（Generative Adversarial Networks, GAN）和 TL 框架，通过在 GAN 中引入相似度度量损失提升生成数据质量，同时运用 TL 训练后续诊断算法中的分类器。类似地，He 等^[62]采用深度卷积生成对抗网络（Deep Convolutional Generative Adversarial Network, DCGAN）增强故障样本，并运用 TL 提取故障特征参数。这些方法直接通过生成模型实现数据增强，再利用 TL 将故障特征迁移至目标域，提高目标域故障诊断的精度。

1.2.4 航空发动机剩余使用寿命预测方法研究现状

航空发动机剩余使用寿命（Remaining Useful Life, RUL）预测是指在发动机运行至某一时刻时，依据其当前健康状态及历史退化规律，预测其距离失效所剩余的可用运行时间。本文所讨论的 RUL 预测主要面向在役发动机运行监测场景，重点关注如何利用传感器数据、运行工况和历史退化样本表征气路性能退化过程，并预测 RUL。与传统结构强度设计中的疲劳寿命计算、部件定寿或寿命裕度评估相比，该类方法不直接以材料损伤、载荷谱或裂纹扩展为主要分析对象，而是更强调从运行监测数据中识别发动机性能状态变化及其退化趋势。

准确的 RUL 预测对于实现视情维修、降低非计划停机风险、保障飞行安全具有重要意义。航空发动机的性能退化通常由疲劳、腐蚀、磨损、积垢、热损伤等多种因素共同作用引起，其退化机理复杂且具有明显的随机性和非线性特征^[63]。虽然这些退化因素最终会反映为部件效率、流量能力、温度、压力和转速等性能参数的变化，但表征发动机真实健康状态的健康指标往往难以直接测量，通常需要借助

可观测传感器数据和历史退化样本进行间接建模与估计^[64]。因此, 现有航空发动机 RUL 预测方法通常围绕“性能退化状态如何表征”和“退化趋势如何外推”两个核心问题展开。根据退化建模方式的不同, 相关方法大体可分为基于物理失效模型的方法和基于数据驱动的方法^[67]。

基于物理失效模型的 RUL 预测方法主要通过建立部件损伤演化、裂纹扩展、疲劳累积或材料失效模型, 描述关键部件由健康状态向失效状态演化的过程。该方法具有较强的机理解释性, 能够将寿命预测结果与材料特性、载荷谱、应力分布和工作环境等因素相联系, 因此常用于轮盘、叶片、轴承等关键部件的寿命评估。例如, Lei 等^[68]提出了基于物理失效概率的航空发动机轮盘疲劳寿命预测框架; Oakley 等^[69]考虑 R 比和 V 型缺口根部残余应力影响, 构建了用于叶片疲劳寿命预测的短裂纹中止模型; 孙宇博等^[70]建立了 TC4 钛合金叶片振动疲劳裂纹扩展寿命计算模型; 孙见忠等^[71]结合状态空间模型与贝叶斯理论开展了发动机气路部件 RUL 预测。现有研究表明, 物理失效模型能够较好刻画特定部件和特定失效模式下的寿命演化规律, 但其应用依赖于对失效机理、材料属性、载荷历程和边界条件的充分掌握。对于航空发动机整机系统而言, 部件耦合关系复杂、运行工况多变, 构建完备高精度物理失效模型难度较大, 限制了其在整机级 RUL 预测中的应用。

与物理失效模型不同, 基于数据驱动的 RUL 预测方法主要依赖发动机从正常运行到失效过程中的历史监测数据, 通过统计建模、机器学习或深度学习建立监测参数与健康状态或剩余寿命之间的映射关系。该方法对先验机理知识依赖较低, 具有建模灵活、适应性强和易于工程实现等优点, 已成为当前航空发动机 RUL 预测研究中的主流方向。早期数据驱动方法多采用隐马尔可夫模型^[72]、随机过程^[74]、人工神经网络^[75]、支持向量机^[77]等方法对发动机退化过程进行建模。根据建模思路不同, 数据驱动 RUL 预测方法可进一步分为直接映射方法、基于随机过程的方法和基于相似性匹配的方法^[79]。

直接映射方法通过构建传感器监测参数到 RUL 标签之间的端到端映射关系, 实现剩余寿命估计。近年来, 深度循环神经网络^[80]、深度置信网络^[82]以及卷积神经网络^[83]被广泛用于提取多源传感器数据中的非线性退化特征, 并取得了较好的预测效果。该类方法的优势在于能够自动学习高维监测数据与寿命标签之间的复杂关系, 避免人工构造健康指标的繁琐过程。然而, 其关键在于 RUL 标签的设定。常见做法是将当前时刻至失效时刻的时间间隔直接作为 RUL 标签, 即默认剩余寿命随运行时间线性递减^[85]。但航空发动机性能退化通常具有阶段性和非线性特征, 线性标签难以准确反映实际退化规律。为此, 部分研究采用分段 RUL 标签, 将运行初期 RUL 设为常数, 随后采用线性函数^[88]或幂函数^[90]描述退化阶段的

寿命衰减过程。尽管这种方式更符合“初期稳定、后期加速退化”的一般规律，但由于不同发动机受制造差异、初始磨损、服役环境和维护历史影响显著，其初始最大 RUL 和退化起点往往难以统一设定，导致模型的个体适应性仍然不足。

基于随机过程的方法则从退化过程的不确定性出发，将发动机性能退化视为具有随机扰动的动态演化过程，并利用概率模型实现 RUL 预测。典型方法包括 Wiener 过程、Gamma 过程、隐马尔可夫模型及其改进形式。Liu 等^[92]采用多阶段 Wiener 过程描述发动机性能退化，并利用贝叶斯方法实时更新模型参数，实现了单台发动机的 RUL 预测；Son 等^[93]利用主成分分析从高维监控数据中提取退化指标，并基于 Wiener 过程建模退化轨迹；Zhou 等^[94]提出缩减内核递归最小二乘与隐马尔可夫模型相结合的多传感器预测模型，在降低计算消耗的同时提升了预测性能；Giantomassi 等^[95]则结合人工神经网络与隐马尔可夫模型，实现了特征提取与寿命预测的联合建模。此类方法能够较好描述退化过程中的随机波动和预测不确定性，但通常需要预先确定退化过程形式，并依赖大量历史数据估计模型参数。当发动机运行环境复杂、退化模式多样或个体差异显著时，随机过程模型的先验假设和参数泛化能力容易受到限制。

基于相似性匹配的方法本质上属于模式识别范畴，其基本思想是从历史运行到失效样本中学习典型退化轨迹，并将当前发动机的观测退化历史与历史样本进行匹配，从而推断其未来退化趋势和剩余寿命。随着深度学习的发展，该类方法逐渐由传统的距离度量和轨迹匹配扩展为深度特征相似性建模。其核心在于如何从多源传感器数据中提取能够表征退化阶段和退化趋势的深层特征，并有效刻画不同传感器之间的空间关联及长时间序列中的动态依赖关系。例如，Li 等^[96]提出卷积神经网络（Convolutional Neural Networks, CNN）与 LSTM 相结合的混合架构，利用 CNN 提取传感器空间特征，并通过 LSTM 建模时间依赖，实现监测参数到 RUL 的端到端预测；Han 等^[97]引入双注意力机制的并行 CNN-LSTM 网络，以强化关键传感器和关键时间片段的贡献；Mitici 等^[98]构建基于蒙特卡罗 CNN 的概率预测框架，在给出 RUL 估计的同时量化预测不确定性；Bae 等^[99]利用 LSTM 学习物理健康时间步长，以更准确捕捉退化阶段演化规律；Faizanbasha A. 等^[100]融合 CNN、Transformer、LSTM 和随机层构建混合集成模型，以适应复杂劣化条件下的 RUL 预测需求。这些研究表明，深度特征提取与时序建模的结合能够显著提升 RUL 预测精度，但同时也对样本规模、数据一致性和模型泛化能力提出了更高要求。

近年来，随着航空发动机运行数据规模的扩大和深度学习模型的发展，RUL 预测研究逐渐从单纯追求预测精度，转向关注复杂运行环境下的泛化能力、个体适应性和时空耦合特征建模。首先，不同飞行任务、运行环境和工况分布会导致监测数

据存在明显分布偏移,使得在某一工况或某一数据集上训练的模型难以直接迁移至其他运行条件。为此,部分研究引入域适应、特征解耦和工况对齐策略,以削弱运行状态变化对退化特征提取的干扰。Wen 等^[101]提出残差对抗特征解耦方法,通过状态映射与对抗训练去除运行工况干扰,提取更接近本质退化过程的特征;Xu 等^[102]基于改进 Transformer 构建多工况时空特征表达,通过多维注意力机制和工况统计先验提升复杂场景下的预测性能;Wang 等^[103]则结合自动健康状态划分与协同多模型学习,实现健康状态标注和多步趋势预测的联合建模。上述研究表明,在多工况条件下,如何区分工况变化与真实性能退化,是提升 RUL 预测可靠性的关键。

同时,航空发动机传感器数据具有显著的时空耦合特性。一方面,不同传感器之间存在由气动热力过程和控制规律决定的空间关联;另一方面,发动机退化过程又表现为长时间尺度上的动态演化。因此,有效挖掘高维传感器特征与长期时序依赖,是提升 RUL 预测精度的重要方向。Costa 等^[104]采用变分编码方法进行空间特征提取;Kamei 等^[105]利用 Transformer 结构建模多传感器时间序列中的时空依赖;Xiang 等^[106]提出贝叶斯门控 Transformer,通过门控机制和贝叶斯建模增强多通道时间序列特征表达;Liu 等^[107]开发差分 Transformer 网络,以差分注意力机制刻画非平稳退化过程;Lin 等^[108]提出结合通道注意力与时间注意力的时间卷积网络(Temporal Convolutional Network, TCN),Zhang 等^[109]提出注意力时域卷积网络,分别从传感器通道选择和关键退化时刻捕捉角度提升模型的时空特征提取能力。总体来看,融合 CNN、LSTM、TCN、Transformer 及注意力机制的深度模型已成为当前 RUL 预测的重要发展趋势,其优势在于能够自动挖掘复杂非线性退化规律,但也存在模型结构复杂、可解释性不足、跨工况泛化能力有限以及对个体差异适应不足等问题。

1.3 研究现状分析

根据上述国内外研究现状分析可知,在航空发动机的气路性能监视、故障诊断、剩余寿命预测领域还存在相关问题亟待解决,可梳理如下:

(1) 当前基于 PBM 的航空发动机性能状态监视技术仍面临两个关键问题:一是单台发动机的个体适配能力不足,二是全寿命周期内性能演化的自适应表征能力有限。对于个体适配问题而言,即使是同型号发动机,也会受到制造公差、装配偏差、转子平衡状态、维护历史、航线环境以及运行操作差异等因素影响,使其实际性能响应与名义基准模型之间存在一定偏差。传统 PBM 主要刻画机队或名义发动机的共性性能规律,难以完全覆盖单台发动机的初始性能差异和局部模型失

配,因此在实际监视过程中容易产生未建模误差,影响性能偏移识别的准确性。对于全寿命周期自适应问题而言,现有方法多通过调节健康因子或修正部件特性图的方式描述发动机性能退化,但这类方法往往依赖较完整的核心部件特性数据和机理模型支撑,且对实际服役过程中复杂、非线性、时变的退化过程表征能力有限。尤其在航司等难以获取部件特性和设计细节的应用场景下,传统机理驱动的退化修正方法难以直接迁移应用,使得面向真实运行数据的数据驱动长周期性能监视方法仍需进一步研究。

(2) 气路故障诊断的准确性与可靠性长期受制于工况变化、测量噪声、个体差异及性能退化等多源不确定性的耦合叠加影响。随着发动机服役过程推进,气路参数基准水平和残差分布会发生持续漂移,正常退化偏移与微弱故障特征容易在特征空间中相互耦合,使故障边界逐渐模糊,从而增加故障检测与隔离难度。因此,如何在多源不确定性条件下有效削弱非故障因素对诊断特征的干扰,并提取兼具稳定性与判别性的故障表征,是提升航空发动机气路故障诊断可靠性的关键。

(3) 当同型号发动机可获得的故障样本较少时,精确故障诊断模型的构建面临更大挑战。一方面,有限的故障数据难以充分覆盖不同故障类型、故障程度和运行工况下的特征分布,使模型难以学习完整的故障判别边界,进而削弱其对未知工况和未知个体的识别能力;另一方面,健康样本与故障样本之间通常存在显著数量不平衡,模型训练过程容易偏向样本数量占优的健康状态或典型故障类别,导致少数故障模式识别能力不足甚至过拟合。上述数据层面的不足会直接降低模型对目标发动机的适应能力,使其在跨工况、跨个体和跨退化阶段应用时出现诊断精度下降和泛化性能不足等问题。

(4) 在航空发动机 RUL 预测领域,现有研究多采用数据驱动方法构建端到端预测模型,通过深度神经网络直接学习监测序列与寿命标签之间的非线性映射关系。这类方法在一定程度上提升了复杂时序数据的建模能力,但多数工作更侧重于网络结构优化,而对原始传感器数据中工况变化、个体差异与真实退化信息的解耦不足,导致模型学习到的特征缺乏明确的退化指向性和物理可解释性。尤其在多工况和长周期服役条件下,若不能有效提取反映性能劣化过程的显式退化特征,RUL 预测模型容易受到非退化因素干扰,影响预测精度与稳定性。因此,如何从高维动态运行数据中构建寿命敏感的退化表征,并进一步通过特征增强机制突出关键退化阶段和重要监测变量,是提升航空发动机 RUL 预测性能亟需解决的关键问题。

1.4 论文主要内容和章节安排

针对上述问题并结合航空发动机实际运维中的关键需求,本文围绕气路性能

监视、故障诊断与剩余使用寿命预测三个方面展开研究。总体上，本文以性能基线为主线，首先研究航空发动机在无故障状态下的性能基线构建与个性化自适应方法，为状态偏移识别提供参考基础；其次，面向多源不确定性和小样本故障条件，分别研究基于个性化残差的鲁棒故障诊断方法，以及基于域自适应的故障样本生成与诊断增强方法，以提高复杂运行条件下的故障检测与隔离能力；最后，面向 RUL 预测，研究基于健康基准残差的退化特征显式表征方法，并构建融合互补注意力的寿命预测模型，以提升复杂退化场景下的 RUL 预测精度与稳定性。基于上述内容，本文的具体研究思路以及各章节的安排如图 1-4 所示：




图 1-4 论文章节安排

论文第 1 章阐述选题背景及意义，综述性能状态监视、故障诊断与预测的研究现状，明确相关技术应用中的挑战及潜在解决路径。

论文第 2 章提出面向个性化长周期的双旁路自适应性能监视方法，分别从物理机理与数据驱动角度构建性能基线模型（Performance Baseline Model, PBM），并

基于 PBM 构建发动机个性化性能模型 (Personalized Performance Model, PPM)。该框架的核心创新在于整合双旁路模型：未建模旁路用于捕捉未建模因素导致的个体性能差异，退化旁路专注于追踪全寿命周期内的性能退化趋势。该方法为解决个体适配性不足与全寿命周期模型自适应挑战提供了新范式，为后续故障诊断与寿命预测提供性能基准。

论文第 3 章提出针对多源不确定性的气路故障诊断方法。该方法基于第 2 章构建的 PPM 生成目标发动机在当前工况下的正常参考输出，并通过实测状态参数与参考输出之间的差值构建残差特征，以削弱工况变化、个体差异和正常退化对故障判别的影响；随后，引入双任务自编码器 (Dual-task Autoencoder, DTAE) 对残差特征进行鲁棒表征学习，通过加噪与掩码机制增强模型对测量噪声和局部扰动的适应能力，并利用重构任务与分类任务的联合约束，使编码器在低维潜特征空间中学习兼具结构完整性和类别可分性的故障特征；最后，采用先故障检测、后故障隔离的分阶段诊断策略，实现对发动机异常状态和具体故障类型的可靠识别。

论文第 4 章提出基于域自适应的航空发动机小样本故障诊断方法。该方法利用源域中较为丰富的正常样本与目标域少量故障样本，通过深度特征提取与域分布对齐，减小源域与目标域在特征空间中的分布差异，构建具有跨域一致性的健康状态表征；在此基础上，进一步利用目标域少量故障样本所提供的故障偏移信息，生成面向目标域的故障样本，以扩充诊断模型训练所需的故障样本空间，从而提高模型在目标发动机小样本故障诊断场景下的识别精度和泛化能力。

论文第 5 章提出基于退化特征增强的剩余使用寿命预测方法。该方法在第 2 章 PPM 模型基础上保留未建模旁路以补偿个体差异，同时去除退化旁路，使实测值与健康基准预测值之间的残差能够更直接表征发动机性能退化程度。在此基础上，构建融合互补注意力机制的 RUL 预测框架，利用金字塔时间卷积网络 (Pyramidal Temporal Convolutional Network, PTCN) 提取多尺度时序退化特征，并通过时序注意力和通道注意力分别突出关键退化阶段与重要监测变量，从而形成由健康基准建模、退化特征增强到 RUL 映射预测的完整方法体系，提高复杂运行条件下航空发动机 RUL 预测的准确性与鲁棒性。

论文第 6 章总结研究工作的创新点及成果，并对未来研究方向进行展望。

第2章 面向个性化长周期的双旁路自适应监视方法研究

2.1 本章引论

PBM 是航空发动机性能状态监视的重要基准,其建模精度直接影响异常检测、故障诊断与趋势预测结果的可靠性,也是支撑视情维修、飞行安全保障和运维成本优化的关键基础。通过构建 PBM,可以定量描述发动机在无故障状态下运行工况、控制输入与气路性能参数之间的内在映射关系,为性能偏移识别、早期异常发现和健康状态评估提供参考依据。

航空发动机 PBM 的构建方式与数据获取条件密切相关。对于发动机设计单位或原始设备制造商 (Original Equipment Manufacturer, OEM) 而言,其通常能够掌握较为完整的部件特性、设计参数和试验数据,因此基于物理机理的 PBM 能够充分发挥热力学模型在物理一致性、可解释性和外推能力方面的优势,较为准确地描述发动机在无故障状态下的性能演化规律。相比之下,航空公司在实际运行维护过程中通常难以获取完整的核心部件特性和设计细节,基于机理模型的 PBM 构建受到一定限制。因此,面向航司应用场景,有必要利用真实运行数据构建数据驱动 PBM,从快速存取记录器 (Quick Access Recorder, QAR) 等实测数据中学习运行工况、控制变量与关键气路测点之间的映射关系,以支撑在翼发动机性能监视。然而,无论采用物理机理建模还是数据驱动建模, PBM 通常只能表征名义发动机或机队群体的共性性能规律,难以完全适应单台发动机的初始个体差异和全寿命周期内逐渐累积的性能退化。因此,如何在 PBM 基础上实现面向单台发动机的个性化长周期性能监视,是本章需要解决的核心问题。

针对上述问题,本章提出一种面向个性化长周期监视的航空发动机双旁路自适应性能监视方法。首先,针对不同数据条件,分别从物理机理和数据驱动两个角度构建 PBM;随后,以 PBM 为基础引入旁路补偿结构,构建目标发动机 PPM。其中,未建模旁路用于补偿 PBM 难以覆盖的初始个体差异和局部模型失配,例如制造偏差、装配差异、维护状态差异以及真实运行环境下的未建模扰动;退化旁路则用于刻画发动机随服役周期推进而逐渐累积的长期性能偏移。通过二者协同作用,PPM 能够在保持 PBM 基准约束的基础上,实现对单台发动机初始差异和长周期退化过程的自适应表征。

本章结构安排如下:2.1 节给出本章研究背景与总体思路;2.2 节定义航空发动机性能监视问题;2.3 节分别从物理机理和数据驱动角度介绍 PBM 的构建方法;

2.4 节提出基于未建模旁路与退化旁路的 PPM 构建及自适应更新方法；2.5 节以小涵道比军用发动机为对象开展仿真验证与结果分析；2.6 节以大涵道比民用涡扇发动机真实 QAR 数据为对象开展验证与结果分析；2.7 节对本章研究内容进行总结。

2.2 性能监视问题定义

性能监视的核心任务是构建一个能够随时间 t 演化、且能消除个体差异干扰的 PPM。由于航空发动机具有强非线性、强耦合和多工况运行特征，其气路测量参数通常不是单一因素作用的结果，而是由环境条件、控制输入、个体差异、噪声以及长期性能退化等多个时变物理因子共同决定的复杂非线性响应。其中，环境条件和控制输入主要决定发动机的当前工作点，可作为 PBM 的显式输入，用于描述名义状态下工况到气路参数之间的映射关系；而制造装配差异、维护状态差异及长期服役退化等因素则体现为相对于名义基线的个体化性能偏移，难以由 PBM 完全刻画。因此，性能监视问题不仅需要建立由工况变量到气路测量参数的基准映射，还需要在此基础上对单台发动机的初始个体差异和随时间累积的退化偏移进行自适应补偿，从而形成能够长期跟踪目标发动机性能状态的 PPM。

2.2.1 连续时间下的 PPM

对于目标发动机个体，其传感器观测数据 $y(t)$ 与系统内部状态演化可由式(2-1)的连续时间状态空间模型表述：

$$\begin{cases} \dot{x}(t) = f(x(t), u(t), a(t), \omega(t), \varphi(t)) + \eta(t) \\ y(t) = g(x(t), u(t), a(t), \omega(t), \varphi(t)) + \varepsilon(t) \end{cases} \quad (2-1)$$

其中， $x(t)$ ——代表系统状态参数；

$\dot{x}(t)$ ——代表状态参数对时间的导数，即系统的动态响应；

$u(t)$ ——代表外部控制输入；

$a(t)$ ——代表环境边界参数；

$\omega(t)$ ——代表发动机个体间的制造差异，在稳定服役期满足 $\dot{\omega} \approx 0$ ，但在维修或大修节点后可能发生跳变；

$\varphi(t)$ ——代表长周期演化中的性能衰退， $\dot{\varphi}$ 受环境和载荷的连续影响；

$y(t)$ ——代表传感器观测数据；

$\eta(t)$ ——代表系统噪声；

$\varepsilon(t)$ ——代表测量噪声；

$t \in [0, T]$ ——代表服役时间， T 为全寿命总时长。

2.2.2 PPM 的加性解耦表达

由于 PBM 通常基于名义个体建模，无法涵盖个体的随机性和时变性。因此，进一步将 PPM 的输出 $y_{PPM}(t)$ 定义为在名义基准模型 $y_{PBM}(t) = f(x(t), u(t), a(t))$ 基础上的补偿修正，如式(2-2)所示：

$$y_{PPM}(t) = y_{PBM}(t) + \Delta y_{umm}(t) + \Delta y_{deg}(t) \quad (2-2)$$

其中， $\Delta y_{umm}(t)$ 为由 $\omega(t)$ 引起的未建模个体差异补偿项， $\Delta y_{deg}(t)$ 为由 $\varphi(t)$ 引起的性能退化补偿项。

在 PBM 提供的通用框架基础上，针对每台发动机 u 的独特性（如制造公差、维修历史、个体性能衰退轨迹等），本章通过双旁路自适应算法实现主——旁协同的个性化适配。

在该架构中，PBM 的核心物理参数保持固定，通过实时观测数据微调双旁路的自适应参数 $\{\theta_{umm}^u, \theta_{deg}^u\}$ 。两者的功能定位解耦如下：

(1) 未建模旁路聚焦补偿结构突变型偏差，如初始制造公差引起的性能偏置、大修后的性能跳变。其参数 θ_{umm}^u 具有较低的更新频率。

(2) 退化旁路专注捕捉长周期渐变型趋势，如随服役时间推移的性能退化。其参数 θ_{deg}^u 基于退化偏离程度进行定期自适应。

基于此，发动机个体 u 的 PPM 预测输出 $y_{PPM}^u(t)$ 由 $y_{PBM}(t)$ 与双旁路补偿量共同构成，如式(2-3)所示：

$$y_{PPM}^u(t) = y_{PBM}(t) + \Delta y_{umm}(\dot{x}(t), a(t), u(t); \theta_{umm}^u) + \Delta y_{deg}(x(t), a(t), u(t); \theta_{deg}^u) \quad (2-3)$$

2.3 PBM 构建方法

根据数据获取条件、建模对象及应用场景的不同，PBM 通常可采用物理机理建模和数据驱动建模两类方法。本节将分别对这两类 PBM 的构建方法进行详细描述。

2.3.1 基于部件法的物理机理 PBM 构建方法

对发动机工作过程建模的常用方法包括解析法与试验法。其中，解析法以发动机内部物理定律为基础，通过数学方法进行描述；试验法则基于发动机试验数据处理获取其特性，进而建立模型。目前应用最广泛的建模方法为解析法中的部件法建模。

部件法建模是依据发动机各部件的特性,按照从进气道到尾喷管的部件顺序,逐一建立气体流动及热力过程方程,以得到发动机稳态模型。该方法以部件特性为基础,通过各部件容积腔之间的动力、热力物理联系及转子动力学特性将所有部件连接为一个整体系统。在给定初猜值与计算精度后,根据发动机气动热力学特性建立部件进出口参数的数学关系,并采用牛顿-拉普森等迭代算法求解发动机流程中的气动参数。模型中旋转部件的流量、效率等参数通过部件特性图获取。

采用该方法的优势在于无需对公式进行线性化,可避免静态性能失真,且能更深入地反映各部件的稳态特性、动态特性、部件间联系及其对整台发动机性能的影响。相关研究已较为成熟,完整实现流程可参见已有文献^[110],此处不再赘述。

2.3.2 基于金字塔时间卷积网络的数据驱动 PBM 构建方法

数据驱动的 PBM 旨在通过深度挖掘系统在健康无故障状态下的历史运行数据,构建能够精准表征其正常行为模式的数学模型。在实际在线监视应用中,该模型以环境参数、控制变量作为输入,输出期望的性能参考值,并将其与实际测量值进行比对生成性能残差,从而实现对系统性能状态的自适应跟踪与评估。

如本章引论中所述,与基于物理机理的 PBM 构建方法相比,数据驱动方法在使用场景的广泛性方面更为优异。当面临设计点参数、部件特性图等核心物理参数未知或难以获取的受限场景时,构建高可靠性的物理 PBM 十分困难。在此背景下,数据驱动的 PBM 展现出巨大的应用潜力,其建模核心从苛求系统内部物理参数的高完备性,转向了对有限测量参数间深层耦合特征的提取。

然而,由于航空发动机各测量参数在量纲与物理属性上存在差异,多源传感器变量对实际运行状态及环境变化的响应表现出明显的多时间尺度异步性。例如,压力参数通常响应较快;温度参数受热惯性影响存在一定滞后;转速参数则受转子惯性和控制规律影响而变化相对平滑。因此,不同传感器变量对同一运行状态或环境变化的响应并非完全同步,而是在响应速度、滞后时间和变化幅值上存在差异。基于此,构建高精度 PBM 需要同时兼顾多参数间的空间相关性、时序动态演化规律以及响应滞后带来的不确定性。

鉴于近年来提出的时间卷积网络(Temporal Convolutional Network, TCN)在处理时空属性的端到端序列建模问题中展现出优越性,本节以 TCN 为基础架构,针对多参数响应速率不确定的工程痛点对传统网络进行深度改进,提出金字塔时间卷积网络(Pyramidal Temporal Convolutional Network, PTCN)。本节后续将首先对 TCN 的基本原理进行简要阐述,随后详细解析所提出的 PTCN 网络拓扑结构及其训练机制。

2.3.2.1 TCN 基本原理

卷积神经网络 (Convolutional Neural Network, CNN) 在图像处理等领域表现优异,但其主要侧重于空间局部特征提取,在处理时间序列等一维数据时,受感受野范围限制,难以充分捕获长距离时间依赖。而 TCN 通过融合因果卷积与空洞卷积,在保证计算效率的同时扩大时间感受野,从而能够有效建模长程时序依赖,并在相关研究中展现出良好的应用潜力^[112]。其因果卷积和空洞卷积层的计算流程如下:

因果卷积层限制了卷积核在时间维度上的滑动方向,确保每个时间步的输出仅依赖于当前时间步和之前的输入。因此,因果卷积层能够保证在动态运行条件下信息的完整性和真实性,示意图如图 2-1 所示。




图 2-1 因果卷积层

空洞卷积层允许在卷积滤波器内并行计算多个时间步,同时引入间隔来跳过计算过程中的某些元素。因此,当滤波器滑动时,它可以同时计算多个位置的输出,从而增强模型的计算效率,示意图如图 2-2 所示。




图 2-2 空洞卷积层

在 TCN 的结构中，因果卷积确保模型某时刻输出仅依赖该时刻及之前输入，契合时间序列因果性本质；空洞卷积通过引入膨胀因子，在不增加卷积核参数数量的情况下，指数级扩大卷积操作感受野。从而既解决传统 CNN 处理长序列时感受野有限的问题，还避免了因增加网络深度或宽度带来的计算复杂度爆炸式增长。

TCN 的每一层都通过特定计算流程生成输出序列。对于第 l 层，输出序列 $\mathbf{Z} = [\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_T]$ 的计算方式如式(2-4)所示：

$$\mathbf{z}_t^l = f \left(\sum_{k=0}^{K-1} \mathbf{w}_k^l \cdot \mathbf{z}_{t-k \cdot d^l}^{l-1} + \mathbf{b}^l \right) \quad (2-4)$$

其中， $\mathbf{z}_t^l \in \mathbb{R}^{C_l}$ ——代表第 l 层时间步 t 处的输出特征向量；

C_l ——代表第 l 层输出的通道数；

$\mathbf{z}_{t-k \cdot d}^{l-1}$ ——代表来自第 $l-1$ 层、位于对应空洞位置的输入， $l=1$ 时为原始序列；

$\mathbf{w}_k^l$ ——代表第 l 层卷积核的权重参数；

$\mathbf{b}^l$ ——代表第 l 层偏置项；

d^l ——代表第 l 层膨胀因子；

$f(\cdot)$ ——代表激活函数；

k ——代表卷积核位置；

K ——代表卷积核大小。

通过逐层计算，TCN 将输入序列从底层原始特征逐步转换为高层抽象表示，每一层在因果卷积和空洞卷积作用下，整合历史信息，最终实现对长程时间依赖关系的有效建模，图 2-3 展示了双层 TCN 的整体计算流程。




图 2-3 双层 TCN 计算流程示意图

为精确量化 TCN 的感受野，假设每一层膨胀因子呈指数增长，即第 l 层膨胀因子设为 2^l 。对于总共有 L 层的 TCN，其感受野（Receptive Field, RF）由公式(2-

5)表示:

$$RF = 1 + \sum_{l=0}^{L-1} (K-1) \cdot 2^l \quad (2-5)$$

2.3.2.2 PTCN 网络拓扑结构

在计算机视觉领域，金字塔结构已被证实是实现多尺度特征表征与层级信息融合的高效范式，其中以何凯明团队提出的系列架构最具代表性——例如金字塔残差网络与特征金字塔网络^[113]。这类架构的核心设计思想在于通过构建“层级化特征金字塔”，在不同网络深度上同步捕获目标的多尺度信息：浅层网络因感受野较小，擅长提取细粒度的局部特征，如图像中的边缘、纹理；深层网络则凭借更大的感受野，聚焦于抽象化的全局特征，如目标的整体轮廓、语义信息。同时，通过横向连接与自上而下的信息传递机制，金字塔结构能够将深层网络的全局语义信息与浅层网络的局部细节信息有效融合，既避免了单一尺度特征对复杂目标表征的局限性，又提升了模型对不同尺度目标的适应性与鲁棒性。

受此启发，本节针对时间序列数据的多尺度依赖捕获需求，提出一种时空金字塔网络拓扑结构 PTCN。该架构通过构建层级化的网络拓扑，捕捉并提取多源时序数据中不同时间跨度的动态演化特征，进而实现高效的多尺度特征融合。如图 2-4 所示，PTCN 架构的设计围绕多感受野特征提取和层级化特征融合两个核心步骤展开，具体流程如下：

（1）多感受野特征提取

多感受野特征提取阶段，PTCN 上游以一维卷积操作作为基础特征提取单元，构建了 M 个分层金字塔分支。在网络拓扑形态上，各分支自底向上逐层进行时间维度的下采样，同时同步递增特征矩阵的通道数量，从而在扩大模型时间视野的同时提炼出更高维的抽象特征。

其次，对于每一个独立的金字塔分支，其内部核心均由残差模块构成，具体结构如图 2-5 所示。该残差模块采用了双层特征提取架构，并引入残差连接方式，以确保深层网络的梯度传递稳定性。在特征提取的单一算子层内：首先利用 TCN 层提取多维输入特征；随后，特征映射经权重归一化处理以加速模型收敛过程；最后，依次通过 ReLU 激活函数引入非线性表达能力，并结合 Dropout 正则化机制，缓解复杂网络在训练过程中可能出现的过拟合风险。

在残差模块内部，两层卷积算子采用了差异化的膨胀因子，第一层以较小的膨胀因子保证对输入时序数据的无遗漏覆盖，第二层增大膨胀因子以提取大跨度特征。因此金字塔浅层专注于提取短期的局部动态突变；而深层则聚焦于长期的全局

退化趋势，最终实现模型对多尺度时序信息的提取。




图 2-4 PTCN 网络拓扑结构计算流程示意图




图 2-5 残差模块计算流程示意图

(2) 层级化特征融合

层级化特征融合阶段，PTCN 引入了横向卷积与自顶向下的信息流动机制，旨在解决多层次特征的维度对齐与信息互补问题。各层级的横向卷积模块首先对特征进行通道归一化，消除因感受野差异导致的维度不一致，确保高层与低层特征可融合。对于第 l 个金字塔输出 $\mathbf{z}_t^{(l)}$ ，其通道归一化过程如式(2-6)所示：

$$\hat{\mathbf{z}}_t^l = \text{Conv1D}_{1,1}(\mathbf{z}_t^l) = \mathbf{W}_{norm}^l * \mathbf{z}_t^l + \mathbf{b}_{norm}^l \quad (2-6)$$

其中， $\mathbf{W}_{norm}^l \in \mathbb{R}^{1 \times C_l \times C_{out}}$ ——代表通道归一化所用 1×1 卷积的权重；

C_{out} ——代表目标通道数；

$\mathbf{b}_{norm}^l \in \mathbb{R}^{C_{out}}$ ——代表偏置项；

$\hat{\mathbf{z}}_t^l \in \mathbb{R}^{C_{out}}$ ——代表固定通道数的输出。

随后,网络采用自上而下的信息传递机制。对于高层特征,由于其对应的时间序列分辨率较低,即第 $l+1$ 个金字塔的分辨率 $T^{l+1} < T^l$, 需通过线性插值的上采样操作将其序列长度调整至与低层特征匹配。对齐后,高、低层特征通过元素级加法实现融合,将高层特征的全局语义信息注入低层特征的局部细节信息中,实现全局与局部的互补效果,如式(2-7)、(2-8)所示:

$$\tilde{\mathbf{z}}^{l+1} = \text{Upsample}(\hat{\mathbf{z}}^{l+1}, T^l) \quad (2-7)$$

$$\tilde{\mathbf{z}}^l = \tilde{\mathbf{z}}^{l+1} + \hat{\mathbf{z}}^l \quad (2-8)$$

PTCN 选择金字塔最底层的融合结果作为核心特征输出。该层特征整合了全局信息和局部信息,具备最广的时间跨度覆盖能力,能够完整映射序列的长期动态演变过程。在此基础上,网络进一步引入一维卷积进行特征平滑与邻域信息聚合,消除上采样过程中可能产生的特征噪声,如式(2-9)所示:

$$\mathbf{O}^l = \text{Conv1D}_{3,1}(\tilde{\mathbf{z}}^l) \quad (2-9)$$

最后,通过线性映射将特征维度转换为与下游任务匹配的输出维度,从而得到最终的序列预测结果。

2.3.2.3 数据驱动的 PBM 训练机制

以某型号发动机的全机队数据集 $D_{fleet} = \{(X_i, Y_i)\}_i^N$ 为数据基础,本节旨在构建一个能够精准捕捉发动机机队气路演化规律的 PBM。考虑到实际工程中数据管理的局限性,通常难以获取所有发动机绝对全新的理想运行数据。因此构建 PBM 的数据集涵盖了不同服役年限、不同运行工况、不同飞行航线的发动机历史 QAR 数据,数据中包含正常状态及性能退化等多元场景。

PBM 中参数 θ_{PBM} 的训练本质上是一个基于全机队数据的全局寻优过程。该过程通过最小化全局损失函数来完成参数优化,具体的数学表达式如(2-10)所示:

$$\theta_{PBM} = \arg \min_{\theta} \frac{1}{N} \sum_{i=1}^N L(F(X_i; \theta), Y_i) \quad (2-10)$$

其中, $F(\cdot)$ ——代表采用前文所述的 PTCN 架构作为特征提取与预测的计算主体;

$L(\cdot)$ ——代表模型训练选用的损失函数。

最终构建的 PBM 不仅能够稳定输出机队层面的平均气路演变规律,更重要的是形成一套标准化的多尺度特征表征体系,从而作为后续评估个体发动机的基础。

2.4 基于双旁路自适应的模型修正方法框架

在航空发动机性能建模与健康监测中，PBM 主要用于表征机队层面的共性性能规律，但受模型结构、数据条件和个体差异等因素限制，难以完全刻画单台发动机的局部偏差和长期退化特征。为此，本章引入旁路补偿机制，在保留 PBM 通用表征能力的基础上，通过附加分支对模型预测偏差进行针对性修正。

旁路机制的优势在于其模块化和自适应特性。一方面，旁路分支可针对制造装配差异、维修维护状态和局部未建模扰动等个体化因素进行补偿，而无需对 PBM 进行整体重构，从而降低计算成本并避免破坏主模型已有的通用知识；另一方面，旁路分支能够根据发动机服役过程中的状态变化进行动态更新，使模型具备持续跟踪单台发动机性能演化的能力^[115]。

基于上述思路，本节在 2.2 节和 2.3 节所述 PBM 基础上，构建由未建模旁路和退化旁路组成的双旁路自适应修正框架。其中，未建模旁路主要用于补偿初始个体差异和局部模型失配，退化旁路则用于表征长期运行过程中逐渐累积的性能退化。通过主模型与双旁路的协同作用，PPM 能够兼顾机队共性规律、个体差异和长周期退化趋势，为单台发动机性能监视提供更加准确的个性化基准。

本节后续将首先介绍双旁路模型的整体结构与个性化适配策略，随后给出持续增量学习过程中数据池的构建方法，最后详述模型自适应更新流程。

2.4.1 两阶段 PPM 建模框架

未建模因素是指在 PBM 建模过程中，受模型结构、测点数量、参数可观测性及外部不确定性等限制，未能被显式描述的影响因素。对于航空发动机这类复杂系统，制造公差、装配差异、维护状态及运行扰动等均可能导致实测值与 PBM 预测值之间存在偏差。因此本节引入未建模旁路，用于补偿初始个体差异和局部模型失配引起的性能偏移。

性能退化因素是指发动机长期服役过程中由磨损、积垢、腐蚀等因素引起的部件性能衰退。若不考虑退化影响，PBM 输出将随运行时间逐渐偏离目标发动机的实际状态，降低长期性能监视的可靠性。因此本节进一步引入退化旁路，用于跟踪并补偿随服役周期累积的渐变型性能偏移。

基于上述双旁路结构，PPM 以机队级 PBM 为通用底座，通过未建模旁路和退化旁路分别表征目标发动机的初始个体差异与长期退化影响，实现由机队共性性能规律向单台发动机个体运行特征的自适应迁移，从而为长期性能监视提供个性化参考基准。

图 2-6 展示了在实际部署中基于 PPM 的性能监视流程。该流程依托 QAR 数

据实现对全机队所有发动机运行状态的实时在线监视，并通过唯一发动机标识符检索 PPM 库。针对不同的匹配结果，系统采取差异化的调用策略：若目标发动机已有专属 PPM，则直接部署该模型进行监测；反之，对于新投入服役的个体，系统则自动调用机队级 PBM 进行初始化。




图 2-6 基于个性化性能模型的性能监视流程

2.4.2 持续增量学习下的数据池构建

在模型在线自适应过程中，灾难性遗忘是增量学习面临的主要问题^[116]。若模型仅利用最新流式数据进行微调，其参数容易过度适应当前数据分布，从而削弱对历史全包线数据中已学习到的共性规律和全局表征能力。在航空发动机性能监视场景下，这种现象可能导致模型对近期瞬态噪声或局部工况产生过拟合，进而降低其作为健康状态评估基准的可靠性。

本章提出的主-旁协同结构通过冻结 PBM 参数，在一定程度上避免了在线更新对主模型通用知识的破坏。然而，旁路网络的自适应更新仍依赖于增量数据的可靠性和代表性。因此，如何在新数据适应与历史知识保持之间取得平衡，是保证 PPM 持续有效更新的关键。

基于此，本节构建基于工况聚类与动态边界控制的双数据池架构，包括未建模数据池 D_{unm} 和退化数据池 D_{deg} ，分别用于未建模旁路和退化旁路的自适应更新。为保证数据代表性并控制数据规模，本节进一步引入临时缓存集合，在样本正式进入数据池前进行筛选。针对两类旁路的不同功能，缓存集合的数据来源和筛选条件分别设置，具体构建与更新流程如下。

2.4.2.1 双分支差异化数据准入与缓存机制

首先,针对未建模旁路,构建临时缓存集合 U_{unm} 。由于未建模旁路主要用于补偿事件触发后的初始个体差异和局部模型失配,因此其数据来源限定为目标发动机在特定物理事件发生后的前 N_{init} 个飞行架次。此时可近似认为发动机尚未发生明显渐变退化,集合定义如式(2-11)所示:

$$U_{unm} = \left\{ (X_i, Y_i) \mid (X_i, Y_i) \in D_{event}^{1 \sim N_{init}} \right\} \quad (2-11)$$

其中, D_{event} ——代表由特定物理事件(如发动机全新服役、大修返工或核心部件更换等)触发后的飞行架次数据集;

$1 \sim N_{init}$ ——代表物理事件发生后的初始 N_{init} 个有效架次。

其次,针对退化旁路,构建临时缓存集合 U_{deg} 。退化旁路主要用于捕捉发动机长期运行过程中的性能渐变。对于实时输入的架次数据 $D_{stream} = \{(X_i, Y_i)\}$, 监视系统将工况特征 X_i 输入当前PPM, 得到健康状态预测值 $\hat{Y}_i = Y_{PPM}(X_i)$ 。随后, 计算实际测量值 Y_i 与预测值 $\hat{Y}_i$ 之间的残差, 并利用预设的故障判定阈值 τ_{fault} 对样本进行筛选, 其条件如式(2-12)所示:

$$U_{deg} = \left\{ (X_i, Y_i) \mid (X_i, Y_i) \in D_{stream}, \|Y_i - \hat{Y}_i\| \leq \tau_{fault} \right\} \quad (2-12)$$

当残差未超过阈值 τ_{fault} 时, 判定该样本主要反映正常退化或合理的工况波动, 可作为无故障的有效退化数据进入 U_{deg} ; 反之, 则判定该样本可能包含了突发故障或严重异常, 直接予以剔除。

2.4.2.2 基于多维残差表征的数据池下采样初始化方法

在双旁路自适应监视的持续增量学习过程中, 初始数据池的构建不仅影响后续模型更新的稳定性, 也决定了有限存储资源下历史状态信息的保留质量。若直接将全部候选样本纳入数据池, 虽然能够最大程度保留原始信息, 但会带来较大的存储与计算负担; 而若采用简单随机抽样, 则可能破坏样本在气路状态空间中的分布结构, 导致关键运行状态或稀疏区域信息丢失。为此, 本节提出一种基于多维残差表征的数据池下采样初始化方法, 在给定容量约束下从候选样本集中筛选具有代表性的样本子集, 以兼顾数据压缩需求与状态分布保持能力。

设数据池的容量上限为 D_{max} , 假设初始状态下 $U_{unm} = U_{deg} = U_{init}$ 。当 U_{init} 中包含的样本量 $N < D_{max}$ 时, 直接保留全部样本作为初始数据池; 仅当候选样本规模超过容量限制时, 才触发下采样过程。由于双旁路模型的在线更新主要依赖于气路残差特征对发动机状态偏差和个体差异的刻画, 本节以样本对应的多维残差向量作为数据池压缩时的主要表征对象。记 U_{init} 中第 i 个样本的 p 维测量值为

$Y_i = [y_{i1}, y_{i2}, \dots, y_{ip}]$, 为增强代表性样本选择对关键变化维度的敏感性, 首先统计各残差维度在候选样本集上的方差, 并据此构造归一化权重 ω_i , 如式(2-13)所示:

$$\omega_i = \frac{\sigma_j^2}{\sum_{l=1}^p \sigma_l^2}, j=1, 2, \dots, p \quad (2-13)$$

其中, σ_j^2 ——代表第 j 维残差特征的样本方差。

该权重反映不同残差维度对样本区分能力的相对贡献, 变化幅度越大的特征在样本代表性评价中占比越高。当各残差维度整体波动较弱时, 说明当前候选样本集内部差异有限, 此时可直接采用随机抽样完成数据池初始化, 以避免在分布退化条件下引入不稳定的分层结果。

在一般情况下, 为保持样本在多维残差空间中的相对分布结构, 本节对各维残差特征进行分位离散化处理, 将每一维特征按照其在候选样本集中的相对位置映射至若干分位区间。随后, 按照对应维度权重对各维分箱编号进行加权求和, 得到样本的综合分布得分, 如式(2-14)所示:

$$s_i = \sum_{j=1}^p \omega_i b_{ij} \quad (2-14)$$

其中, b_{ij} ——代表样本 Y_i 在第 j 维残差上的分箱编号。

该得分综合反映样本在多维残差空间中的相对位置, 可视为高维状态分布的一种低维统计表征。进一步依据综合分布得分对候选样本进行再分层, 并按照各层样本在候选集中的占比分配保留配额。在样本密集区域保留较多样本, 以维持主体分布结构; 在样本稀疏区域保留少量样本, 以避免边缘状态信息在压缩过程中完全丢失。

为使压缩后的数据池规模满足容量限制, 同时尽量继承原始候选样本集的分布比例, 本节在各综合分层内部执行按配额随机抽样, 并将各层抽取结果合并得到初始化数据池。该过程可统一表示为下式:

$$D_{unm} = D_{deg} = v(U_{init}, D_{max}) \quad (2-15)$$

其中, $v(\bullet)$ ——代表基于残差分布保持的下采样算子。

2.4.2.3 内存受限下的数据池在线动态演化机制

在 PPM 的在线监测阶段, 数据池需随着新合格架次数据 D_{update} 的流入持续更新。为保持数据池规模稳定, 避免内存溢出和计算负担增加, 本节采用合并下采样的动态演化机制。当历史数据池 $D_{history}$ 与 D_{update} 合并后的样本集合容量超限时, 即满足:

$$|D_{history} \cup D_{update}| > D_{max} \quad (2-16)$$

系统将对合并后的数据集重新执行式(2-13)至式(2-15)所述的残差分布保持下采样过程,将数据池规模压缩至 D_{max} 。由此既能控制数据存储规模,又能在持续更新过程中尽可能保留历史状态与新增状态的分布特征。

2.4.3 双旁路自适应流程

在获得具有代表性的双数据池后,本节进一步给出 PPM 中双旁路的自适应更新流程。该流程的核心在于通过差异化触发机制和参数隔离策略,分别对发动机初始个体差异和长期性能退化进行补偿。

未建模旁路采用事件触发逻辑。当监测系统检测到发动机全新服役、大修返厂或关键部件更换等特定事件时,令未建模触发标志 $Flag_{unm}$ 置为 1,并启动未建模旁路更新。此时,以未建模数据池 D_{unm} 作为数据源,冻结 PBM 参数 θ_{PBM} 与退化旁路参数 θ_{deg}^u ,仅更新未建模旁路参数 θ_{unm}^u ,其优化目标如式(2-17)所示:

$$\theta_{unm}^u = \arg \min_{\theta} \frac{1}{n_{unm}^u} \sum_{j=1}^{n_{unm}^u} L(F(X_{unm}^{u,j}; \theta, \theta_{PBM}, \theta_{deg}^u), Y_{unm}^{u,j}) \quad (2-17)$$

退化旁路采用阈值触发逻辑,用于响应发动机长期服役过程中逐渐累积的性能偏移。在每个飞行循环结束后,计算关键气路参数的平均绝对百分比误差(Mean Absolute Percentage Error, MAPE)。若任一关键参数的 MAPE 在连续若干个飞行循环中超过预设更新阈值 τ_{deg} ,且未超过异常检测阈值,则认为当前偏差主要来源于正常性能退化而非突发故障,令退化触发标志 $Flag_{deg}$ 置为 1。此时以退化数据池 D_{deg} 作为数据源,冻结 θ_{PBM} 与 θ_{unm}^u ,仅更新 θ_{deg}^u ,其优化目标如式(2-18)所示:

$$\theta_{deg}^u = \arg \min_{\theta} \frac{1}{n_{deg}^u} \sum_{k=1}^{n_{deg}^u} L(F(X_{deg}^{u,k}; \theta, \theta_{PBM}, \theta_{unm}^u), Y_{deg}^{u,k}) \quad (2-18)$$

由于退化旁路在长周期下需要持续进行增强学习,更易发生灾难性遗忘,本节进一步引入经验回放与参数正则约束。具体而言,将最新无故障架次数据 D_{update} 与历史退化数据池 D_{deg} 联合用于模型更新,计算联合经验回放损失函数的梯度如式(2-19)所示:

$$g_t = \nabla_{\theta_{deg}} [\alpha L(D_{update}; \theta_{deg}^t) + (1-\alpha) L(D_{deg}; \theta_{deg}^t)] \quad (2-19)$$

其中, α ——代表新数据与历史数据间的平衡系数。

进一步,为抑制退化旁路参数过度偏移,引入相对于历史稳定参数的正则约束,

参数更新过程表示为式(2-20)所示:

$$\theta_{deg}^{t+1} = \theta_{deg}^t - \eta_t g_t - \lambda(\theta_{deg}^t - \theta_{deg}^{history}) \quad (2-20)$$

其中, θ_{deg}^t ——代表更新前的退化旁路参数;

θ_{deg}^{t+1} ——代表更新后的退化旁路参数;

η_t ——代表学习率;

$\theta_{deg}^{history}$ ——代表退化旁路上次参数;

λ ——代表正则化惩罚系数。

基于上述方法, 双旁路自适应的整体流程如算法 2-1 所示。

算法 2-1 未建模旁路与退化旁路的自适应流程

参数:

机队数据集: $D_{fleet} = \{(X_i, Y_i)\}_N^i$

未建模数据池: $D_{unm}^u = \{(X_{unm}^{u,j}, Y_{unm}^{u,j})\}_{j=1}^{n_{unm}^u}$; 退化数据池: $D_{deg}^u = \{(X_{deg}^{u,k}, Y_{deg}^{u,k})\}_{k=1}^{n_{deg}^u}$

PBM 参数: θ_{PBM} ; 未建模旁路参数: θ_{unm}^u ; 退化旁路参数: θ_{deg}^u

未建模旁路事件触发标志: $Flag_{unm} \in \{0,1\}$; 退化旁路阈值触发标志: $Flag_{deg} \in \{0,1\}$

故障判定阈值: τ_{fault} ; 故障判定阈值: τ_{deg}

1. 初始化 θ_{PBM} ;
2. 训练 PBM: $\theta_{PBM} = \arg \min_{\theta} 1/|D_{fleet}| \sum_{(x,y) \in D_{fleet}} L(F_{PBM}(x; \theta), y)$;
3. 冻结 θ_{PBM} , 初始化 θ_{unm}^u , θ_{deg}^u ;
4. 监视目标发动机 u , 获取新架次数据 D_{stream} ;
5. 若满足 $Flag_{unm} = 1$, 则构建 D_{unm}^u ;
6. 冻结 θ_{PBM} 和 θ_{deg}^u , 执行 $\theta_{unm}^u = \arg \min_{\theta} 1/|D_{unm}^u| \sum_{(x,y) \in D_{unm}^u} L(F(x; \theta_{PBM}, \theta, \theta_{deg}^u), y)$;
7. 将 D_{stream} 输入当前 PPM, 计算各参数预测偏差 APE 是否超过 τ_{fault} ;
8. 判断是否连续多架次预测偏差 MAPE 超过 τ_{deg} ;
9. 若满足 $Flag_{deg} = 1$, 则构建 D_{deg}^u ;
10. 冻结 θ_{PBM} 和 θ_{unm}^u , 执行 $\theta_{deg}^u = \arg \min_{\theta} 1/|D_{deg}^u| \sum_{(x,y) \in D_{deg}^u} L(F(x; \theta_{PBM}, \theta, \theta_{unm}^u), y)$;
11. 返回更新后 PPM 参数 $\{\theta_{PBM}, \theta_{unm}^u, \theta_{deg}^u\}$;
12. 重复步骤 4—11, 直至目标发动机监视过程结束;
13. 结束流程。

2.5 仿真案例 1：小涵道比军用涡扇发动机

为验证本章所提出的双旁路 PPM 自适应框架在物理机理建模场景下的有效性，本节以某型小涵道比军用涡扇发动机为对象开展仿真研究。基于部件级非线性模型构建 PBM，并引入个体差异与性能退化等不确定因素，评估所提方法对单台发动机气路参数的补偿精度和长期跟踪能力。

2.5.1 仿真数据描述与预处理

本节所用试验模型与仿真数据来源于西安交通大学构建的部件级发动机模型及公开气路故障诊断数据集^[118]。数据覆盖不同飞行环境、控制输入和部件状态下的气路响应，可用于验证 PPM 对个体差异和性能退化的自适应补偿能力。

2.5.1.1 部件级模型及接口描述

本节采用的小涵道比双转子涡扇发动机部件级模型主要由风扇（Fan）、低压压气机（Low Pressure Compressor, LPC）、高压压气机（High Pressure Compressor, HPC）、高压涡轮（High Pressure Turbine, HPT）、低压涡轮（Low Pressure Turbine, LPT）、高压轴（High Pressure Shaft, HPS）、低压轴（Low Pressure Shaft, LPS）、外涵道、燃烧室、加力燃烧室及喷管等部件组成，如图 2-7 所示。




图 2-7 双转子涡扇发动机机构型示意图

表 2-1 给出了该双转子加力涡扇发动机上与气路性能相关的主要传感器测量参数。主要分为温度传感器、压力传感器、转速传感器和角/线位移传感器测量参数四类。

表 2-1 部件级模型各气路传感器测量参数

参数类型	参数名称	单位	符号
环境参数	发动机进气总压	kPa	Pt2
	发动机进气总温	K	Tt2
	环境静压	kPa	Ps0
控制参数	油门杆角度	°	PLA
	控制周期	s	T _{step}
	风扇导叶角度	°	α_1
	压气机导叶角度	°	α_2
	主燃油流量	kg/h	Wf
	加力燃油流量	kg/h	Wfa
	喷口面积	cm ²	A8
状态参数	风扇转速	rpm	N1
	压气机转速	rpm	N2
	风扇内涵出口总压	kPa	Pt25
	风扇内涵出口总温	K	Tt25
	压气机出口总压	kPa	Pt3
	压气机出口总温	K	Tt3
	低压涡轮出口总压	kPa	Pt5
	低压涡轮出口总温	K	Tt5

2.5.1.2 模型不确定性因素

该数据集主要为测试气路故障诊断算法精度开展设计，因此在获取数据集运行数据及故障数据时，考虑了实际运行中存在的多维度不确定性，如图 2-8 所示。具体而言，该数据集通过扰动标称模型纳入了发动机个体差异、海平面环境温度波动、传感器误差及噪声、性能退化及气路故障。

（1）个体差异

通过在标称模型的基础上，对 Fan、HPC、HPT、LPT 等核心部件的初始绝热效率、流通能力及关键截面积施加随机扰动实现。针对目标发动机，其具体扰动与分布参数详见表 2-2。

（2）环境干扰及工况剖面

引入海平面环境温度的季节性与随机性波动，用以考核监视算法在非稳态环境下的自适应能力。将海平面环境温度在-15℃ 至 30℃ 范围内随机选择，以反映

多样化的运行环境。对于飞行工况剖面，从地面起飞后将按顺序飞往飞行包线内随机生成的 16 个包线点，并在遍历所有航点后着陆。图 2-9 展示了一个典型的运行示例。




图 2-8 不确定性注入方法

表 2-2 目标发动机个体差异量化指标

编号	偏差项	数值
1	Fan 绝热效率	+0.02%
2	Fan 流通能力	+0.18%
3	HPC 绝热效率	-0.16%
4	HPC 流通能力	-0.09%
5	燃烧室总压恢复系数	+0.19%
6	HPT 绝热效率	+0.19%
7	HPT 最小流通面积	+0.13%
8	LPT 绝热效率	-0.01%
9	LPT 最小流通面积	+0.13%
10	LPT 出口面积	-0.15%
11	外涵道出口面积	+0.17%
12	喷管最大喉道面积	+0.05%

（3）测量不确定性与噪声

考虑到真实传感器的物理特性，文献[118]中提出在观测矢量 $y(t)$ 中引入了由固有偏差、增量漂移、正弦干扰及高斯白噪声构成的多成分不确定性模型，其中固有偏差采用牛顿蛇形曲线刻画物理偏置，增量漂移模拟长周期老化效应，并结合具

有边缘分布特征的“缺口高斯”分布生成随机干扰。

（4）长周期性能衰退

性能衰退模拟了发动机从服役初期到寿命终止的渐变过程。退化特征通过在飞行任务剖面中，对部件特性参数施加随时间逐渐增加的修正增量来实现，具体退化标准及衰减速率汇总于表 2-3。在连续时间框架下，该过程模拟了积垢、磨损等物理损伤导致的性能连续衰减趋势




图 2-9 工况剖面示意图

表 2-3 目标发动机性能退化量化指标

编号	偏差项	数值
1	Fan 绝热效率	-0.85%
2	Fan 流通能力	-1.16%
3	HPC 绝热效率	-0.83%
4	HPC 流通能力	-1.18%
5	HPT 绝热效率	-1.49%
6	HPT 流通能力	+1.00%
7	LPT 绝热效率	-0.31%
8	LPT 流通能力	+0.15%

（5）气路故障

该数据集中的边缘故障被定义为在 10 秒内动态显现的突发性偏差。此类故障在相同工况下会导致 1% - 3%的推力损失；由于损失超过 3%的故障通常可被飞行

员直接感知，因此改数据集聚焦于该范围内的微小故障。针对不同部件的具体故障注入比例详见表 2-4。

表 2-4 故障边界量化指标

编号	参数	上边界	下边界
1	Fan 绝热效率	-2.24%	-2.33%
2	Fan 流通能力	-0.93%	-1.34%
3	HPC 绝热效率	-2.68%	-2.69%
4	HPC 流通能力	-1.08%	-1.61%
5	HPT 绝热效率	-1.78%	-1.85%
6	HPT 流通能力	+1.07%	+0.74%
7	LPT 绝热效率	-2.66%	-2.77%
8	LPT 流通能力	+1.60%	+1.11%

基于实际的工程场景，该数据集中用于模型训练的各架次正常样本及故障样本不存在时序关系，而用于测试的数据集则考虑时序关系，模型故障注入在 1 秒内完成，落地时被修复。本章重点讨论所提方法在多种不确定性补偿下的长期性能监视效果，因此在测试过程中剔除了所有故障架次。针对气路故障诊断的研究内容将在第 3 章进行阐述。

2.5.1.3 数据归一化

本节采用的发动机模型测量传感器涉及到压力、温度、转速等不同物理性质的参数，为了消除量纲及数值大小对后续算法模型的影响，提高模型收敛稳定性，将训练输入参数采用 Min-Max 归一化处理，如式所示：

$$X^d = \frac{x^d - x_{\min}^d}{x_{\max}^d - x_{\min}^d} \quad (2-21)$$

其中， x^d ——代表输入数据样本的第 d 维特征数据；

$x_{\min}^d$ ——代表样本集中 x^d 的最小值；

$x_{\max}^d$ ——代表样本集中 x^d 的最大值；

X^d ——代表输入数据样本的第 d 维特征归一化后结果。

2.5.2 模型设置与仿真指标

2.5.2.1 模型设置

针对模型的输入-输出架构，双旁路模型在整体设计上遵循输入统一、输出解耦的基本原则。输入统一是指未建模旁路与退化旁路共享相同的工况描述变量，以保证二者建立在一致的发动机工作状态表征基础上，避免因输入条件不一致而引入额外不确定性；输出解耦则是指根据不同旁路的补偿目标分别设置输出变量，以提升模型对特定偏差来源的适配能力。

具体而言，统一输入变量主要用于描述发动机当前热力学工作点，涵盖进气边界参数和控制变量。其中 P_{s0} 、 P_{t2} 和 T_{t2} 用于表征发动机进口气动热力状态， α_1 、 α_2 、 W_f 、 W_{fa} 、 A_8 用于表征导叶调节、燃油供给及喷管面积等控制作用。通过上述变量，模型能够在全包线工况下形成较完整的状态输入，具体变量设置如表 2-5 所示。

在输出端，未建模旁路主要用于补偿 PBM 难以刻画的初始个体差异和局部模型失配，因此其输出设置为所有气路可测参数的自适应补偿值，以增强对整体静态偏差的修正能力。退化旁路则主要用于表征长期服役过程中由部件性能衰退引起的渐变偏移，其输出应优先选择对退化更加敏感且物理含义明确的气路参数。因此，退化旁路输出在未建模旁路输出基础上剔除了 25 截面参数。其原因在于，25 截面参数更靠近进气边界和导叶调节区域，容易受到入口温度、压力畸变及局部气动匹配变化的影响，测量结果中混有较强的边界扰动信息，对核心机长期退化的稳定表征能力相对较弱^[120]。已有研究也表明，25 截面相关参数对核心机退化的敏感性低于其他关键气路测点^[121]。因此，本节未将 T_{t25} 和 P_{t25} 纳入退化旁路输出，以提高退化补偿的针对性和物理一致性。

表 2-5 旁路模型的输入输出设置

双旁路共用输入		未建模旁路输出		退化旁路输出	
参数	接口	参数	接口	参数	接口
P_{s0}	输入	N1 补偿值	输出	N1 补偿值	输出
P_{t2}	输入	N2 补偿值	输出	N2 补偿值	输出
T_{t2}	输入	P_{t25} 补偿值	输出	P_{t3} 补偿值	输出
α_1	输入	T_{t25} 补偿值	输出	T_{t3} 补偿值	输出
α_2	输入	P_{t3} 补偿值	输出	P_{t5} 补偿值	输出
W_f	输入	T_{t3} 补偿值	输出	T_{t5} 补偿值	输出
W_{fa}	输入	P_{t5} 补偿值	输出		
A_8	输入	T_{t5} 补偿值	输出		

两种旁路模型均采用多层感知机（Multi-layer Perceptron, MLP）构建，具体超参数配置见表 2-6，模型训练过程中使用 Adam 优化器和均方误差（Mean Squared Error, MSE）作为损失函数。验证在配置有 NVIDIA GeForce GTX 4060 Laptop GPU 的计算环境中进行，软件环境为 Python 3.9 和 PyTorch 2.0，后续的所有研究均基于此开发环境进行实现与验证。

表 2-6 旁路模型超参数设置

超参数	未建模旁路	退化旁路
各层神经元	[8,32,32,8]	[8,32,32,6]
激活函数	ReLU	ReLU
优化器	Adam	Adam
学习率	0.001	0.001
Epoch	100	100
损失函数	MSE	MSE

2.5.2.2 仿真指标

为评价双旁路自适应监视方法在全寿命周期内的建模精度，本节聚焦于以下两个维度：

（1）瞬时偏差：利用绝对百分比误差（Absolute Percentage Error, APE）和最大绝对百分比误差（Maximum Absolute Percentage Error, MaxAPE）衡量模型对于复杂瞬态的建模效果。其中，APE 用于表征单个采样点上的建模偏差；MaxAPE 用于衡量全剖面任务中的最大建模偏差，能够反映模型在工况剧烈过渡或个体差异修正初期的鲁棒性边界，如式(2-22)和(2-23)所示：

$$APE = \left| \frac{\hat{y}_i - y_i}{y_i} \right| \times 100\% \quad (2-22)$$

$$MaxAPE = \max_{i=1, \dots, N} \left| \frac{\hat{y}_i - y_i}{y_i} \right| \times 100\% \quad (2-23)$$

（2）全局偏差：利用平均绝对百分比误差（Mean Absolute Percentage Error, MAPE）衡量模型在单次飞行循环下的整体预测精度。该指标一方面用于评估旁路模型对于全寿命周期退化轨迹的全局建模能力，另一方面作为后续退化旁路更新的核心决策指标如式(2-24)所示：

$$MAPE = \frac{1}{N} \sum_{i=1}^N \left| \frac{\hat{y}_i - y_i}{y_i} \right| \times 100\% \quad (2-24)$$

其中, N ——代表样本数量;

y_i ——代表第 i 个采样点的传感器观测值;

$\hat{y}_i$ ——代表 PPM 的输出值。

如 2.4.3 节所示, 未建模旁路的更新逻辑遵循事件触发, 其更新主要基于维护、水洗等显著影响发动机性能的离散操作。而退化旁路由于采用阈值触发, 为避免瞬态扰动或随机噪声导致误更新, 本节仅当 MAPE 连续 3 次超过更新阈值且未达到故障阈值时, 才判定退化旁路需要更新。本节试验中, 设定更新阈值为 1.5%, 故障阈值为 3%。其只要观测量中存在任意参数达到阈值时, 即触发自适应更新过程。

2.5.3 仿真验证结果及分析


本节针对所提方法开展仿真验证, 验证过程围绕未建模旁路补偿效果、退化旁路更新效果以及自适应数据池连续更新演化展开, 重点比较 PBM 与 PPM 在不同气路参数上的预测误差差异, 并结合 MAPE、MaxAPE 及误差演化趋势评估所提方法对初始个体差异和长期性能退化的补偿能力。通过上述分析, 验证双旁路结构在提升单台发动机性能跟踪精度和长期监视稳定性方面的有效性。

2.5.3.1 物理机理 PPM 未建模旁路性能评估


本节重点验证未建模旁路对目标发动机初始个体差异的校正能力。实验选取目标发动机前 5 个飞行架次的无故障运行数据作为离线适配样本, 并依据 2.4.2 节所提出的数据池构建方法完成未建模旁路模型的初始化。具体而言, 将离线数据池的最大容量设定为 1000。当候选样本数量超过容量约束时, 采用本章提出的基于残差分布保持的数据池下采样初始化方法, 对不同工况点下的差异特征进行筛选与压缩, 为未建模旁路学习目标发动机的初始个体偏差提供数据基础。

为评价未建模旁路的校正效果, 本节以目标发动机第 6 个运行循环作为测试对象, 对比校正前、后 PPM 在各气路参数上的预测性能, 如图 2-10 所示。


各参数校正前后的误差结果如表 2-7 所示。由图中对比及表中统计结果可知, 引入未建模旁路后, PPM 在各气路参数上的 MAPE 均明显低于 PBM, 表明未建模旁路能够有效补偿目标发动机相对于名义基线模型的初始个体差异。具体来看, N1、N2、Tt25、Pt25、Tt3、Pt3、Tt5 和 Pt5 的 MAPE 分别由 0.26%、0.61%、1.31%、1.00%、0.11%、0.65%、0.72% 和 0.20% 降低至 0.04%、0.04%、0.21%、0.13%、0.03%、0.16%、0.07% 和 0.10%。




(a1) 第 6 个运行架次 PBM、PPM 的 N1 预测值与真实值对比




(a2) 第 6 个运行架次 PBM、PPM 与真实值间 N1 的预测偏差




(b1) 第 6 个运行架次 PBM、PPM 的 N2 预测值与真实值对比




(b2) 第 6 个运行架次 PBM、PPM 与真实值间 N2 的预测偏差




(c1) 第 6 个运行架次 PBM、PPM 的 Tt25 预测值与真实值对比




(c2) 第 6 个运行架次 PBM、PPM 与真实值间 Tt25 的预测偏差




(d1) 第 6 个运行架次 PBM、PPM 的 Pt25 预测值与真实值对比




(d2) 第 6 个运行架次 PBM、PPM 与真实值间 Pt25 的预测偏差




(e1) 第 6 个运行架次 PBM、PPM 的 Tt3 预测值与真实值对比



(e2) 第 6 个运行架次 PBM、PPM 与真实值间 Tt3 的预测偏差



(f1) 第 6 个运行架次 PBM、PPM 的 Pt3 预测值与真实值对比



(f2) 第 6 个运行架次 PBM、PPM 与真实值间 Pt3 的预测偏差




图 2-10 未建模旁路修正前后对比

表 2-7 未建模旁路校正前后预测误差对比 (%)

参数	PBM MAPE	PPM MAPE	PBM MaxAPE	PPM MaxAPE
N1	0.26	0.04	1.81	0.74
N2	0.61	0.04	1.25	0.60
Tt25	1.31	0.21	20.69	18.31
Pt25	0.99	0.13	2.01	2.15
Tt3	0.11	0.03	0.75	0.48
Pt3	0.65	0.16	3.35	2.61
Tt5	0.72	0.07	1.76	1.29
Pt5	0.20	0.10	1.39	1.31

从最大瞬时误差来看，PPM 在多数参数上同样取得了改善。N1、N2、Tt3、Pt3、Tt5 和 Pt5 的 MaxAPE 均低于 PBM，说明未建模旁路不仅能够降低全局平均

偏差,也能够一定程度上抑制局部工况下的瞬时预测误差。然而, Tt25 的 MaxAPE 仍保持较高误差, Pt25 的 MaxAPE 也出现小幅增加。进一步分析最大误差点附近的工况变化可以发现, 该时刻 α_1 和 α_2 均处于快速调节过程, 如图 2-11 所示。




图 2-11 导叶角 α_1 和 α_2 的调节过程

导叶角的快速变化会改变冷端部件的流量分配和局部气动匹配状态, 从而引入明显的瞬态非线性扰动。由于 25 截面位于风扇后、压气机前, 更接近导叶调节区域和进气边界, 其温度、压力响应对 α_1 和 α_2 的变化更为敏感。尤其是 Tt25 直接反映该截面的总温状态, 在导叶快速、大幅动作下更容易出现短时响应滞后或局部尖峰误差, 因此其 MaxAPE 最为突出。

而由于 Tt3 和 Tt5 位于更下游位置, 受系统惯性、压气、燃烧过程以及流动混合影响, 局部导叶扰动在传播过程中有所平滑, 因此 MaxAPE 并未出现同等程度放大。尽管如此, Tt25 和 Pt25 的 MAPE 均显著降低, 说明 PPM 对 25 截面参数的校正仍然有效, 只是在导叶快速调节引发的强瞬态工况下仍存在局部补偿不足。


2.5.3.2 物理机理 PPM 退化旁路性能评估

为验证退化旁路对发动机长周期性能衰退的跟踪能力, 本节沿目标发动机全寿命周期逐架次统计各气路参数的 MAPE 变化。不同于未建模旁路主要补偿初始个体差异, 退化旁路重点用于刻画随服役周期累积的性能偏移。因此, 本节主要分析预测误差是否随运行循环增加呈现退化相关的累积趋势, 以及模型更新后是否能够有效降低由退化引起的系统性偏差。


图 2-12 展示了 PBM 和 PPM 在各气路参数上的 MAPE 随在翼时长变化的演化轨迹。可以看出, 随着发动机服役时间增加, 部件性能衰退逐渐累积, 目标发动机气路响应相对于当前模型产生新的偏移, 导致部分关键参数的预测误差逐步增大。当误差持续超过设定更新阈值时, 说明当前退化旁路已难以充分表征新的退化状

态，需要引入最新退化样本对模型进行更新。


根据 2.5.2 节设定的更新判据，退化旁路分别在第 39、164 和 289 个运行循环触发更新。具体而言，当同一气路参数的 MAPE 连续三个运行循环高于更新阈值时，认为该偏差具有持续性，而非单次瞬态扰动或随机噪声引起，此时启动退化旁路自适应更新。由图 2-12 可见，每次更新后，各参数预测误差均得到不同程度抑制，说明退化旁路能够通过增量学习吸收新的退化信息，并提升 PPM 对当前发动机性能状态的适配能力。




(a) PBM、PPM 对 N1 预测值对比




(b) PBM、PPM 对 N2 预测值对比




(c) PBM、PPM 对 Tt3 预测值对比



(d) PBM、PPM 对 Pt3 预测值对比



(e) PBM、PPM 对 Pt5 预测值对比



(f) PBM、PPM 对 Pt5 预测值对比

图 2-12 PBM 和 PPM 对各气路参数预测偏差随在翼时长的演化过程

分析更新触发原因可知,三次退化旁路更新均主要由 Pt3 预测偏差持续超阈值引起,说明在当前仿真条件下, Pt3 对性能衰退导致的气路状态变化较为敏感,能够较早反映 PPM 与目标发动机之间的退化失配。同时,这也表明退化旁路更新机制能够根据各参数误差演化情况,自动识别主要失配来源。需要说明的是,本节为验证方法有效性采用统一更新阈值;实际工程应用中,可根据不同气路参数的监视精度要求设置差异化阈值,以提高更新判据的适应性。

为进一步验证退化旁路对当前退化阶段的校正能力,本节选取第 289 个运行循环作为典型对象,对比更新前后模型在同一架次数据上的预测性能,如图 2-13 所示。

图中,更新前 PPM 表示尚未吸收当前阶段退化样本的模型,更新后 PPM 表示经退化旁路增量自适应后的模型。二者均采用相同的第 290 个飞行架次数据进行测试,且 PBM 与未建模旁路参数保持不变。因此,更新前后预测误差的变化主要反映退化旁路对当前性能衰退状态的补偿效果。各气路参数在更新前后的 MAPE 和 MaxAPE 如表 2-8 所示。

表 2-8 退化旁路校正前后预测误差对比 (%)

参数	PBM MAPE	PPM MAPE	PBM MaxAPE	PPM MaxAPE
N1	0.75	0.16	2.99	2.60
N2	0.69	0.26	1.86	1.56
Tt3	0.37	0.12	0.98	0.64
Pt3	2.55	0.93	6.65	5.78
Tt6	1.51	0.59	3.14	2.27
Pt6	1.03	0.39	4.85	4.33

由统计结果可知,更新前 PPM 相对于实测值仍存在一定系统性偏差;更新后 PPM 能够更准确地跟踪真实气路响应,残差幅值整体减小,误差分布更加集中。说明退化旁路更新不仅降低了预测误差,也改善了模型对当前退化阶段的动态适配能力。

2.5.3.3 自适应数据池连续更新演化分析

为验证数据池更新机制的代表性保持能力与环境包线覆盖能力,本节对连续更新条件下的数据池分布演化进行分析。实验以前 5 个飞行架次数据构建初始样本池,随后依次引入第 6、第 7 和第 8 个飞行架次作为新增数据源。每次更新时,

将新增数据与上一阶段样本池合并，并依据 2.4.2 节提出的代表性采样机制，将数据池规模约束为 1000，以观察固定容量条件下历史样本与新增样本的动态保留情况。




图 2-13 更新前后 PPM 对各气路参数预测偏差对比

考虑到发动机在翼运行过程中环境边界条件会直接影响气路响应，本节选取 Tt2 和 Pt2 作为环境运行包线的代表性维度进行可视化分析，结果如图 2-14 所示。图中分别给出了初始样本池及连续三次更新后样本池在 Tt2-Pt2 平面内的分布，用于表征数据池对环境运行空间的覆盖变化。




图 2-14 样本池连续更新演化过程

从样本来源构成来看,初始样本池全部由前 5 个架次样本构成,规模为 1000。第一次更新后,数据池保留 500 个初始样本,并引入 500 个第 6 架次样本;第二次更新后,数据池包含 252 个初始样本、246 个第 6 架次样本和 502 个第 7 架次样本;第三次更新后,数据池进一步调整为 127 个初始样本、126 个第 6 架次样本、252 个第 7 架次样本和 495 个第 8 架次样本。该结果表明,数据池并未被最新架次样本完全替代,而是在容量约束下实现了历史样本与新增样本的动态平衡。

由图 2-14 可知,连续更新后的样本池仍覆盖初始样本的主要 $Tt2$ - $Pt2$ 分布区域,同时随着新增架次引入,样本边界逐步向新的运行区域扩展。这说明所设计的数据池更新机制既保留了发动机早期状态下的典型环境特征,又吸收了后续运行中的新工况信息,有助于缓解持续增量学习中的历史遗忘问题。

需要指出的是,由于数据池中持续保留部分退化前期样本,更新后的样本分布并非完全聚焦于当前最新退化状态。因此,在退化程度快速变化或后期退化特征显著增强时,历史样本的保留可能在一定程度上削弱模型对最新退化阶段的拟合精度。但从长期在线监视角度看,该机制能够权衡模型的稳定性与适应性,保证数据的长期可靠。

2.6 仿真案例 2：大涵道比民用涡扇发动机

为进一步验证双旁路自适应监视方法在真实运行场景下的适用性，本节选取某型大涵道比民用涡扇发动机的民航在翼运行数据开展第二组验证。与前述基于部件级仿真模型的案例不同，本案例数据来源于真实航线运行过程，且由于设计数据和部件特性未知，难以直接构建完整的物理机理 PBM。因此，本节采用 2.3.2 节所述数据驱动方法构建 PBM，并在此基础上引入未建模旁路与退化旁路，以验证所提方法在真实民航数据条件下的泛化能力与鲁棒性。

2.6.1 民航数据描述与预处理

2.6.1.1 民航数据描述

本节数据来源于某航空公司运营的某型大涵道比民用涡扇发动机 QAR 数据库。该数据记录了发动机在真实航线运行过程中的飞行工况、控制输入及气路状态响应，能够反映复杂运行环境下发动机性能状态的实际变化特征。

受真实型号发动机传感器配置限制，QAR 数据中可用于性能监视的测点数量相对有限，难以像仿真模型一样获取完整截面参数和部件级健康参数。因此，本节选取与气路性能监视密切相关的典型变量作为建模对象。其中，运行工况与控制输入参数包括飞行马赫数 Ma 、飞行高度 Alt 、燃油流量 W_f 等；气路状态参数包括 $N1$ 、 $N2$ 、 $Tt25$ 、 $Tt3$ 、高压压气机出口静压 $Ps3$ 和排气温度 EGT 。

在模型训练与评估阶段，本节根据不同模块的功能需求，将 QAR 数据划分为 PBM 训练数据、未建模旁路适配数据和退化旁路验证数据三部分，如表 2-9 所示。

表 2-9 用于训练与测试的 QAR 相关信息

发动机编号	架次数	采样点	飞行时长	数据用途
1	1	8781	2.44h	训练 PBM
2	1	6879	1.91h	训练 PBM
...	...	...	...	...
100	1	10660	2.96h	训练 PBM
<i>A</i>	1-5	5611-8499	1.56-2.36h	验证未建模旁路
<i>B</i>	1-5	7051-10263	1.96-2.85h	验证未建模旁路
...	...	...	...	...
<i>E</i>	1-5	7384-11124	2.05-3.09h	验证未建模旁路
<i>F</i>	1-212	2685-13964	0.75-3.88h	验证退化旁路

第一部分用于数据驱动 PBM 训练, 选取 100 台同型号发动机的 QAR 数据, 每台发动机对应一个真实飞行循环。需要说明的是, 在航空公司实际运营场景中, 难以获得大量严格意义上的全新出厂发动机数据。航司机队中的发动机通常来源和状态较为复杂, 可能包括新交付发动机、租赁发动机、返修发动机及不同服役阶段的在翼发动机, 其初始性能状态并不完全一致。因此, 本节 PBM 训练数据主要选取该型号发动机正常运营状态下的群体运行数据。

第二部分用于未建模旁路训练与测试, 选取另外 5 台发动机的 QAR 数据, 每台发动机提供 5 个连续飞行循环。其中, 发动机 A、B、C 为新机, 发动机 D、E 为大修后发动机。该设置同时包含新机初始个体差异和大修后发动机可能存在的性能恢复差异、装配偏差, 可用于验证未建模旁路对目标发动机初始偏差和局部模型失配的校正能力。。

第三部分用于退化旁路训练与测试, 选取一台连续运行 60 天的发动机 F 的 QAR 数据, 共包含 212 个真实飞行循环。该数据具有连续时间跨度, 能够反映同一台发动机在服役过程中的状态演化特征, 适合用于验证退化旁路对长期性能变化的跟踪能力及自适应更新机制的有效性。

2.6.1.2 数据预处理

由于 QAR 数据来源于真实民航运行过程, 数据采集与传输过程中不可避免地受到通信异常、记录丢包等因素影响, 原始数据中可能存在异常零值、局部缺失及样本序列过长等问题。若直接将原始 QAR 序列输入模型, 不仅会影响数据驱动 PBM 的训练稳定性, 也可能使模型学习到与发动机真实状态无关的异常扰动。因此, 在模型训练前需对 QAR 数据进行预处理, 主要包括异常零值修复和滑动窗口时序切片。

(1) 异常零值插值修复

在 QAR 数据中, 部分测点可能由于短时通信异常或记录错误而出现异常零值。此类零值通常不会触发机载监测系统的故障告警, 也不代表发动机真实物理状态发生突变, 而是数据采集链路中的局部异常。

为保证时序数据的连续性与物理合理性, 本节采用邻域插值方法对异常零值进行修复。具体而言, 对于任一观测变量序列, 当某一时刻出现异常零值时, 首先在该时刻前后邻域内搜索最近的非零有效观测值, 并基于相邻有效点进行线性插值, 以替代该异常零值。设某多变量在时刻 t 的观测值为 $x_t \in \mathbb{R}^d$, 若 $x_t = 0$ 且被判定为异常记录, 则寻找其前后最近的有效观测点 x_{t_a} 和 x_{t_b} , 其中 $t_a < t < t_b$, 且 $x_{t_a} \neq 0$ 、 $x_{t_b} \neq 0$ 。插值修复后的观测值 $\tilde{x}_t$ 可表示式(2-25)所示:

$$\tilde{x}_t = x_{t_a} + \frac{t - t_a}{t_b - t_a} (x_{t_b} - x_{t_a}) \quad (2-25)$$

对于连续零值较短的片段，同样采用其前后最近有效观测点进行线性插值修复；对于连续异常长度过长、难以保证物理可信度的片段，则不参与后续建模。此外，本节仅选取马赫数 $Ma > 0$ 的飞行段数据作为建模与分析对象，排除了地面静止或滑行阶段数据对性能建模的干扰。

(2) 滑动窗口时序切片方法

单次飞行循环中的 QAR 数据通常包含大量连续采样点，且不同飞行循环之间的序列长度并不完全一致。由于本节后续采用的 PTCN 需要在固定长度的局部时间窗口内提取多尺度时序特征，若直接将完整飞行序列输入模型，不仅会增加计算负担，也不利于构造统一尺寸的批量训练样本。因此，本节采用滑动窗口方法对原始 QAR 时间序列进行切片处理，将不同长度的飞行序列转换为固定长度的多变量时序样本，如图 2-15 所示。




图 2-15 序列样本构建示意图

设经过异常零值修复和标准化处理后的原始多变量时间序列为 $\mathbf{X} = \{x_1, x_2, \dots, x_T\}$ ， T 为该飞行循环的序列长度。采用长度为 L 的滑动窗口，并以步长 S 对序列进行切分，可得到第 i 个时序样本如式(2-26)所示：

$$\mathbf{X}^{(i)} = \{x_i, x_{i+1}, \dots, x_{i+L-1}\}, i = 1, S+1, 2S+1, \dots, S \cdot \left\lfloor \frac{T-L}{S} \right\rfloor + 1 \quad (2-26)$$

L 控制单个样本包含的历史时间长度， S 控制相邻样本间的滑动间隔。通过调整 L 和 S ，可以在样本数量、样本重叠率和时序特征覆盖范围之间进行权衡。

2.6.2 数据驱动 PPM 模型设置

相较于物理机理 PBM，数据驱动 PBM 的输入输出设置更依赖于具体建模目标。在 QAR 数据场景下，N1 和 N2 既可作为发动机在给定工况和控制输入下的响应结果，也可作为表征当前工作点的重要状态变量。若将 N1 和 N2 作为输出，模型需要仅依靠外部工况、控制输入和历史时序信息推断转子动态响应，对数据时序建模能力要求较高。

考虑到 QAR 数据记录的是发动机与控制系统共同作用后的实际运行结果，N1 和 N2 已综合反映燃油供给、几何调节、转子惯性及控制器调节后的工作状态。因此，将其作为输入能够更直接地约束发动机当前工作点，降低输入—输出映射的不确定性。在此基础上，以 Tt25、Tt3、Ps3、EGT 等温度、压力及排气参数作为输出，更有利于刻画气路热力状态相对于基准模型的偏离程度，并提高关键热力参数的预测精度。因此，本节在数据驱动 PBM 构建中将 N1 和 N2 纳入输入变量，最终输入输出变量设置如表 2-10 所示。

表 2-10 数据驱动 PBM 模型的输入输出设置

变量名	符号	接口
马赫数	Ma	输入
高度	Alt	输入
燃油流量	Wf	输入
压气机导叶角度	a_2	输入
可调放气活门开度	VBV	输入
低压转子转速	N1	输入
高压转子转速	N2	输入
高压压气机进口温度	Tt25	输出
高压压气机出口温度	Tt3	输出
高压压气机出口静压	Ps3	输出
排气温度	EGT	输出

本节所采用模型的主要超参数如表 2-11 所示，包括数据驱动 PBM 中的 PTCN 结构及两个旁路微调结构。PTCN 由 3 个残差 TCN 模块构成，各层通道数依次为 32、64 和 128，卷积核大小为 3，膨胀系数设置为[1,2,4]，下采样步长为 2，以实现多尺度时序特征提取。层级化特征融合阶段将不同金字塔层级的特征统一映射至 256 维，并通过线性插值完成上采样和特征对齐，最终输出 4 维气路性能参数。

未建模旁路和退化旁路均采用 2 层轻量化全连接结构。其中，退化旁路输出不包含 T25 补偿值，原因与 2.5.2.1 节所述一致，仅对退化敏感参数进行补偿。在时间序列样本构建过程中，滑动窗口长度 L 设置为 256，滑动步长 S 设置为 32。

表 2-11 PPM 中各子模型的输入输出设置

超参数	PTCN 结构	未建模旁路	退化旁路
各层神经元	[7,32,64,128]	[7,32,32,4]	[7,32,32,3]
残差模块数	3	-	-
卷积核大小	3	-	-
TCN 膨胀系数	[1,2,4]	-	-
下采样步长	2	-	-
激活函数	Relu	Relu	Relu
金字塔融合维度	256	-	-
上采样方法	线性插值	-	-
学习率	0.005	0.001	0.001
Epochs	300	100	100
优化器	Adam	Adam	Adam
Batch 大小	32	32	32
损失函数	MSE	MSE	MSE

2.6.3 仿真验证结果及分析

2.6.3.1 数据驱动 PPM 未建模旁路性能评估

为验证数据驱动 PBM 的基准建模能力及未建模旁路对目标发动机初始个体差异的适配效果，本节首先采用编号 1 至 100 的同型号发动机历史 QAR 数据训练机队级 PBM，为后续个性化建模提供统一基准。


在 PBM 训练完成后，另选取 5 台未参与训练的同型号发动机作为测试对象。对于每台测试发动机，仅使用 1 个飞行架次数据构建未建模旁路，用于形成目标发动机的初始个性化补偿模型；随后采用其余连续 4 个飞行架次数据作为验证集，对比 PBM 与 PPM 的预测性能。

实验结果见表 2-12，图 2-16 至图 2-20 展示了其中一个飞行架次的预测结果。其中，PBM 在测试发动机上的平均预测误差整体处于较低水平。由结果可知，PBM 在测试发动机上的平均预测误差整体较低，Tt25、Tt3、Ps3 和 EGT 的 MAPE 分别为 0.40%、0.35%、1.10% 和 0.56%。其中，Tt25、Tt3 和 EGT 的 MAPE 均低于 0.60%，


Ps3 虽相对较高,但仍保持在约 1.10%的水平,说明基于 PTCN 的数据驱动 PBM 能够较好地学习机队级 QAR 数据中的共性运行规律,并对未参与训练的同型号发动机形成有效基准预测。

表 2-12 数据驱动 PBM 与未建模旁路补偿后初始 PPM 预测误差统计结果 (%)

参数	PBM MAPE	PPM MAPE	PBM MaxAPE	PPM MaxAPE
Tt25	0.40	0.28	4.80	3.95
Tt3	0.35	0.25	6.61	7.30
Ps3	1.10	0.90	21.86	15.48
EGT	0.56	0.28	7.96	5.37




(a) 测试架次的 Alt




(b) 测试架次的 Ma

图 2-16 测试架次的飞行剖面




(a) 测试架次的 Tt25 预测对比



(b) 测试架次的 Tt25 预测偏差


图 2-17 数据驱动 PBM 与未建模旁路补偿后的 Tt25 预测结果



(a) 测试架次的 Tt3 预测对比

(b) 测试架次的 Tt3 预测偏差


图 2-18 数据驱动 PBM 与未建模旁路补偿后的 Tt3 预测结果



(a) 测试架次的 Ps3 预测对比

(b) 测试架次的 Ps3 预测偏差

图 2-19 数据驱动 PBM 与未建模旁路补偿后的 Ps3 预测结果



(a) 测试架次的 EGT 预测对比

(b) 测试架次的 EGT 预测偏差

图 2-20 数据驱动 PBM 与未建模旁路补偿后的 EGT 预测结果

引入未建模旁路后，PPM 在所有气路参数上的 MAPE 均进一步降低。其中，Tt25 由 0.40% 降至 0.28%，Tt3 由 0.35% 降至 0.25%，Ps3 由 1.10% 降至 0.90%，EGT 由 0.56% 降至 0.28%。从 MaxAPE 来看，PPM 在 Tt25、Ps3 和 EGT 上的最大瞬时

误差均低于 PBM，表明未建模旁路不仅提高了整体预测精度，也在一定程度上抑制了局部误差峰值。需要注意的是，Tt3 的 MaxAPE 由 6.61% 增加至 7.30%，但其 MAPE 仍明显降低，说明 PPM 对 Tt3 的整体适配效果有所改善，仅在少数瞬态工况或局部异常样本处存在误差放大。由于 MaxAPE 对单点极值较为敏感，因此应结合 MAPE 综合评价模型的整体预测性能。

2.6.3.2 数据驱动 PPM 退化旁路性能评估

为评估退化旁路在真实运行数据条件下的性能跟踪能力，本节选取一台未参与 PBM 训练的大修后发动机作为测试对象。大修后发动机在装配状态、性能恢复水平及后续运行过程中可能存在区别于机队平均状态的个体化偏移，因此更适合用于验证退化旁路对长期性能变化的自适应跟踪能力。

本实验利用该发动机连续运行期间的 QAR 数据模拟实际在翼服役过程，并沿运行周期统计模型预测误差的变化。分析内容主要包括两个方面：一是统计关键气路参数 MAPE 随运行周期的演化过程，用于识别误差阶段性变化及退化旁路更新触发时刻；二是选取典型更新周期，对比更新前后 PPM 在同一运行周期上的预测性能，以验证退化旁路对当前状态偏移的校正效果。

如图 2-21 所示，在 212 个运行周期内，模型误差呈现明显的阶段性变化。随着运行周期推进，部分关键参数预测误差逐渐增大，表明当前 PPM 对目标发动机状态变化的适配能力下降。当误差持续满足更新条件时，系统触发退化旁路更新。实验中共发生两次更新，分别位于第 80 个和第 192 个运行周期，两次分别由 Tt3 和 Ps3 误差持续超阈值触发。

两次更新前，关键气路参数 MAPE 均明显上升，说明原有退化旁路已难以充分表征当前阶段的性能偏移；更新后，模型误差得到有效抑制，预测精度明显恢复。该结果表明，退化旁路能够利用新增运行数据吸收当前退化阶段的状态信息，并通过增量更新提高 PPM 对目标发动机的持续适配能力。




图 2-21 各架次下各参数预测结果

进一步地, 图 2-22 至图 2-24 展示了利用更新前后的 PPM 对第 81 个架次的预测结果。更新后, Tt3、Ps3 和 EGT 的 MAPE 均显著降低, 其中 Tt3 由 1.59% 降至 0.44%, Ps3 由 2.28% 降至 0.96%, EGT 由 1.28% 降至 0.33%。




图 2-22 基于退化旁路微调的 Tt3 预测结果




图 2-23 基于退化旁路微调的 Ps3 预测结果




图 2-24 基于退化旁路微调的 EGT 预测结果

2.6.3.3 数据驱动 PBM 建模方法对比

为进一步验证本章所提的 PTCN 在数据驱动 PBM 构建中的有效性,本节选取 CNN-LSTM-Attention^[122]、并行多尺度 TCN^[123]、Transformer^[124]和 Informer^[125]等典型时序建模方法进行对比。上述模型均具备时序特征提取能力,能够从不同角度刻画 QAR 数据中的飞行剖面变化、控制输入响应及气路参数动态关联,可作为数据驱动 PBM 的对照方法。

为保证对比公平性,各模型采用相同的数据划分、预处理流程、输入输出变量、训练策略和评价指标。模型输入均由 Ma、Alt、Wf、N1、N2、 a_2 、VBV 构成的多变量时序样本,输出为 Tt25、Tt3、Ps3 和 EGT 等气路热力参数。各模型均基于机队级 QAR 数据训练,并在相同测试集上计算 MAPE 和 MaxAPE。

表 2-13 给出了不同方法在各气路参数上的 MAPE 对比结果。可以看出,PTCN 在四个预测参数上均取得最低平均误差,说明其能够更有效地提取 QAR 数据中的时序动态特征,提高 PBM 对气路参数的整体预测精度。由表 2-14 的 MaxAPE 结果可知,PTCN 在 Tt25、Tt3 和 EGT 上也取得最低最大瞬时误差,表明其在局部工况点下具有较好的预测稳定性。

表 2-13 采用不同方法预测的 MAPE (%)

方法	Tt25	Tt3	Ps3	EGT
CNN-LSTM-Attention	0.98	1.04	1.44	1.15
多尺度并联 TCN	0.90	1.10	1.61	1.15
Transformer	0.92	0.97	1.42	1.08
Informer	0.78	0.53	1.39	0.94
PTCN	0.40	0.35	1.10	0.56

表 2-14 采用不同方法预测的 MaxAPE (%)

方法	Tt25	Tt3	Ps3	EGT
CNN-LSTM-Attention	12.12	12.41	20.23	10.23
多尺度并联 TCN	8.12	10.12	24.34	8.12
Transformer	6.12	8.32	31.32	15.67
Informer	9.12	13.01	17.20	9.23
PTCN	4.80	6.61	21.86	7.96

从模型结构角度分析, CNN-LSTM-Attention 通过 CNN 提取局部特征,再利用 LSTM 和注意力机制建模序列依赖,但其循环结构在长序列建模中计算效率相对较低,且对复杂飞行剖面下的多尺度动态特征表达有限。多尺度并联 TCN 通过

并行卷积分支提取不同尺度特征,但其多分支结构在特征融合时可能存在冗余,且对层级递进的动态演化表征不足。Transformer 和 Informer 能够建模长程依赖关系,但对样本规模和训练稳定性要求较高,在 QAR 数据这种局部动态特征明显、飞行循环样本有限的场景下,不一定能够充分发挥全局注意力结构的优势。

相比之下,PTCN 通过递进式金字塔时序卷积结构逐层扩大有效感受野,使浅层网络关注局部瞬态变化,深层网络进一步提取较长时间范围内的趋势特征。这种由短时动态到较长趋势的层级特征提取方式,更符合真实 QAR 数据中燃油调节、转速响应、几何机构动作和热力参数变化所具有的多时间尺度特征。

2.6.3.4 PTCN 架构消融试验

为分析 PTCN 关键结构对预测性能的影响,本节从历史时间窗长度 L 、单分支 TCN 层数以及特征金字塔融合模块 (Feature Pyramid Fusion, FPN) 三个方面开展消融实验。其中,时间窗长度 L 分别设置为 32、64、128 和 256,对应滑动步长 S 分别为 8、16、32 和 64,以保持相近的窗口重叠比例;TCN 层数分别设置为 1、2、3 和 4 层,用于分析时序特征提取深度的影响;FPN 模块则通过对比完整 PTCN 与去除 FPN 后的模型性能进行验证。除消融变量外,其余网络结构、输入输出变量、训练参数及数据划分均保持一致。

时间窗长度消融结果如表 2-15 所示。当窗口长度分别为 32、64、128 和 256 时,平均 MAPE 分别为 0.71%、0.93%、0.79%和 1.00%。其中, $L=32$ 时取得最低平均误差,说明在当前 QAR 采样频率和飞行工况变化条件下,较短时间窗已能够提供较充分的局部动态信息;继续增大窗口长度虽然扩大了历史信息范围,但也引入更多跨工况变化信息,削弱模型对局部瞬态特征的刻画能力。

表 2-15 时间窗长度消融试验结果 (%)

消融类型	实验设置	Tt25	Tt3	Ps3	EGT	平均 MAPE
时间窗长度	$L=32, S=8$	0.35	0.39	1.44	0.66	0.71
时间窗长度	$L=64, S=16$	0.38	0.43	1.92	0.97	0.93
时间窗长度	$L=128, S=32$	0.36	0.45	1.59	0.77	0.79
时间窗长度	$L=256, S=64$	0.56	0.58	2.01	0.84	1.00

TCN 层数消融结果如表 2-16 所示。当 TCN 层数为 1、2、3 和 4 层时,平均 MAPE 分别为 1.04%、0.95%、0.79%和 1.10%。可以看出,层数由 1 层增加至 3 层时,模型误差逐步降低,说明适当加深时序卷积结构有助于提取更充分的多级动态特征;但当层数进一步增加至 4 层时,误差反而升高,这是由于连续下采样降低了

时间分辨率，导致部分细粒度动态信息损失。

表 2-16 TCN 层数消融试验结果 (%)

消融类型	实验设置	Tt25	Tt3	Ps3	EGT	平均 MAPE
TCN 层数	1 层	0.57	0.59	2.03	0.97	1.04
TCN 层数	2 层	0.44	0.48	2.09	0.78	0.95
TCN 层数	3 层	0.36	0.45	1.59	0.77	0.79
TCN 层数	4 层	0.36	0.49	2.71	0.84	1.10

FPN 模块消融结果如表 2-17 所示。在窗口长度为 128、TCN 层数为 3 层的相同设置下，完整 PTCN 的平均 MAPE 为 0.79%，去除 FPN 后升高至 0.86%。这表明 FPN 模块能够有效融合不同时间尺度下的 TCN 特征，使模型同时利用浅层高时间分辨率信息和深层抽象动态特征，从而提升整体预测精度。

表 2-17 FPN 模块消融试验结果 (%)

消融类型	实验设置	Tt25	Tt3	Ps3	EGT	平均 MAPE
FPN 模块	去除 FPN	0.46	0.48	1.80	0.72	0.86
FPN 模块	保留 FPN	0.36	0.44	1.59	0.77	0.79

基于上述结果，当前实验条件下，较优结构配置为：时间窗长度 $L=32$ 、TCN 层数为 3 层，并保留 FPN 模块。该配置能够在局部动态信息捕捉、时序特征提取深度和多尺度特征融合之间取得较好平衡。

2.7 本章小结

本章围绕航空发动机个性化长周期性能监视问题，提出了基于 PBM 与双旁路自适应补偿的性能监视方法。针对不同应用场景下数据获取条件的差异，分别从物理机理和数据驱动两个角度构建 PBM，并在此基础上引入未建模旁路和退化旁路，形成 PPM，以解决传统 PBM 难以适应单台发动机初始个体差异和长期性能退化的问题。

在方法构建方面，本章首先定义了航空发动机性能监视问题，明确了 PBM 作为无故障性能基准的作用；随后分别介绍了物理机理 PBM 和数据驱动 PBM 的构建思路。在此基础上，设计了未建模旁路用于补偿制造、装配、维护状态等因素带来的初始个体差异，设计退化旁路用于跟踪服役周期内逐渐累积的性能偏移。同时，针对旁路模型的持续更新需求，构建了数据准入、代表性下采样和在线动态演化相

结合的数据池管理机制，为模型长期稳定自适应提供数据支撑。

在验证方面，本章分别以小涵道比军用发动机和大涵道比民用涡扇发动机为对象开展实验。小涵道比发动机案例验证了基于物理机理 **PBM** 的双旁路方法能够有效降低初始预测偏差，并通过退化旁路更新跟踪长周期性能变化；数据池连续更新结果表明，所提数据池机制能够在保留历史代表性样本的同时吸收新增状态信息。大涵道比民用涡扇发动机案例基于真实 **QAR** 数据开展验证，采用金字塔时序卷积网络构建数据驱动 **PBM**，结果表明 **PTCN** 相比多种典型时序模型具有更好的基准预测能力，未建模旁路能够在小样本条件下实现快速个性化适配，退化旁路能够在连续运行周期中根据误差变化实现自适应更新。

第3章 多源不确定性下的气路故障诊断方法研究

3.1 本章引论

传统航空发动机气路故障诊断方法多依赖固定阈值、静态诊断模型或浅层特征判别策略。在发动机全寿命周期服役过程中,气路参数会受到个体差异、性能退化、未建模扰动和测量噪声等多源不确定性影响,导致正常状态下的参数基准和残差分布持续漂移。尤其在服役中后期,正常退化引起的性能偏移可能与早期微弱故障特征相互耦合,使故障边界逐渐模糊。此时,若仍采用固定阈值或静态基准进行诊断,容易将正常退化误判为故障,造成虚警率升高;也可能因故障特征被退化趋势和噪声扰动掩盖而产生漏检。因此,如何在多源不确定性条件下实现鲁棒、准确的气路故障诊断,是保障发动机长期安全服役和支撑视情维护的重要问题^[49]。

第2章构建的PPM能够为目标发动机提供更加准确的个性化正常性能参考,为后续气路故障诊断奠定基础。通过计算实测气路参数与PPM预测输出之间的偏差,可获得反映当前状态相对于正常基准偏离程度的残差特征,从而削弱工况变化、个体差异和正常退化对诊断结果的干扰^[126]。然而,在微弱故障或边缘故障条件下,故障引起的残差变化幅值较小,容易与测量噪声和未建模扰动发生混叠,导致原始残差空间中的类别可分性不足。因此,仅依赖残差特征难以保证诊断模型的鲁棒性,还需要进一步挖掘残差中的稳定故障模式,构建兼具抗噪能力和判别能力的特征表示方法。

基于此,本章提出一种基于双任务自编码器(Dual-task Autoencoder, DTAE)的自适应气路故障诊断方法。该方法以PPM残差特征为输入,通过损坏器增强模型对气路噪声和测量扰动的鲁棒性,并在编码过程中联合引入重构约束与分类约束,使模型在低维潜特征空间中学习兼具信息完整性和类别可分性的故障表征。结合数据更新机制,该方法能够适应发动机性能演化过程,提高全寿命周期内微弱故障和边缘故障的识别能力。

本章结构安排如下:3.1节给出本章引论;3.2节定义多源不确定性下的航空发动机气路故障诊断问题;3.3节介绍所提出的DTAE气路故障诊断方法;3.4节基于第2章所述小涵道比军用涡扇发动机开展仿真验证与结果分析;3.5节对本章研究内容进行总结。

3.2 气路故障诊断问题定义

气路故障诊断的核心任务是在 PPM 提供的个性化正常性能基准基础上, 准确识别发动机气路部件的异常状态, 并尽可能削弱环境扰动、个体差异、性能退化及测量噪声对诊断结果的影响。从诊断流程看, 气路故障诊断可分解为故障检测、故障隔离和模型在线自适应三个子问题。其中, 故障检测用于判断发动机当前状态是否异常, 可视为在线二分类问题; 故障隔离用于在检测到故障后识别具体故障部件或故障类型, 可视为在线多分类问题; 模型在线自适应则用于利用高质量运行数据对诊断模型进行增量更新, 以提高模型对目标发动机长期性能演化的适应能力。上述三个子问题可定义如下。

3.2.1 故障检测

故障检测旨在实时判定发动机当前是否偏离正常运行基准。基于式(2-3)定义的 PPM 输出, 定义观测残差 $r(t) \in \mathbb{R}^n$ 为传感器实测值 $y(t)$ 与模型预测值 $y_{PPM}^u(t)$ 之间的插值, 如式(3-1)所示:

$$r(t) = y(t) - y_{PPM}^u(t) = \Delta y_{fault}(t) + \varepsilon(t) \quad (3-1)$$

其中, $\Delta y_{fault}(t)$ ——代表由气路故障引起的性能突变或异常演化量。

$\varepsilon(t)$ ——代表测量噪声和随机扰动。

以 $r(t)$ 作为气路故障特征, 可将故障检测问题转化为二分类假设检验问题:

$$H_0 : \Delta y_{fault}(t) = 0 \quad (3-2)$$

表示发动机处于正常状态, $r(t)$ 主要由测量噪声和正常扰动构成;

$$H_1 : \Delta y_{fault}(t) \neq 0 \quad (3-3)$$

表示发动机存在故障状态, $r(t)$ 均值或分布特征发生显著偏移。

3.2.2 故障隔离

故障隔离是在完成故障检测后, 进一步识别故障所属的具体气路部件或故障类型。本章将故障隔离建模为从连续残差特征空间到离散故障类别集合的映射问题。考虑引入故障特征矩阵 D 和故障向量 $f(t)$, 将式(2-1)中的观测方程扩展为式(3-4):

$$y(t) = g(x(t), u(t), a(t), \omega(t), \varphi(t)) + D \cdot f(t) + \varepsilon(t) \quad (3-4)$$

在实际诊断中, 故障隔离模型以 $r(t)$ 为输入, 通过映射 M 输出不同故障类别

及概率分布，如式(3-5)、(3-6)所示：

$$M: r(t) \rightarrow \{0, 1, \dots, k\} \quad (3-5)$$

$$p = [p_0, p_1, \dots, p_k]^T, \quad \sum_{i=0}^k p_i = 1 \quad (3-6)$$

其中， p_i ——代表样本属于第 i 类故障的概率。最终以概率最大的类别作为故障隔离结果，从而定位具体故障部件。

3.2.3 模型在线自适应

模型在线自适应用于保证诊断模型在发动机全寿命周期性能演化过程中的鲁棒性和持续适应能力。其前提是输入更新数据具有可靠性，避免将故障样本误用于模型更新。因此，本章采用由故障检测模块反馈控制的更新机制：仅当检测结果为正常时，当前阶段的监测数据 $\{u, y\}$ 才被存入更新缓存池；若检测到潜在故障，则暂停模型更新，以避免将故障引起的残差漂移误学习为正常性能退化。

3.3 气路故障诊断方法

3.3.1 基于 DTAE 的故障诊断方法流程

针对多源不确定性条件下航空发动机气路故障诊断问题，本章提出一种基于 DTAE 的分阶段故障诊断方法。该方法以 PPM 生成正常参考输出，以实测输出与参考输出之间的偏差构建残差特征，并通过引入加噪和掩码机制的 DTAE 实现鲁棒特征提取。在诊断策略上，本章采用符合工程应用需求的分阶段决策方式，即先进行故障检测，再对异常样本进行故障隔离，以降低正常状态被误判为故障的虚警风险。

从实现过程上看，所提出的方法包括离线训练和在线诊断及自适应过程两个阶段。其中，离线训练阶段用于构建残差样本、训练鲁棒特征提取模型，并分别建立故障检测模型和故障隔离模型；在线诊断及自适应阶段则面向目标发动机实时判别运行状态，并利用后续确认无故障的数据对模型进行持续更新，以适应发动机个体状态的动态变化。

3.3.1.1 离线训练过程

离线训练的目标是基于历史运行数据构建残差特征样本，利用 DTAE 学习鲁棒潜在表示，并进一步完成故障检测与故障隔离模型训练，如图 3-1 所示。具体过

程包括以下三个步骤。




图 3-1 故障诊断模型离线训练流程示意图

(1) 残差特征构建

首先,从历史运行样本中提取工况参数和状态参数,并利用第2章构建的PPM计算对应工况下的正常参考输出。随后,将实测状态参数与PPM预测输出作差,分别构建正常样本和故障样本的残差特征。相比直接使用原始测量参数,残差特征能够削弱工况变化、个体差异和正常退化趋势的影响,使故障引起的异常偏移更加突出。

(2) DTAE 鲁棒特征学习

在获得残差特征后,将其输入DTAE进行潜在特征学习。DTAE通过重构任务和分类任务的联合优化,学习既能保留残差主要结构信息、又具备故障判别能力的低维特征表示。为增强模型对噪声和局部异常的适应能力,本章在编码器输入端引入加噪和掩码操作。其中,加噪操作用于模拟传感器噪声和环境扰动,掩码操作用于模拟局部特征缺失、信号污染或异常波动。通过扰动增强,编码器被迫从受污染或部分缺失的残差输入中提取稳定特征,从而提高模型鲁棒性。

在任务设计上,重构任务通过最小化输入残差与重构残差之间的误差,使潜在

特征保留原始残差的主要信息；分类任务则利用标签监督，引导编码器提取更有利于区分正常状态、故障状态及不同故障模式的判别特征。二者共同作用，使模型获得兼具稳定性和可分性的故障表示。

(3) 故障检测与隔离模型训练

DTAE 训练完成后，利用编码器提取的潜在特征分别训练故障检测模型和故障隔离模型。其中，故障检测模型以正常样本和故障样本为训练对象，学习正常/故障二分类边界；故障隔离模型仅以故障样本为训练对象，学习不同气路故障类型之间的细粒度差异。由于故障隔离建立在故障已被检测的基础上，因此模型可以更专注于故障类别间的判别，提高具体故障类型的识别精度。

3.3.1.2 在线诊断及自适应过程

在线诊断及自适应过程面向目标发动机实时运行数据，主要用于完成异常识别、故障类别判定以及 PPM 的持续修正。其核心是利用 PPM 生成当前工况下的正常参考输出，并基于实测值与参考值之间的残差进行故障诊断；同时，仅将判定为正常的运行样本用于后续模型更新，以适应发动机长期服役过程中的状态演化。具体流程如图 3-2 所示，该过程主要包括以下三个步骤。




图 3-2 故障诊断模型在线诊断及自适应流程

(1) 在线残差特征构建

在在线部署前，首先利用目标发动机初始无故障飞行架次对 PPM 进行初始化微调，使其能够表征该发动机健康状态下的个体化输入输出关系。在实时运行阶段，系统采集当前工况参数并输入 PPM，得到对应的正常期望输出；随后将实测状态参数与 PPM 预测输出作差，构建在线残差特征。该残差特征进一步输入离线训练

好的编码器，提取潜在特征表示，为后续诊断决策提供输入。

(2) 分阶段故障诊断

获得潜在特征后，系统首先调用故障检测模型进行正常/异常二分类判别。若检测结果为正常，则维持正常监测状态，不再触发故障隔离；若检测结果为异常，则进一步调用故障隔离模型，识别具体故障类别并输出诊断结果。

(3) 模型在线自适应

对于在线阶段判定为正常的样本，系统将其加入更新数据池，用于后续 PPM 自适应修正。由于发动机在长期服役过程中会发生正常性能退化，若 PPM 长期保持不变，残差分布将随时间逐渐漂移，进而影响故障检测与隔离效果。因此，利用新增无故障样本持续更新 PPM，可使正常参考模型动态跟踪目标发动机的性能演化过程，从而提高长期在线诊断的稳定性和可靠性。

3.3.2 双任务自编码器

多任务学习是一种通过同时学习多个相关任务来提升模型泛化能力的机器学习范式。其核心思想是利用任务之间的关联性，实现特征共享和协同优化，从而增强模型对复杂数据的表征能力。针对气路故障诊断中残差特征易受噪声扰动、类别边界模糊等问题，本章构建 DTAE，通过重构任务和分类任务的联合约束，学习兼具稳定性和判别性的潜在故障特征。

3.3.2.1 自编码器基本原理

自编码器（Auto Encoder, AE）由编码器和解码器两部分组成，编码器通过非线性映射将输入特征压缩为低维潜在表示，解码器则根据该潜在表示重构原始输入。设输入特征向量为 $\mathbf{x} \in \mathbb{R}^d$ ，编码过程通过激活函数 $f(\bullet)$ 计算隐藏层输出向量 $\mathbf{z}$ ，如式(3-7)所示：

$$\mathbf{z} = f(\mathbf{W}\mathbf{x} + \mathbf{b}) \quad (3-7)$$

其中， $\mathbf{W}$ ——代表输入层与隐藏层之间的权重矩阵；

$\mathbf{b}$ ——代表输入层与隐藏层之间的偏置。

重构过程通过激活函数 $g(\bullet)$ 对隐藏层向量进行逆转换以重构输入信号 $\hat{\mathbf{x}}$ ，如式(3-8)所示：

$$\hat{\mathbf{x}} = g(\mathbf{W}'\mathbf{z} + \mathbf{b}') \quad (3-8)$$

其中， $\mathbf{W}'$ ——代表隐藏层与输出层之间的权重矩阵；

$\mathbf{b}'$ ——代表隐藏层与输出层之间的偏置。

自编码器的训练目标是使重构输出尽可能接近原始输入，因此其重构损失通

常定义为式(3-9):

$$L_{rec} = \frac{1}{N} \sum_{i=1}^N \|x_i - \hat{x}_i\|_2^2 \quad (3-9)$$

其中, N ——代表训练样本数量;

x_i ——代表第 i 个样本的输入特征;

$\hat{x}_i$ ——代表第 i 个样本的重构特征。

基础 AE 主要依赖重构误差学习输入数据结构, 能够较好地描述数据分布, 但并不一定保证潜在特征具有良好的类别可分性。在气路故障诊断任务中, 仅依靠重构任务可能使模型忽略对故障类别区分有用的局部差异。因此, 有必要引入监督信息, 引导编码器学习更具判别性的潜在特征。

3.3.2.2 多任务学习基本原理

多任务学习 (Multi-Task Learning, MTL) 通过共享模型结构或特征表示, 同时优化多个相关任务。其基本思想是, 当不同任务之间存在关联时, 模型可通过共享层学习更通用的特征, 并利用任务特定分支完成不同预测目标, 从而提高模型的泛化能力和训练稳定性^[127]。

典型 MTL 结构通常由共享特征提取层和任务分支组成。设共享特征提取网络为 $F(\bullet)$, 输入样本为 x , 则共享特征表示如式(3-10)所示:

$$h = F(x) \quad (3-10)$$

对于第 k 个任务, 其预测输出 $\hat{y}_k$ 可表示为式(3-11):

$$\hat{y}_k = H_k(h) \quad (3-11)$$

其中, $H_k(\bullet)$ ——代表第 k 个任务对应的任务分支。

多任务学习的整体优化目标通常由多个任务损失加权组成, 如式(3-12)所示:

$$L_{MTL} = \sum_{k=1}^K \lambda_k L_k \quad (3-12)$$

其中, K ——代表任务数量;

λ_k ——代表第 k 个任务的权重系数;

L_k ——代表对应任务的损失函数。

对于气路故障诊断而言, 残差特征既包含发动机状态偏离的结构信息, 也包含正常/故障状态及具体故障模式的判别信息。若仅依赖重构任务, 模型可能更关注整体数据分布, 而忽略类别差异; 若仅依赖分类任务, 模型可能过度拟合标签信息,

降低对噪声扰动和未见样本的适应能力。因此，将重构任务与分类任务结合，有助于学习兼具稳定性和可分性的潜在表示。

3.3.2.3 双任务自编码器整体架构

基于 AE 和 MTL 思想，本章构建 DTAE 用于气路故障诊断中的鲁棒特征学习。需要说明的是，本章所述“双任务”并非指在线诊断阶段同时完成故障检测和故障隔离两个决策输出，而是指模型训练阶段同时引入重构任务和分类任务。其中，重构任务用于约束潜在特征保留输入残差的主要结构信息，分类任务用于增强潜在特征对健康状态和故障模式的判别能力。

DTAE 整体由输入扰动层、编码器、解码器和分类分支组成。输入残差特征首先经过加噪和掩码处理，得到受扰动输入；随后，编码器将其映射到潜在空间，获得鲁棒潜在特征表示。一方面，潜在特征输入解码器，用于重构原始残差特征；另一方面，潜在特征输入分类分支，用于完成诊断相关的监督判别。模型通过重构损失与分类损失的联合优化，实现抗噪表征学习和故障判别能力提升。DTAE 基本架构如图 3-3 所示，具体流程如下：




图 3-3 DTAE 基本架构

为模拟实际气路监测中的噪声干扰和局部特征缺失，本节采用掩码与乘性噪声相结合的输入扰动方式。首先生成二值掩码向量 $\mathbf{M} = [M_1, M_2, \dots, M_d]^T \in \{0, 1\}^d$ ，并将 $\mathbf{M}$ 与 $\mathbf{x}$ 进行逐元素相乘得到掩码中间结果 $\mathbf{x}_{masked}$ 。然后将 $\mathbf{x}_{masked}$ 乘以乘性高斯噪声 $\eta \sim N(1, \sigma^2)$ ，利用乘性形式避免产生依赖于绝对数据大小的失真。破经过掩码和噪声扰动后的输入特征 $\tilde{\mathbf{x}}$ 表达式如式(3-13)所示：

$$\tilde{\mathbf{x}} = (\mathbf{M} \odot \mathbf{x}) \odot \eta \quad (3-13)$$

DTAE 的编码与重构过程与标准 AE 类似，但重构任务的目标并不是重构 $\tilde{\mathbf{x}}$ ，而是尽可能恢复原始 $\mathbf{x}$ 。因此，重构损失定义与式(3-9)一致，以保证潜在特征能够保留原始残差结构信息。

在分类任务中，潜在特征 $\mathbf{z}$ 被送入分类分支，该分支通过 $\text{classifier}(\bullet)$ 激活函数将隐藏层向量映射到类别概率分布，如式(3-14)所示：

$$\hat{\mathbf{p}} = \text{classifier}(\mathbf{W}_c \mathbf{z} + \mathbf{b}_c) \quad (3-14)$$

其中， c ——代表类别数量；

$\mathbf{W}_c$ ——代表隐藏层与分类输出层之间的权重矩阵；

$\mathbf{b}_c$ ——代表隐藏层与分类输出层之间的偏置；

$\hat{\mathbf{p}} \in \mathbb{R}^c$ ——代表预测的类别概率分布。

分类损失采用交叉熵损失函数，如(3-20)所示：

$$L_{cls} = -\frac{1}{N} \sum_{i=1}^N \sum_{c=1}^C p_{i,c} \log \hat{p}_{i,c} \quad (3-15)$$

其中， $p_{i,c}$ ——代表真实标签编码；

$\hat{p}_{i,c}$ ——代表模型预测第 i 个样本属于第 c 类的概率。

最终，DTAE 通过联合优化重构损失和分类损失进行训练，其目标函数如式(3-16)：

$$\{\mathbf{W}, \mathbf{b}, \mathbf{W}', \mathbf{b}', \mathbf{W}_c, \mathbf{b}_c\} = \arg \min [L_{rec}(\mathbf{x}, \hat{\mathbf{x}}) + L_{cls}(\mathbf{p}, \hat{\mathbf{p}})] \quad (3-16)$$

通过该联合约束，DTAE 能够在保持残差结构信息的同时增强故障类别可分性，从而提升多源不确定性条件下气路故障诊断的鲁棒性。

3.4 仿真试验与分析

3.4.1 试验数据描述

为验证本章所提出的基于 DTAE 的气路故障诊断方法的有效性，本节基于第 2.5.1 节中构建的航空发动机仿真数据开展试验分析。由于仿真数据的工况参数、控制量、气路状态参数及故障注入方式已在前文中进行了说明，本节不再对数据来源进行重复介绍，而是重点说明面向故障诊断任务的数据组织方式、模型输入输出设置以及评价指标。

3.4.2 模型设置与评价指标

3.4.2.1 DTAE 模型设置

针对故障诊断过程中的检测与隔离两个阶段，本章分别构建了 DTAE 检测模型（DTAE_Det）和 DTAE 隔离模型（DTAE_Iso）。其中，DTAE_Det 用于实现正常/故障二分类，DTAE_Iso 用于实现不同气路故障类型的多分类识别。

结合本节仿真数据设置，模型输入由气路温度、压力和转速等状态参数偏差构成，即 $\mathbf{x} = [\Delta N1, \Delta N2, \Delta Pt25, \Delta Tt25, \Delta Pt3, \Delta Tt3, \Delta Pt5, \Delta Tt5]$ ；DTAE_Det 的输出是为正常或故障状态，DTAE_Iso 的输出是 Fan、HPC、HPT 和 LPT 四类故障。表 3-1 展示了两个模型的输入与输出设置。

表 3-1 诊断模型中各子模型的输入输出设置

角色	DTAE_Det	DTAE_Iso
输入	$\Delta N1, \Delta N2, \Delta Pt25, \Delta Tt25, \Delta Pt3, \Delta Tt3, \Delta Pt5, \Delta Tt5$	$\Delta N1, \Delta N2, \Delta Pt25, \Delta Tt25, \Delta Pt3, \Delta Tt3, \Delta Pt5, \Delta Tt5$
输出	正常，故障	Fan 故障，HPC 故障， HPT 故障，LPT 故障

仿真试验中，DTAE_Det 和 DTAE_Iso 的超参数通过网格搜索确定，具体设置如表 3-2 所示。两个模型均采用相同的编码器和解码器结构，编码器结构为[8,8,8,4]，解码器结构为[4,8,8,8]。分类器部分根据任务类型设置不同输出维度：DTAE_Det 分类器结构为[4,4,2]，DTAE_Iso 分类器结构为[4,4,4]。模型训练中，掩码比例设为 0.5，噪声幅值设为 0.05，优化器采用 Adam，学习率为 0.001，训练轮数为 100。

表 3-2 诊断模型中各子模型的超参数设置

超参数设置	DTAE_Det	DTAE_Iso
各层结构	编码器：[8,8,8,4] 解码器：[4,8,8,8] 分类器：[4,4,2]	编码器：[8,8,8,4] 解码器：[4,8,8,8] 分类器：[4,4,4]
掩码比例	0.5	0.5
噪声幅值	0.05	0.05
激活函数	ReLU+Sigmoid	ReLU+Softmax
优化器	Adam	Adam
学习率	0.001	0.001
训练 epoch	100	100
损失函数	$L_{\text{总}} = L_{\text{rec}} + L_{\text{cls}}$	$L_{\text{总}} = L_{\text{rec}} + L_{\text{cls}}$

3.4.2.2 故障诊断评价指标

由于仿真数据以飞行架次为基本诊断对象，而单个飞行架次内包含大量连续采样点，诊断模型会对每个采样点输出一级检测或隔离结果。因此，在计算评价指标前，需要首先采样点级诊断结果转换为架次级诊断结果。

对于第 j 个飞行架次，设其包含 N_j 个采样点，故障检测模型在各采样点上的输出为 $\hat{d}_{j,i} \in \{0,1\}, i=1,2,\dots,N_j$ ，其中 0 代表检测为正常，1 代表判定为故障。式(3-17)定义了该架次内被判定为故障的采样点比例为：

$$\rho_j = \frac{1}{N_j} \sum_{i=1}^{N_j} \hat{d}_{j,i} \quad (3-17)$$

当 ρ_j 大于预设架次判定阈值 τ_f 时（本节默认取 $\tau_f = 0.5$ ），认为第 j 个飞行架次为故障架次；否则判定为正常架次。进一步，基于被判定为故障的架次，统计该架次内所有被检测为故障采样点的隔离结果。设故障隔离模型输出的类别为 $\hat{c}_{j,i} \in \{1,2,\dots,K\}$ ， K 为故障类别数量，统计出现频次最高的类别作为最终的架次级诊断结果。

在架次级诊断结果上，本章选取虚警率（False Alarm Rate, FAR）、检测率（Detection Rate, DR）和隔离率（Isolation Rate, IR）作为评价指标^[128]。其中，FAR 用于衡量无故障样本被误判为故障的比例，DR 用于衡量实际故障样本被成功检测出的比例，IR 用于衡量已检测故障被正确定位至具体故障部件的比例。其定义如式(3-18)、(3-19)、(3-20)所示：

$$FAR = \frac{N_{FA}}{N_{NF}} \times 100\% \quad (3-18)$$

$$DR = \frac{N_{CD}}{N_F} \times 100\% \quad (3-19)$$

$$IR = \frac{N_{CI}}{N_{CD}} \times 100\% \quad (3-20)$$

其中， N_{NF} ——代表无故障气路样本的总数；

N_{FA} ——代表被错误归类为故障的无故障样本数量；

N_F ——代表实际存在故障的气路样本总数；

N_{CD} ——代表正确检测到的故障样本数量；

N_{CI} ——代表被准确判定具体故障部件的故障样本数量。

基于上述定义，故障检测阶段主要关注 FAR 和 DR，以评价模型对正常样本

误报控制能力和故障样本识别能力；故障隔离阶段主要关注 IR，以评价模型对具体故障类型的定位能力。

3.4.3 连续 50 个飞行架次的故障诊断验证

为验证所提方法在连续服役过程中的故障检测与隔离能力，本节设计了包含 50 个连续飞行循环的仿真试验。该试验用于评估诊断模型在短周期连续运行条件下对多部件间歇性气路故障的识别能力，并分析其在降低虚警和提高诊断可靠性方面的效果。

试验中考虑不同飞行循环间的工况变化以及发动机性能随循环推进产生的缓慢退化，分别在第 19—20、29—30、39—40 和 49—50 个飞行循环中向 Fan、HPC、HPT 和 LPT 注入气路故障，并在第 20、30、40 和 50 个飞行循环结束后执行维护与重置操作，以模拟气路部件短时突发异常及维护恢复过程。由此，4 类部件故障各持续 2 个飞行循环，共包含 8 个故障循环。

针对上述数据集，本节选取 PBM-MLP、PBM-DTAE、PPM-MLP 和 PPM-DTAE 四种方法进行对比。其中，PBM 和 PPM 分别用于构建残差特征，MLP 和 DTAE 分别作为后端诊断模型。各方法均遵循两阶段检测、隔离的范式，并分别统计 FAR、DR 和 IR 等指标。试验结果如图 3-4 和图 3-5 所示。




图 3-4 连续 50 个飞行架次的诊断结果

从图 3-4 的试验结果可以看出，两种基于 PBM 的方法整体诊断性能较差，尤其在虚警控制方面表现不理想，其 FAR 均高达 65.1%。这同样说明了在连续运行过程中，仅依赖统一的 PBM 难以准确表征目标发动机的个体性能状态。当发动机存在个体差异或正常退化累积时，PBM 输出与实测状态之间的偏差会逐渐增大，

使得由退化或个体差异引起的正常偏移被误认为突发故障，进而造成大量虚警。此时不论后端选择何种特征学习模型，均难以弥补正常参考模型不准确带来的影响。图 3-5 所示的混淆矩阵进一步揭示了 PBM 类方法诊断性能下降的原因。可以看到，基于 PBM 的方法存在较为严重的误判现象，即大量正常飞行循环被错误识别为 Fan、HPC、HPT 或 LPT 等部件故障。




图 3-5 50 个连续飞行架次中四种诊断方法的混淆矩阵

相比之下，两种基于 PPM 的方法均取得了更加理想的诊断结果。基于该参考模型构建的残差特征能够更有效地剥离正常退化影响，使突发故障引起的异常偏移在特征空间中更加清晰。因此，PPM-MLP 和 PPM-DTAE 均表现出较低的 FAR 和较高的 DR，验证了 PPM 在复杂连续运行场景下对故障诊断的重要作用。

3.4.4 连续 400 个飞行架次的故障诊断验证

为进一步验证所提方法在长期服役场景下的诊断鲁棒性,本节设计了包含 400 个连续飞行架次的仿真试验。相比 3.4.3 节的 50 个架次验证,本节进一步延长运行周期,并提高故障注入的随机性和复杂性,用于评估不同方法在长期退化累积、故障幅值波动和多部件随机故障条件下的诊断性能。

在试验设计中,从 400 个连续飞行循环中随机抽取 40 个非连续循环,分别向 Fan、HPC、HPT 和 LPT 注入气路故障,并在每个故障架次着陆后完成维护与重置。与 50 个架次试验相比,本节扩大了故障幅值范围,以模拟实际服役过程中故障程度随机变化、早期弱故障难以识别等情况。因此,该试验共包含 40 个故障架次,其余为正常架次,可用于考察诊断方法在长周期监测条件下对正常退化、微弱故障和随机突发异常的区分能力。

针对上述数据集,仍采用 PBM-MLP、PBM-DTAE、PPM-MLP 和 PPM-DTAE 四种方法进行对比,并统计 FAR、DR 和 IR 等指标,结果如图 3-6 和图 3-7 所示。




图 3-6 连续 400 个飞行架次的诊断结果

从故障检测结果看,基于 PBM 的方法在长期运行场景下面临更严重的虚警问题。随着 400 个架次内性能退化不断累积, PBM 难以维持稳定准确的正常参考基准,使正常循环对应的残差逐渐偏离健康样本分布,进而被误判为故障。其中, PBM-DTAE 的 FAR 升高至 94.6%,表明大量正常循环被错误识别为故障。图 3-7 (a)-(b)中的混淆矩阵也显示, PBM 类方法对正常类别的识别能力明显下降,难以有效区分自然退化偏移和真实气路故障。相比之下, PPM 类方法仍能保持较低 FAR,体现了其对目标发动机正常性能基准的持续跟踪能力。




图 3-7 400 个连续飞行架次中四种诊断方法的混淆矩阵

进一步比较 PPM-MLP 与 PPM-DTAE 可知, PPM-MLP 虽然能够降低虚警, 但其 IR 下降至 70.0%, 说明仅依赖 PPM 残差特征和传统 MLP 分类器, 仍难以充分识别弱故障和边缘故障。图 3-7 (c) 中的混淆矩阵显示, PPM-MLP 存在较明显漏检现象, 部分微弱故障被误判为正常, 表明浅层分类模型对细微异常模式的判别能力有限。

相比之下, 本章提出的 PPM-DTAE 取得了更优的综合诊断性能, IR 达到 94.0%。由图 3-7 (d) 可见, PPM-DTAE 的混淆矩阵在正常状态和各故障类别上均呈现更集中的对角线分布, 说明该方法不仅能够准确识别正常循环, 还能有效提高对 Fan、HPC、HPT 和 LPT 等不同故障类别的检测与隔离能力。尤其在故障幅值随机变化


和微弱故障样本存在的情况下，DTAE 通过抗噪特征学习增强了残差特征的可分性，从而提高了诊断稳定性。

基于上述分析可知，PBM 类方法由于缺乏个体适应与退化补偿能力，在长周期运行中容易出现严重虚警；PPM-MLP 能够借助个性化正常参考降低 FAR，但在弱故障识别方面仍存在漏检风险；PPM-DTAE 则同时发挥了 PPM 的正常基准自适应能力和 DTAE 的鲁棒特征学习能力，在长期退化、多部件随机故障和故障幅值不确定条件下取得了更高 DR 和更稳定的故障识别效果。

3.4.5 DTAE 潜在特征可视化分析

为进一步分析 DTAE 对残差特征表征能力的提升作用，本节对原始残差特征和 DTAE 编码器输出的潜在特征进行可视化对比。前述诊断结果表明，PPM-DTAE 在 FAR、DR 和 IR 等指标上均取得较好效果，但统计指标难以直观反映特征空间结构的变化。因此，本节采用主成分分析（Principal Component Analysis, PCA）方法将高维特征映射至二维平面，从样本分布角度分析 DTAE 对故障检测和故障隔离性能提升的作用机制。

图 3-8 展示了原始残差特征的二维分布结果，图 3-9 展示了 DTAE 潜在特征的二维分布结果。其中，正常样本与故障样本的分布用于分析故障检测能力，Fan、HPC、HPT 和 LPT 四类故障样本的分布用于分析故障隔离能力。通过对比两类特征空间中的样本分布，可直观评估 DTAE 是否学习到了更适合诊断任务的特征表示。



(a) 故障检测数据特征主成分可视化 (b) 故障隔离数据特征主成分可视化

图 3-8 原始特征数据主成分可视化结果




图 3-9 诊断模型潜空间可视化结果

从原始残差特征可视化结果可以看出，正常样本与故障样本已呈现一定分布差异，说明 PPM 残差能够削弱工况变化和正常退化的影响，并保留故障相关信息。然而，正常样本与部分故障样本之间仍存在交叠，尤其在故障幅值较小、噪声扰动较强或不同故障残差响应相近时，部分故障样本容易分布在正常样本边界附近，导致类别边界不够清晰。

相比之下，DTAE 潜在特征表现出更明显的类别聚集和分离特征。在故障检测任务中，正常样本与故障样本形成相对独立的分布区域，二者间隔明显增大；在故障隔离任务中，Fan、HPC、HPT 和 LPT 四类故障样本分别形成较为集中的聚类区域，类别重叠明显减少。这说明 DTAE 能够将原始残差映射到更具判别性的潜在空间，从而提高正常/故障判别和故障类型区分能力。

DTAE 潜在空间可分性的提升主要来源于重构任务、分类任务和扰动增强机制的共同作用。重构任务约束编码器保留残差特征中的主要结构信息，避免关键故障响应在降维过程中丢失；分类任务利用标签监督引导潜在特征向类别可分方向优化；加噪和掩码操作则降低模型对局部噪声和偶然扰动的敏感性，使编码器更加关注多维残差之间稳定的故障关联模式。

基于以上可视化结果，可知 DTAE 并非仅对原始残差进行简单压缩，而是在重构保持、分类监督和扰动增强的共同约束下，学习到了更鲁棒、更具判别性的潜在故障表示。

3.4.6 噪声鲁棒性验证

为验证所提出 DTAE 模型在传感器扰动和残差特征噪声条件下的稳定性, 本节在测试样本的原始残差特征上叠加不同强度的高斯噪声, 并分析模型诊断性能随噪声强度变化的规律。噪声添加方式如式(3-21)所示:

$$\mathbf{x}_{noisy} = \mathbf{x} + \sigma \cdot std(\mathbf{x}) \cdot N(0,1) \quad (3-21)$$

其中, $\mathbf{x}_{noisy}$ ——代表添加噪声后的原始残差特征;

$std(\mathbf{x})$ ——代表各维残差特征的标准差;

$N(0,1)$ ——代表标准正态分布随机变量;

σ ——代表噪声强度。

本节分别设置 σ 为 0%、1%、2%、3%、5%、8%、10%、15%、20%、25% 和 30%。除无噪声情况外, 各噪声强度重复 10 次实验, 并取均值作为最终结果。

由图 3-10 可知, 随着噪声强度增加, DTAE 的 DR 和 IR 整体保持在较高水平, 而 FAR 呈逐步上升趋势。无噪声条件下, DTAE 的 DR 为 0.99, FAR 为 0.001, IR 为 1.00; 当噪声强度增加至 20% 时, DR 为 0.99, FAR 为 0.007, IR 为 0.99; 当噪声强度进一步增加至 30% 时, DR 仍保持在 0.99, FAR 上升至 0.04, IR 为 0.98。上述结果表明, DTAE 在较强噪声扰动下仍具有稳定的故障检测和隔离能力。




图 3-10 不同噪声强度下 DTAE 模型性能变化

进一步分析可知, 噪声主要增加了正常样本被误判为故障的风险, 而对故障样本的检出能力影响较小。这是因为强噪声会使部分正常样本残差向故障边界附近扩散, 从而提高误报概率; 而故障样本相对于正常状态通常具有更明显的残差偏移, 因此仍能够被模型较稳定地识别。

为进一步验证 DTAE 结构的抗噪优势, 本节将其与 MLP 和 AE+分类器进行对

比。三种方法采用相同的数据划分和噪声设置。其中，MLP 仅包含分类网络，不含重构约束；AE+分类器包含编码器、解码器和分类头，但训练阶段不主动引入噪声扰动。

在故障检测任务中，由图 3-11 可知，DTAE 在不同噪声强度下均保持较高 DR，且 FAR 上升幅度相对较小。以 30% 噪声为例，DTAE 的 DR 为 0.99，FAR 为 0.04；AE+分类器的 DR 为 0.98，FAR 为 0.10；MLP 的 DR 为 0.96，FAR 为 0.07。说明 DTAE 在保持较高检测率的同时，能够更有效地抑制噪声导致的误报。




图 3-11 不同噪声强度下各方法故障检测性能对比

在故障隔离任务中，由图 3-12 可知，三种方法的 IR 均随噪声增强而下降，但 DTAE 下降幅度最小。30% 噪声条件下，DTAE 的 IR 为 0.99，AE+分类器为 0.98，MLP 为 0.97。说明 DTAE 通过去噪训练和潜在特征约束，使不同故障类型在高噪声条件下仍保持较好的类间可分性。




图 3-12 不同噪声强度下各方法故障隔离性能对比

3.5 本章小结

本章围绕多源不确定性条件下航空发动机气路故障诊断问题，提出了一种基于 DTAE 的分阶段故障诊断方法。针对发动机个体差异、性能退化、未建模扰动以及噪声干扰等因素对故障特征提取和诊断决策造成的影响，本章首先利用 PPM 构建目标发动机在当前工况下的正常参考输出，并通过实测状态参数与参考输出之间的差值构建残差特征，使诊断模型能够在相对正常基准的偏离空间中识别故障，从而削弱工况变化和正常退化对故障判断的干扰。

在诊断模型设计方面，本章构建了基于 DTAE 的鲁棒特征学习模型。该模型以 AE 为基础，引入重构任务和分类任务联合优化机制，使编码器学习到兼具结构保持能力和类别判别能力的潜在特征。同时，针对噪声不确定性对残差特征的影响，在编码器训练过程中引入加噪和掩码操作，增强模型对测量噪声、局部扰动和信息缺失的适应能力。在诊断流程上，本章采用先故障检测、后故障隔离的分阶段策略，先通过二分类模型判断发动机是否异常，再对异常样本进行具体故障类型识别，以降低正常样本被误判为故障的虚警风险。

在仿真验证方面，本章分别开展了连续 50 个飞行架次和连续 400 个飞行架次的故障诊断试验。结果表明，基于 PBM 的方法由于缺乏对发动机个体差异和长期退化的适应能力，容易将正常退化引起的偏移误判为气路故障，导致较高虚警率；而基于 PPM 的方法能够更准确地构建目标发动机当前状态下的正常参考基准，有效区分自然退化与突发故障。在此基础上，PPM-DTAE 进一步提升了故障检测和故障隔离的稳定性，尤其在长周期运行、故障幅值随机变化和微弱故障条件下表现出更好的综合诊断性能。

第4章 基于域自适应的小样本气路故障诊断方法研究

4.1 本章引论

第3章针对多源不确定性条件下的航空发动机气路故障诊断问题,构建了基于PPM残差和DTAE鲁棒特征学习的诊断方法,并验证了其在噪声扰动、传感器偏差和工况变化等因素影响下的有效性。然而,在实际工程应用中,诊断模型仍面临故障样本稀缺和跨域分布差异两方面挑战。尤其当目标发动机仅有少量带标签故障样本时,模型难以充分学习不同故障模式的特征分布,导致诊断精度和泛化能力受限。

一方面,航空发动机大部分服役周期处于正常运行状态,真实气路故障发生概率低,且故障试验成本高、风险大,因此可获取的真实带标签故障样本十分有限^[129]。虽然源域通常能够积累较为丰富的正常运行数据,用于描述发动机健康状态下的性能变化规律,但故障样本仍然不足,难以直接支撑深度诊断模型对多类故障特征的充分学习。另一方面,不同发动机个体受制造装配差异、运行环境、服役历史和工况分布等因素影响,其气路参数响应和故障特征分布往往存在差异。传统数据驱动诊断方法通常隐含训练数据与测试数据服从独立同分布的假设,若直接将源域样本或源域模型应用于目标发动机,容易因源域与目标域之间的分布偏移而导致模型泛化能力下降,甚至出现诊断失效^[131]。

为解决上述问题,本章在第3章研究基础上引入域自适应思想,开展小样本条件下的气路故障诊断方法研究。与直接迁移源域故障样本或诊断模型不同,本章方法主要利用源域中较为丰富的正常样本,结合目标域少量故障样本,通过深度特征提取和域分布对齐,构建源域正常状态与目标域故障状态之间具有可比性的跨域特征空间。在此基础上,利用目标域少量故障样本所包含的故障偏移信息,生成面向目标域的故障样本,以扩充诊断模型训练所需的故障特征空间,从而提高小样本条件下目标发动机故障诊断的精度和泛化能力。

本章结构安排如下:4.1节给出本章引论;4.2节定义小样本条件下的气路故障诊断问题,并分析源域与目标域之间的分布差异;4.3节介绍所提出的域自适应故障样本生成方法及模型结构;4.4节通过仿真案例验证生成样本的有效性及其对诊断性能的提升作用;4.5节对本章研究内容进行总结。

4.2 小样本故障诊断方法问题定义

4.2.1 域与数据分布的数学描述

在域自适应理论框架下，将拥有丰富标签数据的场景定义为源域，通常对应于航空发动机的高保真仿真模型或积累了大量历史故障数据的同型机队；将缺乏充足标签数据的当前实际诊断场景定义为目标域。

定义源域数据集为 $\mathcal{D}_s = \{(x_i^s, y_i^s)\}_{i=1}^{n_s}$ ，其中 $x_i^s \in \mathcal{X}_s$ 表示源域的第 i 个样本的特征向量（如气路传感器的测量偏差、状态参数等）， $y_i^s \in \mathcal{Y}_s$ 表示对应的健康状态或故障模式标签， n_s 为源域样本总数。源域数据服从边缘概率分布 $P_s(X)$ 。

同理，定义目标域数据集为 $\mathcal{D}_t$ 。在小样本前提下，目标域通常由少量的有标签数据集 $\mathcal{D}_t^l = \{(x_j^t, y_j^t)\}_{j=1}^{n_l}$ 和大量的无标签数据集 $\mathcal{D}_t^u = \{x_k^u\}_{k=1}^{n_u}$ 组成，即 $\mathcal{D}_t = \mathcal{D}_t^l \cup \mathcal{D}_t^u$ 。其中， $n_l \ll n_u$ ，且对于每一个故障类别 $c \in \mathcal{Y}$ ，目标域中仅包含极少量的 K 个带标签样本。目标域数据服从边缘概率分布 $P_t(X)$ 。

4.2.2 跨域小样本诊断的核心挑战

本章所研究的航空发动机跨域气路故障诊断问题，满足以下两个基本假设与挑战：

（1）特征空间与标签空间一致：源域与目标域共享相同的特征观测维度和故障模式类别，即 $\mathcal{X}_s = \mathcal{X}_t = \mathcal{X}$ ， $\mathcal{Y}_s = \mathcal{Y}_t = \mathcal{Y}$ 。

（2）边缘分布与条件分布偏移：由于工况与服役环境的改变，源域和目标域的特征边缘概率分布不相等，即 $P_s(X) \neq P_t(X)$ ；同时，在某些复杂退化模式下，相同的故障特征可能对应不同的故障严重程度，导致条件概率分布也可能存在差异，即 $P_s(Y|X) \neq P_t(Y|X)$ 。

在传统的深度学习诊断模型中，模型通常基于独立同分布假设。若直接将仅在 $\mathcal{D}_s$ 上训练的诊断模型 $f: \mathcal{X} \rightarrow \mathcal{Y}$ 应用于 $\mathcal{D}_t$ ，由于 $P_s(X) \neq P_t(X)$ 的存在，模型在目标域上的泛化误差将显著增加。

因此，基于域自适应的小样本气路故障诊断的核心目标是：在目标域有标签样本极其稀缺的限制下，充分利用源域丰富的带标签数据 $\mathcal{D}_s$ 和目标域的少标签数据 $\mathcal{D}_t^l$ ，学习到一个鲁棒的特征提取器 G_f 和故障分类器 G_y 。

为解决以上问题，思路之一是基于 $\mathcal{D}_s$ 和 $\mathcal{D}_t^l$ ，获取无标签数据集 $\mathcal{D}_t^u$ ，从而构建完备的目标域数据集 $\mathcal{D}_t$ ，便于后续 G_f 和 G_y 的训练。具体而言，本章在无监督的范式下，力求获取源域边缘分布 $P_s(X)$ 的表征方式；再将该先验特征空间作为优化起点，引入跨域知识迁移机制，利用 $\mathcal{D}_t^l$ 中极少量的观测样本及其标签信息，对先验

分布空间进行目标导向微调, 引导模型逼近目标域的条件概率分布 $P_t(X)$, 最终在极度数据不平衡与跨域偏移的双约束下, 实现数据增强。

4.3 域自适应算法原理

4.3.1 基于迁移学习与高斯混合变分自编码器的目标域故障样本生成方法

针对目标域故障样本稀缺导致诊断模型难以充分学习故障特征分布的问题, 本章提出一种结合高斯混合变分自编码器 (Gaussian Mixture Variational Autoencoder, GMVAE) 与迁移学习 (Transfer Learning, TL) 的目标域故障样本生成方法。该方法首先利用源域中较为丰富的健康运行样本学习发动机正常状态下气路参数的潜在分布结构与映射关系; 随后在保持健康状态特征表达能力的基础上, 引入目标域少量带标签故障样本对生成模型进行迁移微调, 使其能够在目标域分布约束下生成具有真实故障特征的扩展样本, 从而缓解小样本条件下诊断模型训练不足的问题。

所提方法包括两个阶段, 第一阶段为健康状态分布建模阶段。考虑到航空发动机正常运行数据相对充足, 且健康样本能够反映不同工况下气路参数之间的耦合关系, 本章首先利用健康样本训练 GMVAE 模型。设发动机正常运行状态下的气路参数样本服从分布 $P(x)$, 故障状态样本服从分布 $Q(x)$ 。虽然故障会引起部件性能突变或参数偏移, 使 $P(x)$ 与 $Q(x)$ 在概率密度上存在差异, 但故障样本本质上仍受发动机气动热力循环规律和部件耦合关系约束, 因此二者在潜在特征空间中具有一定共享结构。

在 GMVAE 中, 通过引入高斯混合先验对潜在空间进行建模, 使模型能够刻画多工况、多模态运行条件下的样本分布特征。相比传统 VAE 采用单一高斯先验, GMVAE 能够更好地描述航空发动机宽工况范围内由运行状态、控制规律和环境条件共同导致的复杂分布形态。因此, 第一阶段的目标是学习生成模型 $G(z; \theta)$, 使其输出尽可能逼近健康样本分布, 如式(4-1)所示:

$$\min_{\theta} D_{KL}(P(x) \| G(z; \theta)) \quad (4-1)$$

其中, z ——代表潜变量;

θ ——代表生成模型参数;

$D_{KL}(\cdot)$ ——代表 KL 散度。

通过该阶段训练, GMVAE 能够建立从潜在空间到健康气路参数空间的非线性映射关系, 为后续故障样本生成提供基础分布表达能力。

第二阶段为目标域故障迁移生成阶段。在完成健康状态 GMVAE 训练后，将第一阶段学习得到的编码器和生成器参数迁移至故障样本生成模型，并冻结部分关键参数，以保留模型已学习到的气路参数映射关系和健康状态分布结构。在此基础上，利用目标域少量带标签真实故障样本对模型进行微调，使模型参数由 θ 调整为 $\theta + \Delta\theta$ ，从而使生成分布由健康状态分布逐步向目标域故障状态分布迁移。该过程如式(4-2)所示：

$$\min_{\theta} D_{KL}(Q(x) \| G(z; \theta + \Delta\theta)) \quad (4-2)$$

其中， $Q(x)$ ——代表目标域故障样本分布；

$\Delta\theta$ ——代表参数修正量。

通过迁移微调，模型能够在保留发动机气路参数基本映射关系的同时，学习故障状态相对于健康状态的分布偏移特征，进而生成符合目标域特征分布的故障样本。需要指出的是，当源域健康样本与目标域故障样本在工况覆盖范围和特征分布上具有较高相似性时，迁移微调主要发生在生成模型输出层或少量高层特征映射层；当二者之间存在较明显域偏移时，则需要对更深层参数进行适度调整，以增强模型对目标域故障分布的适应能力。

最终，利用微调后的 GMVAE 生成模型扩充目标域故障样本集，并将生成样本与少量真实故障样本共同用于后续故障分类器训练。该框架能够在故障样本有限的情况下增强目标域故障特征空间覆盖能力，从而提高小样本气路故障诊断的精度和泛化能力，整体流程如图 4-1 所示。




图 4-1 基于 GMVAE-TL 的故障样本生成流程

4.3.2 基于高斯混合分布的变分自编码器生成模型

4.3.2.1 变分自编码器原理

变分自编码器 (Variational Autoencoder, VAE) 作为一种无监督生成模型, 将输入数据映射至潜在空间的高斯分布, 结合抽样引入随机性, 从而实现多样化样本的生成^[133]。假设输入层变量 x , $x \sim p_{\theta^*}(x|z)$, VAE 的目标在于构建隐空间连续随机变量 z , $z \sim p_{\theta}(z)$, 使得 $p_{\theta}(z|x) \cong q_{\phi}(z|x)$, 其中 $p_{\theta}(z|x)$ 是给定 x 后 z 的条件似然值。 $q_{\phi}(z|x)$ 即 $\min(D_{KL}(q_{\phi}(z|x) \| p_{\theta}(z|x)))$, 可化简为式(4-3)所示:

$$\begin{aligned} D_{KL}(q_{\phi}(z|x) \| p_{\theta}(z|x)) &= -\sum_z q_{\phi}(z|x) \log \left(\frac{p_{\theta}(z|x)}{q_{\phi}(z|x)} \right) \\ &= -\sum_z q_{\phi}(z|x) \log \left(\frac{p_{\theta}(x,z)}{p_{\theta}(x) \cdot q_{\phi}(z|x)} \right) \\ &= \log(p_{\theta}(x)) - \underbrace{\sum_z q_{\phi}(z|x) \left[\log \left(\frac{p_{\theta}(x,z)}{q_{\phi}(z|x)} \right) \right]}_{L(\theta, \phi; x)} \end{aligned} \quad (4-3)$$

由于 $D_{KL}(q_{\phi}(z|x) \| p_{\theta}(z|x)) \geq 0$, 因此 $\log(p_{\theta}(x)) \geq L(\theta, \phi; x)$, 称 $L(\theta, \phi; x)$ 是变分下界, 从而目标可等价于式(4-4)所示:

$$\min(D_{KL}(q_{\phi}(z|x) \| p_{\theta}(z|x))) \Leftrightarrow \max(L(\theta, \phi; x)) \quad (4-4)$$

将 $L(\theta, \phi; x)$ 进一步展开的结果如式(4-5)所示:

$$\begin{aligned} L(\theta, \phi; x) &= \sum_z q_{\phi}(z|x) \left[\log \left(\frac{p_{\theta}(x,z)}{q_{\phi}(z|x)} \right) \right] \\ &= \sum_z q_{\phi}(z|x) \left[\log(p_{\theta}(x|z)) + \log \left(\frac{p_{\theta}(z)}{q_{\phi}(z|x)} \right) \right] \\ &= \underbrace{-D_{KL}(q_{\phi}(z|x) \| p_{\theta}(z))}_{Loss 1} + \underbrace{E_{q_{\phi}(z|x)}[\log(p_{\theta}(x|z))]}_{Loss 2} \end{aligned} \quad (4-5)$$

其中, $Loss 1$ ——代表正则化损失;

$Loss 2$ ——代表重构损失。

在训练过程中, 对两个损失函数进一步细化的结果如式(4-6)、(4-7)所示, 便于后续网络中直接进行计算。

$$\begin{aligned} Loss 1 &= \int q_{\phi}(z|x) \log(p_{\theta}(z)) dz - \int q_{\phi}(z|x) \log(q_{\phi}(z|x)) dz \\ &= -0.5 E_{Z \sim N(z; \mu, \sigma^2)}[Z^2] + 0.5 \sum_{j=1}^J \log(\sigma_j^2) + 0.5 E_{Z \sim N(z; \mu, \sigma^2)} \left[\left(\frac{z - \mu}{\sigma} \right)^2 \right] \\ &= 0.5 \sum_{j=1}^J (1 + \log(\sigma_j^2) - \mu_j^2 - \sigma_j^2) \end{aligned} \quad (4-6)$$

$$Loss\ 2 = \frac{1}{L} \sum_{i=1}^L \|\hat{X} - X\|_2 \quad (4-7)$$

4.3.2.2 高斯混合模型原理

高斯混合模型（Gaussian Mixture Model, GMM）是一类典型的有限混合概率模型，其假设样本数据由若干高斯分量共同生成，并通过各高斯分量的加权叠加来近似整体概率密度分布。由于不同高斯分量能够刻画数据中的不同局部结构，相较于单一高斯分布，GMM 能够更灵活地描述多峰、非均匀及复杂形态的数据分布^[134]。

GMM 的主要参数包括各高斯组件的均值、协方差矩阵和混合权重，通常采用期望最大化（Expectation-Maximization, EM）算法进行估计。EM 算法包括期望步骤（E-step）和最大化步骤（M-step）：前者根据当前参数计算样本属于各高斯组件的后验概率，后者利用该后验概率更新各组件参数。通过迭代执行上述过程，模型逐步逼近样本的真实分布。

在样本生成时，GMM 首先根据混合权重选择一个高斯组件，再从该组件对应的高斯分布中采样得到新样本。给定观测数据，GMM 的采样过程如式(4-8)所示：

$$p(x) = \sum_{k=1}^K \pi_k N(x | \mu_k, \sigma_k) \quad (4-8)$$

其中， π_k ——代表第 k 个高斯分布的权重，满足 $\sum_{k=1}^K \pi_k = 1$ ；

$N(x | \mu_k, \sigma_k)$ 代表——第 k 个高斯分布。

4.3.2.3 高斯混合变分自编码器整体架构

GMVAE 与传统 VAE 的主要区别在于潜在空间建模方式。传统 VAE 通常假设潜在变量服从单一高斯分布，难以刻画多工况、多模态数据中的复杂分布特征；而 GMVAE 采用高斯混合分布对潜在空间进行建模，通过多个高斯分量分别描述不同运行状态或样本子群体，从而增强模型对复杂数据分布的表达能力。

GMVAE 整体结构如图 4-2 所示。该模型将 GMM 的多模态分布建模能力与 VAE 的生成机制相结合，引入离散隐变量表示样本所属高斯组件，并利用连续隐变量表征对应组件内的潜在特征。模型训练以最大化 $L(\theta, \phi, \pi; x)$ 为目标，同时优化编码器、解码器和高斯混合先验参数，具体过程如下。

在 GMVAE 中，假设潜变量 z 来自多个高斯分布的混合，如式(4-9)所示：

$$q(z|x) = \sum_{k=1}^K q(y=k|x)q(z|x, y=k) \quad (4-9)$$

其中, $q(y=k|x)$ ——代表生成数据属于第 k 个分布的概率;

$q(z|x, y=k)$ ——代表给定第 k 个分布时的高斯分布。

此时, GMVAE 中 $L(\theta, \phi, \pi; x)$ 化简过程如式(4-10)所示:

$$\begin{aligned} L(\theta, \phi, \pi; x) &= E_{q_f(z, y|x)} \left[\log \left(\frac{p_\theta(x, z, y)}{q_f(z, y|x)} \right) \right] \\ &= E_{q_f(y|x)} \{ E_{q_f(z|x, y)} [\log p_\theta(x|z) + \log p_\theta(z|y) \\ &\quad + \log p_\theta(y) - \log q_f(z|x, y) - \log q_f(y|x)] \} \\ &= E_{q_f(z|x)} \{ \log p_\theta(x|z) - \sum_{k=1}^N q_f(y=k|x) \\ &\quad [D_{KL}(q_f(z|x, y=k) \| p_\theta(z|y=k)) + \log \frac{q_f(y=k|x)}{\pi_k}] \} \end{aligned} \quad (4-10)$$

其中, $E_{q_\phi(z|x)} [\log p_\theta(x|z)]$ ——代表预测输出的重构误差。

KL 散度包括两部分, $D_{KL}(q_\phi(z|x, y=k) \| p_\theta(z|y=k))$ 用于衡量混合高斯

分布中各组件与变分分布的差异, $\log \frac{q_\phi(y=k|x)}{\pi_k}$ 用于衡量分量概率分布间的差异。




图 4-2 GMVAE 结构

4.3.3 迁移学习

迁移学习 (Transfer Learning, TL) 是一种面向小样本场景的模型训练方法, 其核心思想是将源域中已学习到的知识迁移至相关目标域, 以提升目标域模型的学习效果。通常情况下, 源域数据相对充足, 而目标域样本数量有限^[58]。通过将源域预训练模型的参数或特征表示作为目标域模型的初始化基础, 可以减少目标域训练对大量样本的依赖, 并提高模型在新环境下的适应能力^[135]。

对于航空发动机故障诊断而言, 受故障试验成本高、风险大以及发动机高可靠性运行特点影响, 真实故障样本往往难以获取^[136]。因此, 本章将正常发动机测量参数分布作为预训练对象, 首先学习健康状态下各气路参数之间的映射关系; 随后利用目标域少量故障样本对模型进行微调, 使其在保留正常气路参数关联结构的基础上, 引入故障偏移信息, 实现由健康状态分布向故障状态分布的迁移。该方法既降低了小样本条件下的训练难度, 也有助于提高目标域故障样本生成的合理性与诊断模型的泛化能力。

4.4 仿真试验与分析

本节通过仿真案例验证所提出域自适应故障样本生成方法的有效性, 并进一步分析生成样本对小样本气路故障诊断性能的提升作用。

4.4.1 模型设置与评价指标

4.4.1.1 模型超参数设置

在生成模型设计过程中, 超参数设置直接影响生成样本的准确性与多样性。阶段 1 主要用于学习正常样本的分布特征, 因此需要合理设置网络结构、激活函数以及 GMM 组件数。通常情况下, 深层网络具有更强的非线性表达能力, 但在小样本条件下也更容易出现过拟合, 导致生成样本多样性不足。综合考虑模型表达能力与小样本训练稳定性, 本节采用浅层全连接网络结构。在激活函数设置方面, 隐藏层采用 ReLU 函数, 以加快模型收敛并缓解梯度消失问题。由于阶段 1 的生成模型基于归一化后的正常样本训练, 输出层采用 Sigmoid 函数, 将生成结果限制在(0,1)范围内, 使其与数据预处理后的特征尺度保持一致, 从而提高生成精度。

GMM 组件数决定了潜在空间对复杂分布的刻画能力。组件数增加有助于提高模型对多模态分布的拟合能力, 但也会增加模型复杂度并带来过拟合风险。为在表达能力与模型复杂度之间取得平衡, 本节采用贝叶斯信息准则 (Bayesian Information Criterion, BIC) 选择 GMM 组件数。在组件数小于 20 的候选范围内,

通过 BIC 准则确定最优组件数，如式(4-11)所示：

$$BIC = k \ln(n) - 2\ln(L) \quad (4-11)$$

其中， k ——代表模型参数的数量；

n ——代表样本数量；

L ——代表模型的最大似然估计。

在阶段 2 中，所提方法利用少量目标域故障样本对阶段 1 预训练模型进行微调，从而构建故障样本生成模型。由于故障样本相对于正常样本存在明显偏移，其归一化结果可能超出(0,1)范围，若继续采用 Sigmoid 作为输出层激活函数，容易限制模型对故障偏移特征的表达。因此，在迁移学习阶段，本节将输出层激活函数替换为 LeakyReLU，以增强模型对故障样本分布扩展范围的适应能力。最终本节所提方法的参数设置如表 4-1 所示。

表 4-1 TL-GMVAE 模型超参数变设置

超参数	数值
编码器结构	特征输入层(特征维度)
	全连接层(15)
	Relu 层
	全连接层((2*潜在维度+1)*组件数)
解码器结构	GMM 采样层
	特征输入层(潜在维度)
	全连接层(15)
	Relu 层
	全连接层(特征维度)
正常样本个数	Sigmoid层/LeakyRelu层
	100000
Batch尺寸	256
潜在维度	20
训练过程Epochs	50
微调过程Epochs	30
训练过程学习率	0.005
微调过程学习率	0.001
求解器	Adam

4.4.1.2 生成样本质量评估指标

生成样本质量直接影响后续故障分类器的训练效果。若生成样本与真实目标域故障样本分布差异过大,可能引入错误故障特征,降低诊断模型判别能力;若生成样本多样性不足,则难以有效扩展故障样本空间,无法充分缓解小样本条件下分类边界学习不足的问题。因此,本章从样本准确性和样本多样性两个方面评价生成样本质量。

(1) 样本准确性

样本准确性用于衡量生成样本与真实样本之间的相似程度。欧氏距离 (Euclidean Distance, E_D) 是数值型样本间最为常用的相似度度量指标^[137]。 E_D 的计算方式如式(4-12)所示:

$$E_D = \|X - Y\|_2 = \sqrt{\sum_{d=1}^n (X_d - Y_d)^2} \quad (4-12)$$

其中, X ——代表理想情况下各个种类的样本数据集;

Y ——代表生成的故障样本;

X_d ——代表样本 X 第 d 维特征;

Y_d ——代表样本 Y 的第 d 维特征。

通过计算生成样本与真实样本之间的最小欧氏距离,可评价生成样本对真实故障样本空间的逼近程度。后续讨论中引入了 E_D 的统计特性,包括均值、极值和方差,以综合评估生成样本的整体偏差和生成稳定性。

(2) 样本多样性

样本多样性用于衡量生成样本对真实样本分布范围的覆盖程度。对于航空发动机气路数据而言,真实样本通常分布在一定运行包线范围内,若生成样本过于集中,即使其局部误差较小,也难以充分表征不同工况下的状态变化^[138]。因此,本节通过比较生成样本与真实样本在各监测变量维度上的取值范围重叠程度,评价生成模型的样本多样性。

设真实正常样本集为 $X^{real} = \{x_1^{real}, x_2^{real}, \dots, x_N^{real}\}$, 生成样本集为 $X^{gen} = \{x_1^{gen}, x_2^{gen}, \dots, x_M^{gen}\}$, 其中, N 和 M 分别表示真实样本和生成样本的数量,每个样本均包含 K 个监测变量。对于第 k 个监测变量,真实样本的取值范围可表示为 $[x_{k,min}^{real}, x_{k,max}^{real}]$, 生成样本在该变量上的取值范围可表示为 $[x_{k,min}^{gen}, x_{k,max}^{gen}]$ 。为了衡量生成样本在该变量维度上对真实样本取值范围的覆盖程度,首先计算二者取值区间的重叠长度,如式(4-13)所示:

$$L_k = \max(0, \min(x_{k,max}^{gen}, x_{k,max}^{real}) - \max(x_{k,min}^{gen}, x_{k,min}^{real})) \quad (4-13)$$

其中, L_k ——代表生成样本与真实样本在第 k 个变量上的有效重叠区间长度。当两个区间不存在重叠时, $L_k = 0$ 。

真实样本在第 k 个变量上的完整取值范围定义如式(4-14):

$$R_k = x_{k,\max}^{real} - x_{k,\min}^{real} \quad (4-14)$$

则生成样本在第 k 个变量上的覆盖率定义为式(4-15):

$$C_k = \frac{L_k}{R_k} \quad (4-15)$$

其中, C_k ——代表生成样本对真实正常样本在第 k 个监测变量上的覆盖程度。

进一步地, 为综合评价生成样本在所有监测变量维度上的整体覆盖能力, 定义平均覆盖率如式(4-16):

$$C = \frac{1}{K} \sum_{k=1}^K C_k \quad (4-16)$$

其中, C ——代表生成样本多样性的综合评价指标。

当 C 越接近 1 时, 说明生成样本在多个监测变量维度上均能较好覆盖真实正常样本的取值范围, 具有较好的样本多样性和工况适应能力; 当 C 较小时, 说明生成样本覆盖范围有限, 模型可能仅学习到了真实样本分布中的局部特征, 难以充分反映正常运行状态下的多工况变化特征。

4.4.2 样本生成质量评估

正常样本生成器是后续故障样本生成模型的预训练基础, 其生成质量会直接影响迁移学习生成效果和故障分类器训练性能。同时, 对生成故障样本的有效性和统计特性进行评估, 也有助于判断其是否能够扩展目标域故障特征空间。因此, 本节从生成精度和分布覆盖能力两个方面, 对所提方法的样本生成质量进行分析评估。

4.4.2.1 正常样本生成精度评估

为验证 GMVAE 对正常样本分布的建模与生成能力, 本节以归一化后的正常运行样本为参考, 对生成样本的精度和分布一致性进行评估。模型训练完成后, 利用 GMVAE 生成 1000 个模拟正常运行样本, 并与传统 VAE 的生成结果进行对比。两种模型生成样本相对于真实正常样本的最大误差、最小误差、平均误差和误差方差如表 4-2 所示。

表 4-2 GMVAE 与 VAE 样本生成精度的欧氏距离统计特性比较

模型	最大误差	最小误差	平均误差	方差
GMVAE	8.9×10^{-2}	4.2×10^{-3}	4.4×10^{-2}	3.6×10^{-4}
VAE	8.6×10^{-2}	1.1×10^{-2}	5.6×10^{-2}	2.5×10^{-4}

由表 4-2 可知, GMVAE 生成样本的平均误差为 4.4×10^{-2} , 低于 VAE 的 5.6×10^{-2} , 表明 GMVAE 生成样本在整体上更接近真实正常样本分布。同时, GMVAE 的最小误差为 4.2×10^{-3} , 小于 VAE 的 1.1×10^{-2} , 表明 GMVAE 能够生成与真实样本高度接近的局部样本点。虽然 GMVAE 的最大误差和方差略高于 VAE, 但在平均误差更低的情况下, 这更多反映出 GMVAE 具有更强的分布扩展能力, 能够覆盖正常样本中的边界工况和极限工况区域。

为进一步分析生成样本与真实正常样本在不同变量维度上的统计一致性, 本节计算了二者在各维度上的均值、方差和偏度, 结果如表 4-3 所示。可以看出, GMVAE 生成样本在各变量维度上的均值与真实样本较为接近, 说明其能够较好保持真实数据的分布中心; 生成样本方差与真实样本基本一致, 表明模型能够刻画正常样本在不同工况下的离散程度; 生成样本偏度与真实样本也保持相近变化趋势, 说明 GMVAE 不仅能够拟合一阶和二阶统计特征, 也能够一定程度上保持样本分布的非对称性。

表 4-3 GMVAE 生成正常样本与真实正常样本统计特性比较

统计特性	均值		方差		偏度	
	原始数据	生成数据	原始数据	生成数据	原始数据	生成数据
N1	0.51	0.49	0.07	0.06	0.06	0.02
N2	0.44	0.42	0.06	0.05	0.22	0.18
Pt25	0.38	0.36	0.06	0.05	0.24	0.27
Tt25	0.38	0.36	0.06	0.05	0.29	0.27
Pt3	0.45	0.44	0.06	0.05	0.26	0.25
Tt3	0.18	0.18	0.03	0.03	2.04	2.13
Pt5	0.18	0.16	0.03	0.02	1.60	1.76
Tt5	0.15	0.14	0.03	0.02	1.61	1.81

图 4-3 和图 4-4 分别给出了 VAE 与 GMVAE 生成的前 100 个正常样本在 8 个变量维度上与真实样本的对比结果。由图 4-3 可见, VAE 生成样本虽然在部分变量上能够跟随真实样本的总体变化趋势, 但分布范围相对有限, 部分样本集中于局部区域, 未能充分覆盖真实正常样本的主要取值区间。这说明传统 VAE 在单一高斯潜空间先验约束下, 对多工况正常样本全局分布的刻画能力仍存在不足。




图 4-3 VAE 生成正常样本与真实正常样本对比




图 4-4 GMVAE 生成正常样本与真实正常样本对比

相比之下, 由图 4-4 可见, GMVAE 生成样本与真实样本在各变量维度上具有更一致的分佈形态。生成样本能够较好覆盖真实样本的主要变化范围, 说明 GMVAE 不仅能够生成接近真实样本的局部点, 也能够覆盖正常样本分佈中的不同运行状态区域。表 4-4 进一步给出了两种模型的覆盖率对比结果, GMVAE 在 8 个变量维度上的覆盖率均高于 VAE, 平均覆盖率达到 0.93, 高于 VAE 的 0.86, 进一步证明了 GMVAE 在样本分佈覆盖能力方面的优势。

分析可知, 上述差异主要源于两种模型的潜空间建模方式不同。传统 VAE 通常采用单一标准正态分佈作为潜空间先验, 难以刻画正常样本在多工况、多状

态下的多峰分布特征,生成样本容易集中于局部高概率区域,导致覆盖能力不足。相比之下,GMVAE采用高斯混合分布对潜在空间建模,能够将样本分布划分为多个潜在子区域,并从不同高斯成分中采样,从而增强模型对复杂多模态分布的表达能力和样本覆盖能力。

表 4-4 GMVAE 与 VAE 生成正常样本覆盖率对比

模型	N1	N2	Pt25	Tt25	Pt3	Tt3	Pt5	Tt5
GMVAE覆盖率	0.93	0.92	0.97	0.94	0.93	0.98	0.92	0.86
VAE覆盖率	0.91	0.86	0.93	0.87	0.85	0.81	0.87	0.80

4.4.2.2 故障样本生成精度评估

为验证 TL-GMVAE 在小样本故障条件下的生成能力,本节分别设置每类故障真实样本数量为 1、10 和 100 三种情况,并针对 Fan、HPC、HPT 和 LPT 四类典型部件故障各生成 1000 个故障样本。表 4-5 给出了不同样本数量条件下四类故障生成样本的 E_D 统计结果。

表 4-5 不同故障样本数量下生成样本的欧氏距离统计

故障类型	故障样本数量	最大误差	最小误差	平均误差	方差
Fan	1	1.4×10^{-1}	1.9×10^{-2}	7.6×10^{-2}	5.2×10^{-4}
	10	1.2×10^{-1}	2.1×10^{-2}	8.8×10^{-2}	4.1×10^{-4}
	100	1.3×10^{-1}	1.9×10^{-2}	8.2×10^{-2}	4.7×10^{-4}
HPC	1	1.2×10^{-1}	1.6×10^{-2}	8.8×10^{-2}	5.3×10^{-4}
	10	1.2×10^{-1}	2.1×10^{-2}	9.0×10^{-2}	4.0×10^{-4}
	100	1.4×10^{-1}	2.3×10^{-2}	8.2×10^{-2}	4.3×10^{-4}
HPT	1	1.2×10^{-1}	1.3×10^{-2}	8.0×10^{-2}	5.8×10^{-4}
	10	1.3×10^{-1}	3.4×10^{-2}	8.9×10^{-2}	3.4×10^{-4}
	100	1.3×10^{-1}	1.8×10^{-2}	8.1×10^{-2}	4.4×10^{-4}
LPT	1	1.3×10^{-1}	8.2×10^{-3}	8.9×10^{-2}	4.8×10^{-4}
	10	1.4×10^{-1}	2.1×10^{-2}	8.8×10^{-2}	4.3×10^{-4}
	100	1.2×10^{-1}	2.3×10^{-2}	7.9×10^{-2}	4.2×10^{-4}

由表 4-5 可知,在不同故障类型和不同真实故障样本数量条件下,TL-GMVAE 生成样本均保持较低误差水平,所有实验中的最大 E_D 均被控制在了 1.4×10^{-1} 以内,表明生成样本未出现明显的异常离群现象。其中当故障样本个数为 1 时,四类故障的平均 E_D 为 8.3×10^{-2} ;当故障样本个数为 10 时,四类故障的平均 E_D 为 8.9×10^{-2} ;当故障样本个数为 100 时,四类故障的平均 E_D 为 8.1×10^{-2} 。整体来看,三种样本条件下的平均误差均处于较低水平且差异不大,表明 TL-GMVAE 在极少故障样本约束下仍能够生成与真实故障样本较为接近的样本。

为更直观地分析不同样本数量下的生成效果,图 4-5 和图 4-6 分别展示了故障样本数量为 1 和 100 时,TL-GMVAE 生成 Fan 故障样本与真实故障样本在各监测变量维度上的对比结果。由图 4-5 可见,当仅使用 1 个真实 Fan 故障样本进行迁移微调时,生成样本主要集中在该样本附近,并在多数变量维度上与真实样本具有一定重合。这说明模型能够学习少量样本所包含的局部故障特征,但由于目标域故障信息有限,生成样本取值范围较窄,更多体现为对局部故障邻域的扩展,尚难以完整覆盖全局故障分布。




图 4-5 故障样本个数为 1 时 TL-GMVAE 生成 Fan 故障与真实故障样本对比

相比之下,由图 4-6 可见,当故障样本数量增加至 100 时,生成样本在各监测变量维度上的取值范围明显扩大,不再局限于少量真实样本附近的局部区域,而是能够较好覆盖真实故障样本的主要变化范围。尤其在 N1、N2、Pt25、Tt25、Pt3 等变量上,生成样本表现出更宽的分布区间和更高的重合程度。说明随着可用故障样本数量增加,模型能够获得更充分的故障分布信息,进而学习更完整的故障变化边界,使生成样本由局部邻域扩展逐渐转向对真实故障分布的有效覆盖。

为说明真实故障样本对生成结果的约束作用,本节对不同样本数量条件下的原始故障样本分布进行分析。当故障样本数量为 1 时,模型可利用的目标域故障信息仅来自单个样本点。该 Fan 故障样本在各监测变量上的归一化取值分别为:

$N1=0.69$ 、 $N2=0.58$ 、 $Pt25=0.44$ 、 $Tt25=0.48$ 、 $Pt3=0.56$ 、 $Tt3=0.24$ 、 $Pt5=0.23$ 、 $Tt5=0.24$ 。在这种情况下,生成模型只能围绕该单一故障点学习局部邻域特征,因此生成样本主要表现为在该样本取值附近的上下波动,分布范围相对有限。




图 4-6 故障样本个数为 100 时 TL-GMVAE 生成 Fan 故障与真实故障样本对比

当故障样本数量增加至 100 时,原始故障样本本身已能够提供更丰富的目标域故障分布信息。图 4-7 展示了 100 个真实 Fan 故障样本在各监测变量维度上的分布情况。可以看出,不同变量的取值范围和离散程度存在明显差异,说明真实故障样本并非集中于单一点附近,而是在目标域故障状态下形成了一定的分布区间。因此,TL-GMVAE 在迁移微调过程中能够学习到更完整的故障变化边界,使生成样本分布与原始故障样本分布表现出更强的一致性。该结果表明,真实故障样本数量不仅影响生成样本覆盖范围,也决定了生成模型对目标域故障分布的表达能力。




图 4-7 故障样本个数为 100 时随机选择的真实故障样本分布

表 4-6 进一步量化了三种故障样本数量下各维度覆盖率,结果与图 4-5 和图 4-6 中展示一致。当每类故障仅有 1 个真实样本时,生成样本的覆盖率相对有限,Fan、HPC、HPT 和 LPT 四类故障的平均覆盖率分别为 0.47、0.39、0.44 和 0.34。

随着可用故障样本数量增加,各故障类型的平均覆盖率均有所提升。最终当样本数量进一步增加至 100 时, Fan、HPC、HPT 和 LPT 四类故障的平均覆盖率分别达到 0.88、0.79、0.83 和 0.83。进一步印证了目标域故障样本数量的增加能够显著增强模型对故障分布范围的刻画能力。

表 4-6 不同故障样本数量下生成样本覆盖率

故障类型	故障样本数量	N1	N2	Pt25	Tt25	Pt3	Tt3	Pt5	Tt5	平均覆盖率
Fan	1	0.45	0.36	0.48	0.45	0.50	0.55	0.50	0.50	0.47
	10	0.98	0.90	0.82	0.84	0.90	0.80	0.36	0.36	0.74
	100	0.96	0.94	0.98	0.92	1.00	0.66	0.81	0.75	0.88
HPC	1	0.30	0.23	0.42	0.26	0.39	0.72	0.37	0.39	0.39
	10	0.70	0.76	0.88	0.90	0.57	0.48	0.70	0.69	0.71
	100	0.90	0.86	0.94	0.87	0.96	0.53	0.68	0.59	0.79
HPT	1	0.56	0.49	0.48	0.46	0.56	0.23	0.36	0.38	0.44
	10	0.93	0.78	0.83	0.86	0.75	0.41	0.74	0.65	0.75
	100	1.00	0.93	0.88	0.85	0.87	0.90	0.63	0.57	0.83
LPT	1	0.30	0.32	0.38	0.32	0.43	0.55	0.21	0.21	0.34
	10	0.91	0.79	0.61	0.77	0.76	0.48	0.51	0.55	0.67
	100	0.96	0.87	0.97	0.87	0.97	0.64	0.77	0.61	0.83

4.4.3 基于生成故障样本的诊断性能验证分析

4.4.2 节从生成样本自身出发,分析了正常样本和故障样本的生成精度、分布覆盖能力及统计一致性,验证了所提方法在样本生成层面的有效性。然而,本章方法的最终目标并非单纯生成与真实样本相近的数据,而是通过生成故障样本扩充目标域故障训练集,从而提升小样本条件下气路故障诊断模型的检测与隔离能力。因此,本节进一步从诊断任务角度分析生成样本对故障诊断性能的实际贡献。

本节沿用第 3 章中的两阶段诊断思路,即先进行故障检测,判断样本是否处于故障状态;再对故障样本进行故障隔离,识别其具体故障类型。为全面评估生成样本对不同诊断策略的影响,本节设计了三类对比方法:第一类为残差-双任务自编码器(Residual-DTAE, R-DTAE)方法,即利用 GMVAE 输入与输出之间的重构残差构造故障敏感特征,并基于 DTAE 完成检测与隔离;第二类为原始气路参数-

双任务自编码器 (Raw Data-DTAE, RD-DTAE) 方法, 即直接以原始气路参数作为输入训练两阶段 DTAE 模型; 第三类为原始气路参数-随机森林 (Raw Data-Random Forest, RD-RF) 方法, 即直接基于原始气路参数训练随机森林检测模型和隔离模型, 作为传统机器学习对比基准。通过上述方法对比, 可同时分析生成样本增强、GMVAE 残差特征构造以及 DTAE 诊断模型对小样本气路故障诊断性能的影响。

为验证生成样本在不同小样本条件下的有效性, 本节分别设置每类故障真实样本数量为 1、10 和 100 三种情况, 并比较原始小样本训练集与生成增强训练集下的诊断结果。评价指标采用 3.4.2.2 节定义的 FAR、DR 和 IR, 具体结果如表 4-7 所示。

表 4-7 生成样本增强前后的故障诊断性能对比

诊断方法	每类故障样本数	训练方式	FAR/%	DR/%	IR/%
R-DTAE	1	增强前	3.20	6.94	19.08
R-DTAE	1	增强后	7.65	18.71	34.61
R-DTAE	10	增强前	4.83	26.21	38.21
R-DTAE	10	增强后	7.05	32.50	55.73
R-DTAE	100	增强前	4.03	51.18	44.60
R-DTAE	100	增强后	7.35	68.30	60.91
RD-DTAE	1	增强前	1.73	2.70	28.27
RD-DTAE	1	增强后	6.38	13.56	34.56
RD-DTAE	10	增强前	2.25	2.46	21.60
RD-DTAE	10	增强后	6.50	15.03	34.44
RD-DTAE	100	增强前	13.40	28.15	31.22
RD-DTAE	100	增强后	14.33	47.13	37.92
RD-RF	1	增强前	1.33	1.43	28.80
RD-RF	1	增强后	6.83	9.70	28.00
RD-RF	10	增强前	6.15	8.03	24.50
RD-RF	10	增强后	10.63	12.76	26.55
RD-RF	100	增强前	9.63	16.72	27.48
RD-RF	100	增强后	13.68	21.39	30.39

由表 4-7 可知, 引入生成故障样本后, 三类诊断方法的 DR 整体均有所提升, 说明生成样本能够扩充小样本条件下的故障特征空间, 为故障检测模型提供更充分的异常状态信息。以 R-DTAE 为例, 当每类故障样本数量为 1、10 和 100 时, DR 分别由增强前的 6.94%、26.21%和 51.18%提高至 18.71%、32.50%和 68.30%。这表明生成样本在不同样本规模下均能提升模型对故障状态的识别能力, 尤其在真实故障样本极少时, 能够一定程度上缓解训练样本不足导致的检测能力下降问题。

从故障隔离结果来看, R-DTAE 在样本增强后同样取得明显提升。当每类故障样本数量为 1、10 和 100 时, IR 分别由 19.08%、38.21%和 44.60%提高至 34.61%、55.73%和 60.91%。这说明生成故障样本不仅有助于检测模型学习正常/故障差异, 也能为隔离模型提供更丰富的类别特征信息, 从而改善不同故障类型之间的区分能力。

比较 R-DTAE 与 RD-DTAE 可以发现, 在相同 DTAE 诊断框架下, R-DTAE 整体优于直接使用原始气路参数的 RD-DTAE。以 100 个样本增强后的结果为例, R-DTAE 的 DR 和 IR 分别为 68.30%和 60.91%, 而 RD-DTAE 分别为 47.13%和 37.92%。这说明 GMVAE 重构残差特征对诊断性能提升具有重要作用。其原因在于, GMVAE 主要学习正常状态下气路参数之间的潜在耦合关系, 当故障样本输入模型后, 故障引起的异常偏移难以被正常分布模型完全重构, 从而在输入与输出之间形成明显残差。相比原始气路参数, 残差特征能够削弱工况变化和参数绝对幅值差异的影响, 更集中地反映故障相对于正常状态的偏离程度。

RD-RF 的结果进一步说明了诊断模型结构对小样本任务的影响。虽然 RD-RF 在加入生成样本后 DR 和 IR 也有所提高, 例如 100 个样本条件下 DR 由 16.72%提高至 21.39%, IR 由 27.48%提高至 30.39%, 但整体性能明显低于 RD-DTAE 和 R-DTAE。这表明, 相较于传统随机森林, DTAE 能够更有效地提取故障相关深层特征, 提高小样本条件下的表达能力和泛化能力。

需要注意的是, 样本增强在提升 DR 和 IR 的同时, 也导致 FAR 有所上升。例如, R-DTAE 在 1、10 和 100 个样本条件下, FAR 分别由 3.20%、4.83%和 4.03%上升至 7.65%、7.05%和 7.35%。这表明生成样本增强提高了模型对故障状态的敏感性, 但也可能使部分正常样本更接近故障判别边界, 从而带来一定误警增加。因此, 在实际应用中, 需要在故障检出能力与虚警控制之间进行权衡。

4.4.4 各类数据增强算法性能对比分析

为进一步验证所提 TL-GMVAE 方法的有效性, 本节选取基于变换的数据增强

方法 (Transformation-based Data Augmentation, TBDA)^[140]、VAE、TL-VAE 和 TL-GMVAE 进行对比。其中, TBDA 主要通过随机加噪和样本间插值实现样本扩展。基于 4.4.2.2 节的实验设置, 分别在每类故障样本数量为 1、10 和 100 的条件下开展数据增强实验, 并以平均误差和平均覆盖率作为主要评价指标, 结果如表 4-8 所示。

表 4-8 不同数据增强模型的欧氏距离统计特性

方法	每类故障样本数	平均误差	平均覆盖率
TBDA	1	2.4×10^{-2}	0.12
VAE	1	3.1×10^{-2}	0.01
TL-VAE	1	1.0×10^{-1}	0.30
TL-GMVAE	1	8.3×10^{-2}	0.40
TBDA	10	7.5×10^{-2}	0.69
VAE	10	8.4×10^{-2}	0.71
TL-VAE	10	1.3×10^{-1}	0.98
TL-GMVAE	10	8.9×10^{-2}	0.98
TBDA	100	9.1×10^{-2}	0.96
VAE	100	8.3×10^{-2}	0.73
TL-VAE	100	9.5×10^{-2}	0.94
TL-GMVAE	100	8.1×10^{-2}	0.95

在每类故障样本数量为 1 时, TBDA 的平均误差最低, 为 2.4×10^{-2} , 但平均覆盖率仅为 0.12; VAE 的平均误差 3.1×10^{-2} , 但平均覆盖率仅为 0.01。该结果表明, TBDA 和 VAE 在单样本条件下虽然能够生成与已有样本较为接近的数据, 但生成样本主要集中在极窄的局部区域内, 对真实故障分布的覆盖能力明显不足。相比之下, TL-VAE 和 TL-GMVAE 的平均覆盖率分别提高至 0.30 和 0.40, 说明迁移学习能够利用正常样本中蕴含的气路参数分布规律和少量目标域故障信息, 扩展生成样本的分布范围。其中, TL-GMVAE 的平均误差为 8.3×10^{-2} , 低于 TL-VAE 的 1.0×10^{-1} , 且覆盖率更高, 表明高斯混合潜空间在极小样本条件下能够进一步改善生成样本的分布表达能力。

当每类故障样本数量增加至 10 时, 各方法的覆盖能力均有所提升。TBDA 和 VAE 的平均覆盖率分别达到 0.69 和 0.71, 说明随着真实故障样本数量增加, 简单

变换方法和普通 VAE 均能获得一定的分布扩展能力,但其覆盖率仍低于 TL-VAE 和 TL-GMVAE,表明迁移学习机制在小样本条件下仍具有明显优势。

当每类故障样本数量增加至 100 时,各方法性能差异进一步体现。TBDA 的平均覆盖率达到 0.96,说明在样本数量增加后,基于变换的增强方法能够覆盖较大的取值范围,但其平均误差为 9.1×10^{-2} ,高于 TL-GMVAE 的 8.1×10^{-2} 。VAE 的平均误差为 8.3×10^{-2} ,与 TL-GMVAE 较为接近,但平均覆盖率仅为 0.73,说明其生成样本仍存在覆盖不足。TL-VAE 的平均覆盖率为 0.94,但平均误差为 9.5×10^{-2} 。相比之下,TL-GMVAE 在 100 样本条件下取得最低平均误差 8.1×10^{-2} ,同时保持 0.95 的较高平均覆盖率,说明其在生成精度与分布覆盖能力之间取得了更好的平衡。

综合不同样本数量条件下的对比结果可知,不同数据增强方法具有明显差异。TBDA 主要依赖已有样本的局部扰动,在极小样本条件下误差较低,但覆盖范围有限;样本数量增加后覆盖率明显提高,但由于缺乏对气路参数复杂耦合关系的建模能力,生成误差仍相对较高。VAE 能够通过潜变量采样扩展样本,但受单一高斯潜空间先验限制,难以充分表达航空发动机多工况、多模态故障分布,因此覆盖能力不足。TL-VAE 通过迁移学习提高了样本覆盖率,但其潜空间仍为单峰结构,生成误差控制能力有限。

相比之下,TL-GMVAE 在不同小样本条件下均表现出较好的综合生成性能。一方面,迁移学习机制使模型能够利用源域正常样本和少量目标域故障样本实现故障分布适应;另一方面,高斯混合潜空间能够刻画多工况条件下的潜在子分布结构,增强模型对复杂故障分布的表达能力。因此,TL-GMVAE 能够在故障样本生成精度与分布覆盖能力之间取得较优平衡。

4.5 本章小结

本章围绕小样本条件下航空发动机气路故障诊断问题,提出了一种基于 TL-GMVAE 的故障样本生成与诊断增强方法。针对目标域故障样本稀缺、源域与目标域分布存在差异的问题,本章首先利用正常样本训练 GMVAE 模型,学习发动机正常状态下气路参数之间的潜在耦合关系;随后结合少量目标域故障样本进行迁移微调,使模型能够生成具有目标域故障分布特征的扩展样本。

在方法设计方面,本章将迁移学习与高斯混合变分自编码器相结合,利用高斯混合潜空间刻画多工况条件下气路数据的多模态分布特征,并通过迁移微调实现由正常状态分布向目标域故障状态分布的适应。相比传统 VAE 的单一高斯潜空间,TL-GMVAE 能够更好地表达多工况下的复杂分布结构;相比普通生成方法,其能

够利用少量目标域故障样本引导生成分布迁移，从而提高生成样本对目标域故障特征的适应性。

在仿真验证方面，本章首先对正常样本和故障样本的生成质量进行了分析。结果表明，GMVAE 相比传统 VAE 能够更好地表征正常样本的多工况分布；TL-GMVAE 在每类故障样本数量为 1、10 和 100 的条件下，均能够生成具有一定真实性和覆盖能力的故障样本，且随着真实故障样本数量增加，生成样本覆盖范围进一步拓宽、分布一致性逐步提升。进一步地，本章将生成样本引入第 3 章所采用的两阶段故障诊断框架中，结果表明，生成样本能够提升小样本条件下的故障检测率和故障隔离率；同时，与 TBDA、VAE 和 TL-VAE 等数据增强方法相比，TL-GMVAE 在生成误差和覆盖率之间取得了更好的平衡。

第5章 基于退化特征增强的剩余使用寿命预测方法研究

5.1 本章引论

剩余使用寿命 (Remaining Useful Life, RUL) 预测的核心在于建立发动机监测数据、退化状态与寿命标签之间的映射关系。然而,在实际运行过程中,航空发动机长期处于多工况、强耦合和复杂任务环境下,其监测参数不仅受到部件性能退化的影响,还受到环境条件、控制指令和个体差异等因素的共同作用。若直接利用原始传感器数据进行 RUL 预测,模型容易将工况变化或个体差异误判为退化信息,导致退化表征不准确、预测稳定性下降^[142]。因此,如何从复杂运行数据中提取能够真实反映性能劣化过程的退化特征,是提高 RUL 预测精度的关键。

第2章构建的 PPM 能够为目标发动机提供个性化性能基准,为本章退化特征构建提供基础。但与性能监视不同,RUL 预测更关注退化信息的显式保留。若继续采用退化旁路对长期退化偏差进行补偿,真实退化趋势可能被模型吸收,反而削弱寿命预测所需的退化表征。因此,本章在继承第2章 PBM 和未建模旁路思想的基础上,仅保留未建模旁路以补偿个体差异,并去除退化旁路,使实测值与健康基准之间的残差能够直接表征性能退化程度。

基于此,本章提出一种基于退化特征增强的 RUL 预测方法。首先,利用数据驱动 PBM 和未建模旁路构建目标发动机的个性化健康参考模型,并将模型残差作为退化特征;随后,采用金字塔时间卷积网络提取多尺度时序退化信息,并引入融合互补注意力机制,分别从时间维度和变量维度强化关键退化阶段与敏感监测参数,最终实现复杂运行条件下的 RUL 预测。

本章结构安排如下:5.1 节给出本章引论;5.2 节定义航空发动机 RUL 预测问题;5.3 节介绍基于融合互补注意力的金字塔时间卷积网络 RUL 预测方法;5.4 节基于 N-CMAPSS 数据集开展仿真验证;5.5 节对本章研究内容进行总结。

5.2 航空发动机 RUL 预测问题定义

本节对航空发动机 RUL 预测任务进行形式化描述。给定某台发动机在连续飞行循环内采集的多维监测序列,RUL 预测的目标是根据当前及历史状态估计其距离失效时刻的剩余飞行循环数。与一般时间序列预测不同,RUL 预测的输出不是下一时刻传感器值,而是与健康状态演化相关的寿命标签。因此,本节首先定义

RUL 标签形式, 随后给出基于个性化健康基准的退化特征构建方法, 最后将 RUL 预测问题表示为退化特征序列到寿命标签之间的非线性映射。

5.2.1 剩余使用寿命标签定义

设某台发动机在全寿命周期内共经历 T 个飞行循环, 第 t 个飞行循环对应的多维监测数据表示为: $\mathbf{x}_t = [x_t^1, x_t^2, \dots, x_t^K]$, 其中 K 表示监测变量数量, $\mathbf{x}_t$ 包含环境条件、控制变量以及气路传感器测量参数等信息。对于第 t 个飞行循环, 其 RUL 可定义为当前循环距离失效循环之间的剩余循环数, 如式(5-1)所示:

$$RUL_t = T - t \quad (5-1)$$

其中, T ——代表发动机达到寿命终止状态时对应的飞行循环编号。

在实际建模中, 发动机早期健康阶段通常尚未出现明显退化, 不同飞行循环之间的传感器响应差异较小。若直接采用完整线性下降的 RUL 标签, 模型可能过度关注早期健康阶段的寿命数值差异, 而削弱对退化阶段寿命变化规律的学习^[144]。因此, 通常对 RUL 标签进行截断处理, 如式(5-2)所示:

$$y_t = \min(RUL_t, RUL_{\max}) \quad (5-2)$$

其中, $RUL_{\max}$ ——代表预设的最大寿命上限;

y_t ——代表模型训练所使用的 RUL 标签;

经过截断后, 早期健康阶段的寿命标签保持恒定, 退化阶段的寿命标签随飞行循环增加逐渐下降, 使模型更加关注退化显现后的寿命衰减过程。

5.2.2 基于健康基准的退化特征构建

对于航空发动机 RUL 预测, 模型输入特征应尽可能反映发动机自身性能状态的变化, 而不是外部工况或控制条件的波动。原始传感器数据同时包含工况响应、控制调节、个体差异和部件退化信息, 这些因素在观测空间中相互耦合, 使退化特征难以直接分离。因此, 本章不直接将原始气路参数作为寿命预测输入, 而是基于健康基准提取残差形式的退化特征。

设第 t 个飞行循环下, 用于表征发动机性能状态的实际气路测量参数为 $\mathbf{z}_t = [z_t^1, z_t^2, \dots, z_t^M]$, 其中, M 表示参与退化表征的气路监测参数数量。在相同工况条件下, 健康基准模型对气路参数的预测输出为 $\hat{\mathbf{z}}_t = [\hat{z}_t^1, \hat{z}_t^2, \dots, \hat{z}_t^M]$, 则第 t 个飞行循环的退化残差特征定义如式(5-3)所示:

$$\mathbf{r}_t = \mathbf{z}_t - \hat{\mathbf{z}}_t = [r_t^1, r_t^2, \dots, r_t^M] \quad (5-3)$$

其中, r_t^m ——代表第 m 个监测参数相对于健康基准的偏离程度。

此时残差 r_t 可用于描述发动机实际状态相对于健康基准的退化偏移。需要说明的是, 本章在构建健康基准时借鉴第2章 PPM 的建模思想, 但仅保留未建模旁路, 不引入退化旁路。原因在于, 退化旁路会对随飞行循环累积的性能衰退进行补偿, 使模型输出过度贴近退化后的实际状态, 从而削弱残差对退化过程的表征能力。保留未建模旁路则可补偿初始个体差异, 使残差更加集中反映性能退化信息。

5.2.3 基于退化特征序列的 RUL 预测问题形式化

发动机退化是随飞行循环逐渐累积的动态过程。单个循环的退化残差只能反映当前时刻相对于健康基准的偏离程度, 难以完整描述退化趋势、变化速率和阶段性演化规律。因此, 在构建 RUL 预测样本时, 需要将连续多个飞行循环的退化残差组织为时序输入。

设时间窗口长度为 L , 则以第 t 个周期为预测时刻的退化特征序列表示为 $\mathbf{R}_t = [r_{t-L+1}, r_{t-L+2}, \dots, r_t]$, $\mathbf{R}_t \in \mathbb{R}^{L \times M}$, 其中 $\mathbf{R}_t$ 表示由连续 L 个飞行循环、每个循环 M 维退化残差构成的时序样本。该序列同时包含当前退化状态和历史退化轨迹, 可为模型学习退化趋势与寿命衰减规律提供输入基础。

基于上述定义, RUL 预测问题可表示为: 给定退化特征序列 $\mathbf{R}_t$, 构建非线性映射函数 $f(\cdot)$, 输出当前飞行循环对应的 RUL 预测值, 如式(5-4)所示:

$$\hat{y}_t = f(\mathbf{R}_t; \phi) \quad (5-4)$$

其中, $\hat{y}_t$ ——代表模型预测的 RUL 值;

ϕ ——代表模型待学习参数。

模型训练目标是使预测值 $\hat{y}_t$ 尽可能接近真实标签 y_t , 本章采用均方误差作为 RUL 预测损失函数为:

$$L_{RUL} = \frac{1}{N} \sum_{i=1}^N (\hat{y}_t - y_t)^2 \quad (5-5)$$

其中, N ——代表训练样本数量,

L_{RUL} ——代表预测损失。

通过最小化该损失函数, 模型能够学习退化特征序列与剩余使用寿命之间的非线性映射关系, 实现由连续退化轨迹到 RUL 标签的端到端预测。

5.3 基于退化特征增强的 RUL 预测算法原理

本章提出的 RUL 预测框架旨在解决复杂运行条件、发动机个体差异以及退化

过程时序耦合建模带来的预测问题。

5.3.1 基于退化特征增强的 RUL 预测框架

图 5-1 展示了本章所提方法的整体流程。考虑到实际航空发动机部件特性和设计数据通常难以获取，本章延续第 2 章中的 PTCN 建模思想，构建数据驱动性能基线模型，用于描述健康状态下运行条件与气路性能参数之间的映射关系。与第 2 章面向性能监视的目标不同，RUL 预测更强调退化信息的显式表征。因此，本章在健康基准构建中仅保留未建模旁路，用于补偿目标发动机固有个体差异；同时不引入退化旁路，避免真实退化趋势被模型补偿，从而使残差信息能够更直接地反映性能退化程度。




图 5-1 基于退化特征增强的 RUL 预测框架示意图

在退化特征构建阶段，模型根据当前运行条件动态估计每个飞行循环下的健康基准输出，并将实际传感器测量值与预测值作差，得到多维残差特征。由于该残差已在一定程度上削弱工况变化和个体差异的影响，因此能够更集中地表征发动机相对于健康状态的性能偏离。进一步地，本章引入 RUL 预测触发机制：当监测残差相对于健康基准出现持续或显著偏离时，启动 RUL 预测模块；否则仅维持退化状态监测。该机制可避免在早期健康阶段过早进行寿命预测，使模型更加关注具

有明确寿命指示意义的退化阶段。

在 RUL 预测阶段,本章以连续时间窗口内的退化残差序列作为输入,利用 PTCN 主干网络提取多尺度时序退化特征。考虑到发动机退化过程同时具有时间演化特征和多变量耦合特征,本章进一步融合时序注意力和通道注意力机制。其中,时序注意力用于突出退化加速、趋势突变等关键时间步;通道注意力用于自适应强化与性能劣化密切相关的监测变量,抑制冗余和噪声特征。通过两类注意力机制的协同作用,模型能够从时间维度和变量维度增强关键退化信息表达,最终实现由退化特征序列到 RUL 标签的端到端预测。

5.3.2 退化趋势表征与 RUL 预测触发机制

在获得健康基准后,需要进一步从实际测量值与模型预测值之间的差异中提取能够反映退化进程的特征。由于航空发动机在服役初期通常处于相对健康状态,各监测参数相对于健康基准的偏离较小;随着飞行循环增加,部件性能逐渐衰退,实际测量值与健康基准预测值之间的偏差会逐步扩大。因此,基于残差信息构建退化趋势表征,有助于判断发动机是否进入明显退化阶段,并为后续 RUL 预测模型提供更加有效的输入依据。

为了量化各传感器在第 C 个飞行循环内相对于健康基准的整体偏离程度,设第 C 个飞行循环内共有 T 个采样点,定义不同循环下退化偏差指标如式(5-6)所示:

$$R_n^C = \frac{1}{T} \sum_{i=1}^T |S_n^C(i) - \hat{S}_n^C(i)| \quad (5-6)$$

其中, $S_n^C(i)$ ——代表第 n 个传感器的实测值;

$\hat{S}_n^C(i)$ ——代表第 n 个传感器的预测值;

R_n^C ——代表第 n 个传感器在第 C 个飞行循环下的平均退化偏差。

该指标通过对循环内所有采样点的绝对残差求均值,从整体上反映当前飞行循环中发动机实际性能相对于健康基准的偏离程度。当发动机处于健康或轻微退化阶段时, R_n^C 通常维持在较低水平;当退化逐渐加剧时,相关传感器的偏差指标会呈现持续增大趋势。

由于发动机退化过程通常具有阶段性和非线性特征,单一循环的偏差大小并不能充分说明发动机是否已经进入稳定退化阶段。例如,局部工况扰动、测量噪声或短时控制波动均可能导致某一循环残差升高,但这并不一定代表真实退化已经形成。因此,本章进一步引入基于滑动窗口的退化趋势评估方法,通过连续多个循环内退化偏差的变化趋势判断发动机状态是否发生持续性偏离。

对于第 C 个飞行循环,选取其前 5 个循环的退化偏差序列, $\{R_n^{C-5}, \dots, R_n^{C-1}\}, C \geq 6$,

基于该窗口内的退化偏差建立局部线性回归模型，用于描述当前短时窗口内退化偏差随循环数变化的趋势，如式(5-7)所示：

$$\hat{R}_n^C = \theta_0 + \theta_1 \cdot C \quad (5-7)$$

其中， θ_0 ——代表最小二乘参数中偏置估计；

θ_1 ——代表最小二乘参数中趋势估计。

当 θ_1 增大时，则表明该传感器对应的性能偏离随循环数增加迅速增大。进一步定义窗口残差指标，用于衡量实际退化偏差相对于局部回归趋势的偏离程度如式(5-8)所示：

$$\Delta R_n^C = \frac{1}{5} \sum_{i=1}^5 |R_n^{C-i} - \hat{R}_n^{C-i}| \quad (5-8)$$

其中， ΔR_n^C ——代表第 n 个传感器在第 C 个循环对应窗口内的退化趋势残差。

基于上述退化趋势表征，本章构建基于残差的 RUL 触发器。具体而言，当连续多个循环内存在至少一个传感器满足退化趋势残差超过设定阈值时，认为发动机相对于健康基准已经出现持续性退化偏离，进而激活后续 RUL 预测模型。触发条件可表示为 $\Delta R_n^C \geq \delta$ ， δ 为预设的退化阶段触发阈值。当该条件在连续 q 个循环内成立时，触发 RUL 预测模块；否则，系统继续执行退化偏差监测，不进行寿命预测输出。

5.3.3 融合互补注意机制的 RUL 预测模型

由于航空发动机在制造装配、服役环境和任务剖面等方面存在明显差异，不同发动机个体的退化速率和退化模式往往具有较强的不一致性^[146]。即使经过健康基准补偿后，退化残差序列中仍可能同时包含长期退化趋势、阶段性突变以及多传感器之间的耦合变化。因此，RUL 预测模型不仅需要具备多尺度时序特征提取能力，还需要能够自适应识别退化序列中的关键时间片段和关键特征通道。基于此，本章在 PTCN 主干网络的基础上，引入时序注意力和通道注意力两种互补机制，构建融合互补注意力的 RUL 预测模型，其整体流程如图 5-2 所示。

具体而言，模型首先以触发 RUL 预测后的退化残差序列作为输入，通过 PTCN 主干网络提取多尺度时序退化特征。设输入退化特征序列为 $X \in \mathbb{R}^{T \times F}$ ，其中 T 表示时间窗口长度， F 表示特征维度。经过 PTCN 特征提取后，可得到融合不同时间尺度退化信息的隐含特征表示。随后，时序注意力模块和通道注意力模块并行作用于该特征表示，分别从时间维度和通道维度对关键信息进行自适应增强。




图 5-2 融合互补注意力的计算流

在此模型中,时序注意力机制通过动态聚合不同时间步之间的信息,使模型能够关注退化序列中的全局依赖关系和动态变化特征^[147]。对于输入特征,首先通过线性变换得到查询矩阵、键矩阵和值矩阵,如式(5-9):

$$Q = XW_Q, K = XW_K, V = XW_V \quad (5-9)$$

其中, W_Q ——代表查询的线性变换权重矩阵;

W_K ——代表键的线性变换权重矩阵;

W_V ——代表值的线性变换权重矩阵。

随后,通过缩放点积注意力计算不同时间步之间的相关性,如式(5-10)所示:

$$Attention(Q, K, V) = softmax(\frac{Q \cdot K^T}{\sqrt{d}})V \quad (5-10)$$

其中, d ——代表注意力的缩放因子。

该机制能够根据时间步之间的相似性和依赖关系分配注意力权重,使模型重点关注对 RUL 预测更具贡献的退化阶段。例如,在退化加速、趋势突变或寿命敏感阶段,时序注意力能够赋予相应时间片段更高权重,从而增强模型对全局时间动态和关键退化模式的建模能力。

相较于时序注意力,通道注意力更侧重于评估各特征的重要性。在发动机退化过程中,不同传感器残差对寿命预测的贡献并不相同,部分通道可能与关键部件退化密切相关,而部分通道则可能包含较多冗余信息或噪声扰动^[148]。而通道注意力就是基于此对不同特征通道进行自适应加权。具体地,对于每个通道 c ,首先通过全局平均池化对该通道在时间维度上的信息进行压缩,如式(5-11)所示:

$$s = 1/L \sum_{i=1}^L X_{i,c}, \quad c = 1, 2, \dots, C \quad (5-11)$$

其中, s_c ——代表第 c 个通道的全局统计描述;

$X_{i,c}$ ——代表第 i 个时间步下第 c 个通道的特征值。

随后, 通过包含非线性激活的全连接网络生成通道注意力权重 M_C , 其计算过程可表述为式(5-12):

$$M_C = \sigma(W_2 \delta(W_1 s)) \quad (5-12)$$

其中, $\delta(\cdot)$ ——代表 ReLU 激活函数;

$\sigma(\cdot)$ ——代表 Sigmoid 激活函数;

W_1 ——代表第一层全连接层权重;

W_2 ——代表第二层全连接层权重。

输入特征各通道根据 M_C 进行加权调整, 从而强化与 RUL 预测相关性更强的退化特征通道。在完成时序注意力和通道注意力计算后, 模型将两类注意力增强特征在特征层面进行融合。设时序注意力模块输出为 H_T , 通道注意力模块输出为 H_C , 则融合特征 H_F 可表示为:

$$H_F = \text{Concat}(H_T, H_C) \quad (5-13)$$

其中, $\text{Concat}(\cdot)$ ——代表特征拼接操作。

最终将 H_F 输入全连接回归层。通过端到端训练, RUL 预测模型能够从退化残差序列中学习寿命衰减相关的时序演化规律和关键特征权重, 从而提高对不同退化速率、不同退化模式以及复杂运行条件下 RUL 预测任务的适应能力。

5.4 仿真试验与分析

5.4.1 试验数据描述

N-CMAPSS 数据集是 NASA 公开的航空发动机健康管理领域常用基准数据集^[145]。相比传统 CMAPSS 数据集, N-CMAPSS 保留了更完整的飞行过程信息, 每个飞行循环均包含采样频率为 1Hz 的全流程运行数据, 能够反映发动机在起飞、爬升、巡航、下降等不同阶段下的动态响应特征。因此, 该数据集同时具有寿命退化趋势、复杂工况变化、飞行剖面差异和多变量耦合等特点, 对 RUL 预测模型的退化表征能力和时序建模能力提出了更高要求。

N-CMAPSS 数据主要包括运行条件、传感器测量数据、虚拟传感器、模型健康参数和辅助信息五类特征。其中, 虚拟传感器和模型健康参数虽然能够提供更丰

富的状态描述,但在实际航空公司运行场景中通常难以直接获取。为使试验设置更贴近工程应用,本章仅选取运行条件和传感器测量数据两类实际可观测变量,用于健康基准建模、退化特征提取和 RUL 预测。

本章选取 DS01、DS04 和 DS06 三个子数据集开展验证,以评估所提方法在不同退化复杂度下的有效性。其中,DS01 主要模拟 HPT 效率因子的单一退化过程,用于验证模型对典型单部件退化特征的捕捉能力;DS04 涉及 Fan 效率因子和流量因子的联合退化,用于考察部件内部多健康参数耦合退化条件下的预测性能;DS06 进一步包含 HPT 和 LPT 的流量因子与效率因子同步退化,退化源更加复杂,可用于检验模型在多部件、多参数耦合退化条件下的鲁棒性。

本章所构建的健康基准模型输入与输出变量如表 5-1 所示。输入变量包括 Ma、Alt、Wf、N1 和 N2,用于表征飞行工况、燃油供给和发动机工作状态。输出变量选取发动机主要截面处的温度和压力测量参数,覆盖风扇、外涵道、LPC、HPC、HPT 和 LPT 等关键部件出口位置,用于描述气路系统热力状态变化。

表 5-1 健康基准模型的输入输出设置

变量名称	符号	作用
飞行马赫数	Ma	输入
高度	Alt	输入
燃油流量	Wf	输入
风扇转速	N1	输入
核心机转速	N2	输入
低压压气机出口总温	Tt25	输出
高压压气机出口总温	Tt3	输出
高压涡轮出口总温	Tt45	输出
低压涡轮出口总温	Tt5	输出
外涵道总压	Pt15	输出
风扇出口总压	Pt2	输出
低压压气机出口总压	Pt25	输出
高压压气机出口静压	Ps3	输出
燃烧室出口总压	Pt4	输出
低压涡轮出口总压	Pt5	输出

在数据预处理方面,本章主要包括数据归一化和时序样本构建两个步骤。首先,对不同量纲和取值范围的变量进行归一化处理;随后,采用滑动时间窗口构造连续时序样本。由于相关流程与第2.6.1.2节基本一致,本节不再展开说明。

5.4.2 模型设置和评价指标

5.4.2.1 模型设置

针对DS01、DS04和DS06三个子数据集,本节采用统一的数据划分方式开展实验验证。对于每个子数据集,将编号为01—07的发动机单元数据作为训练集,用于健康基准中PBM、未建模旁路以及RUL预测模型的训练;将编号为08—10的发动机单元数据作为测试集,用于评估模型预测性能。

在健康基准模型构建中,PBM采用双层PTCN结构,每层包含32个隐藏单元,卷积核尺寸为3,输入序列长度设为16,扩张因子按 2^k 设置。模型采用ReLU激活函数和Adam优化器,主训练阶段学习率设为0.005,训练100个epoch;未建模旁路微调阶段学习率设为0.0005,训练10个epoch,损失函数均采用均方误差(Mean Squared Error, MSE)。其中,未建模旁路仅在各发动机PPM训练阶段进行更新,用于补偿目标发动机的个体差异。

在RUL预测模型中,PTCN采用三层结构,输入序列长度设为25,用于提取退化残差序列中的多尺度时序特征;旁路微调结构采用MLP实现。各模型的主要参数设置及训练过程如表5-2所示。

表5-2 预测框架中各子模型的超参数设置

参数	PTCN (健康基准)	PTCN (RUL 预测)	MLP 旁路
层数	3	3	1
序列长度	16	25	-
每层隐藏单元数	32	32	32
卷积核大小	3	3	-
膨胀率	Powers of 2	Powers of 2	-
激活函数	ReLU	ReLU	ReLU
优化器	Adam	Adam	Adam
初始学习率	0.005	0.005	0.01
训练轮次	100	100	100
损失函数	MSE	MSE	MSE

针对基于残差的 RUL 预测触发机制，本章将退化触发阈值 δ 设为 0.03，连续触发循环数 q 设为 3。即当退化趋势指标连续 3 个飞行循环满足阈值条件时，认为发动机进入明显退化阶段，并启动后续 RUL 预测模块。

5.4.2.2 评价指标

为全面评估所提 RUL 预测模型的性能，本章选取均方根误差（Root Mean Square Error, RMSE）、平均绝对误差（Mean Absolute Error, MAE）以及 Score 指标作为评价标准。其中，RMSE 和 MAE 用于衡量预测值与真实 RUL 标签之间的整体偏差，Score 指标则用于体现航空发动机维护场景下对预测误差方向的非对称惩罚。RMSE 与 MAE 的定义分别如式(5-14)、(5-15)所示：

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2} \quad (5-14)$$

$$MAE = \sqrt{\frac{1}{N} \sum_{i=1}^N |\hat{y}_i - y_i|} \quad (5-15)$$

其中， N ——代表测试样本数量；

$\hat{y}_i$ ——代表第 i 个样本的 RUL 预测值；

y_i ——代表对应的真实 RUL 标签。

此外，本章采用 CMAPSS 相关研究中常用的 Score 指标进一步评价 RUL 预测结果^[141]。与 RMSE 和 MAE 不同，Score 指标对预测误差方向具有非对称惩罚特性。对于航空发动机维护任务而言，高估 RUL 可能导致维护延误并带来较高安全风险，而低估 RUL 通常主要造成提前维护和成本增加。因此，Score 指标对高估 RUL 的惩罚程度更高，更符合航空发动机视情维护中的风险规避需求。Score 指标的定义如式(5-16)所示：


$$Score = \begin{cases} \sum_{i=1}^n (e^{\frac{y_i - \hat{y}_i}{13}} - 1), & (y_i - \hat{y}_i < 0) \\ \sum_{i=1}^n (e^{\frac{\hat{y}_i - y_i}{10}} - 1), & (y_i - \hat{y}_i > 0) \end{cases} \quad (5-16)$$

5.4.3 基于 N-CMAPSS 数据集的健康基准精度评估

本章 RUL 预测方法依赖于退化残差特征的有效提取，而残差特征的可靠性首先取决于健康基准模型的预测精度。只有健康基准能够准确描述发动机在无明显退化状态下的气路参数响应，实测值与预测值之间的偏差才具有明确的退化指向性。因此，在开展 RUL 预测前，有必要先评估健康基准模型的建模精度。

根据第2章提出的PPM构建思路,本章健康基准由PBM和未建模旁路组成。在PBM训练阶段,首先需要提取发动机健康阶段样本。结合工程经验和N-CMAPSS数据集设定,本节将各发动机全寿命周期前20%的飞行循环近似视为无明显退化阶段,并以此构建健康样本集,通过滑动时间窗口形成序列化训练数据。

图5-3展示了PBM在DS01数据集中08号发动机第10个飞行循环上的预测结果。受篇幅限制,本节选取具有代表性的Tt25和Pt25进行展示。由图可见,PBM预测曲线能够较好跟随实测数据的整体变化趋势,并捕捉由工况变化引起的局部动态波动,说明PTCN结构能够有效表征不同气路参数的时序响应特征。




(a) Pt25 真实值与预测值的比较

(b) Tt25 真实值与预测值的比较

图 5-3 DS01 数据集 08 号发动机第 10 个循环的 PBM 预测结果

在面向目标发机构建健康基准时,本节进一步利用该发动机首个飞行循环数据对预训练PBM进行未建模旁路自适应,仅更新旁路参数,保持PBM主体结构不变。图5-4给出了旁路自适应后的预测结果。可以看出,经过未建模旁路修正后,模型预测曲线与实测曲线更加一致,整体预测精度相比PBM进一步提高,说明未建模旁路能够有效补偿目标发动机的初始个体差异。



(a) Pt25 真实值与预测值的比较

(b) Tt25 真实值与预测值的比较

图 5-4 DS01 数据集 08 号发动机第 10 个循环的健康基准预测结果

为定量评估健康基准模型精度，本节采用 MAPE 统计 DS01 子集中 08 至 10 号发动机各气路传感器的预测误差，结果如表 5-3 所示。评估数据同样取自各发动机前 20%的健康阶段，并排除用于旁路自适应的首个飞行循环。

由表 5-3 可知，健康基准模型在不同发动机单元上的预测误差均保持较低水平。其中，Pt5 的 MAPE 相对最大，但仅为 0.21%，其余传感器误差均低于该值。该结果表明，所构建的健康基准能够较准确地刻画目标发动机健康状态下的气路参数响应，为后续退化残差构建和 RUL 预测提供可靠基础。

表 5-3 健康基准模型预测精度

数据集	各传感器的健康基准预测准确度（以 MAPE 表示）				
	Tt25	Tt3	Tt45	Tt5	Pt15
DS01	0.03%	0.04%	0.07%	0.06%	0.08%
DS04	0.06%	0.03%	0.09%	0.09%	0.05%
DS06	0.04%	0.07%	0.05%	0.10%	0.04%
数据集	Pt2	Pt25	Ps3	Pt4	Pt5
DS01	0.10%	0.11%	0.17%	0.07%	0.21%
DS04	0.11%	0.13%	0.09%	0.12%	0.15%
DS06	0.13%	0.11%	0.12%	0.08%	0.18%

5.4.4 退化特征的显式捕捉

退化趋势提取是实现发动机性能退化显式表征的关键。通过比较实际传感器测量值与健康基准输出，可以获得发动机相对于健康状态的性能偏离程度，从而为后续 RUL 预测提供更具退化指向性的输入特征。以 DS01 子集中的 08 号发动机为例，图 5-5 展示了第 60 个飞行循环中 Tt45 和 Tt5 的真实值与健康基准预测值对比。与 5.4.3 节中早期健康循环的预测结果相比，后期循环中真实值与预测值之间的偏差明显增大，说明随着飞行循环增加，累积退化已使发动机实际性能逐渐偏离健康基准。

需要注意的是，不同传感器对退化的敏感性并不一致，并非所有测量参数都能直观反映退化趋势。图 5-6 给出了 08 号发动机不同传感器预测误差随飞行循环增加的变化趋势。其中温度类传感器，尤其是 Tt45 和 Tt5，对退化过程更为敏感，其误差随循环增加呈现出更明显的上升趋势；相比之下，部分压力类传感器的误差变化幅度较小，对退化过程的表征能力相对有限。




图 5-5 DS01 数据集 08 号发动机第 60 个循环的健康基准预测结果




图 5-6 DS01 数据集中 08 号发动机各传感器 MAE 值随飞行循环数的变化趋势

由物理机理可知,随着发动机长期运行,核心部件效率下降和流量能力衰退会改变原有气动热力匹配关系。为维持相近的推力输出,发动机通常需要更高的燃油供给或更强的热端工作负荷,从而导致热端温度升高^[149]。因此,热端温度测量参数更容易表现出随退化累积而增大的残差特征。相比之下,部分压力参数受工况调节、控制作用和流道匹配关系影响较大,其退化趋势不如温度参数明显。

此外,从各传感器误差随寿命推进的整体变化可以看出,发动机退化过程并非简单线性变化,而是具有明显的阶段性和非线性特征。在健康阶段和早期服役阶段,各传感器残差整体维持在较低水平,退化效应较弱;随着飞行循环增加,部件性能劣化逐渐累积,相关传感器误差开始缓慢上升;进入寿命后期后,退化效应进一步加剧,部分关键传感器残差快速增长,表明发动机偏离健康基准的程度显著扩大。

5.4.5 RUL 预测结果和方法对比

为评估所提方法在航空发动机 RUL 预测任务中的有效性,本节分别在 DS01、DS04 和 DS06 三个子数据集上开展试验,并对测试集 08—10 号发动机的 RUL 进行预测。为降低网络随机初始化、样本批次划分及训练随机性对结果的影响,每组

实验均重复训练和测试 10 次，并统计平均预测结果与性能指标。图 5-7 展示了 DS01 子集中 08—10 号发动机的 RUL 预测结果。




图 5-7 DS01 中第 08 至 10 号发动机 RUL 预测结果

如图 5-7 所示，蓝色实线表示真实 RUL 轨迹，红色虚线表示 10 次独立试验的平均预测结果，红色阴影区域表示预测结果波动范围，用于反映模型预测不确定性；灰色竖直虚线表示 RUL 预测触发周期，即模型由退化监测阶段进入寿命预测阶段的起始位置。下方子图中的绿色区域表示预测值与真实值之间的绝对误差。由图可知，模型触发后，RUL 预测值与真实值保持较高的一致性。同时，红色阴影区域整体较窄，说明模型在不同初始化和训练条件下具有较好的稳定性。绝对误差分布表明触发后的预测误差较小，未出现明显持续性偏差，说明基于退化残差特征和融合互补注意力机制的预测框架能够有效捕捉退化规律，并给出较可靠的 RUL 估计。

为进一步验证方法性能，本节将所提模型与 CNN、LSTM、Bi-LSTM、Transformer、物理信息模型、不确定性感知深度学习模型、集成模型及相关概率变体模型等典型 RUL 预测方法进行对比^[101]。同时，为分析退化残差特征和预测触发机制的作用，设置多种基于残差输入的对比方法。上述残差类方法与本章方法采用相同的健康基准和残差提取方式，区别主要在于后续 RUL 回归预测模型不同。

为保证对比公平性，各基准模型均在优化后的超参数条件下进行训练和评估。其中，DNN 模型主要优化网络深度和激活函数类型；LSTM-DNN 模型主要优化输入序列长度和网络层数；Transformer 模型主要优化注意力头数量和编码层数。所有模型均采用相同的训练集和测试集划分，并分别在 DS01、DS04 和 DS06 子数据集上进行评估。表 5-4 至表 5-6 给出了不同方法在三个数据集上的 RMSE、MAE、Score 及标准差等结果。

表 5-4 DS01 数据集不同方法的 RUL 预测结果对比

方法	RMSE	MAE	Score
CNN	7.85	5.29	1.09
LSTM	7.81	5.24	1.08
Bi-DLSTM	7.71	5.15	1.05
Transformer	8.79	5.99	1.40
Vanilla	7.46	4.98	0.99
Probabilistic	7.66	5.04	1.04
CNN + Wiener	11.13	10.17	-
CNN-LSTM + Wiener	8.28	7.29	-
Transformer + Wiener	8.59	8.95	-
CNN-Transformer + Wiener	5.16	4.98	-
基于残差的 DNN	5.35±0.42	4.88±0.38	0.52±0.04
基于残差的 LSTM-DNN	5.16±0.33	4.63±0.31	0.49±0.03
基于残差的 Transformer	4.11±0.27	4.20±0.24	0.45±0.02
所提方法	3.16±0.13	3.02±0.19	0.33±0.02

表 5-5 DS04 数据集不同方法的 RUL 预测结果对比

方法	RMSE	MAE	Score
CNN	11.88	8.80	3.56
LSTM	12.86	9.31	4.43
Bi-DLSTM	13.55	9.76	4.86
Transformer	11.41	8.06	2.09
Vanilla	10.24	7.41	1.50
Probabilistic	10.03	7.29	1.49
基于残差的 DNN	6.69±0.42	5.71±0.41	0.91±0.04
基于残差的 LSTM-DNN	4.39±0.32	3.98±0.30	0.52±0.03
基于残差的 Transformer	4.63±0.14	4.35±0.13	0.58±0.01
本章所提方法	3.95±0.19	3.66±0.18	0.41±0.02

表 5-6 DS06 数据集不同方法的 RUL 预测结果对比

方法	RMSE	MAE	Score
CNN	9.13	6.09	1.00
LSTM	8.52	5.81	0.86
Bi-DLSTM	8.31	5.69	0.83
Transformer	8.38	5.76	0.86
Vanilla	8.13	5.97	0.80
Probabilistic	8.10	5.68	0.78
基于残差的 DNN	7.04±0.48	4.97±0.45	0.68±0.04
基于残差的 LSTM-DNN	4.47±0.25	4.16±0.21	0.51±0.02
基于残差的 Transformer	4.82±0.31	4.44±0.32	0.59±0.03
本章所提方法	3.23±0.13	3.18±0.11	0.39±0.02

由表 5-4 至表 5-6 可知, 所提方法在三个子数据集上均取得了较优预测性能, 并在多数评价指标上达到最优或接近最优。相比直接基于原始传感器数据的预测方法, 基于退化残差特征的方法整体表现出更低的 RMSE 和 MAE, 说明健康基准残差能够有效削弱工况变化和个体差异干扰, 使模型输入更加聚焦于退化过程本身。同时, 所提方法在 Score 指标上的优势表明, 其能够减少高估 RUL 带来的风险性误差, 更符合航空发动机视情维护对安全性的要求。

5.4.6 消融试验

5.4.6.1 微调样本量影响

为评估微调样本量对健康基准中未建模旁路自适应效果的影响, 本节采用增量交叉验证方式开展消融试验。针对测试集中的 08-10 号发动机, 选取其前 10 个飞行循环作为微调候选样本, 并将微调样本量记为 k , 其中 $1 \leq k < 10$ 。对于每个 k 值, 枚举前 10 个飞行循环中所有不重复的 k 个循环组合作为微调训练集, 其余 $10-k$ 个周期作为测试集。

在每次试验中, 模型仅利用选定的 k 个飞行循环更新目标发动机的未建模旁路参数, PBM 主体结构保持不变, 并在对应测试循环上计算健康基准预测误差。随后, 对相同 k 下所有组合的 MAPE 取平均, 用于分析微调样本量与健康基准自适应精度之间的关系。不同微调样本规模下的结果如表 5-7 所示。

由表 5-7 可知,随着微调样本量增加,各测量参数的平均预测误差整体呈下降趋势,说明更多目标发动机数据有助于未建模旁路更充分地学习个体性能差异,从而提高健康基准预测精度。但该趋势并非完全单调,部分变量在特定 k 值下存在一定波动。这主要是由于新增样本可能引入不同工况分布或局部噪声,使旁路微调效果受到样本代表性的影响。

表 5-7 使用不同样本量进行未建模旁路自适应的预测结果对比

微调样本量 k	各传感器的健康基准预测准确度 (以 MAPE 表示)				
	Tt25	Tt3	Tt45	Tt5	Pt15
1	0.04%	0.05%	0.07%	0.08%	0.06%
2	0.04%	0.05%	0.06%	0.08%	0.06%
3	0.03%	0.04%	0.06%	0.09%	0.05%
4	0.03%	0.04%	0.07%	0.09%	0.07%
5	0.04%	0.04%	0.05%	0.09%	0.06%
6	0.04%	0.04%	0.05%	0.07%	0.08%
7	0.03%	0.04%	0.06%	0.08%	0.06%
8	0.03%	0.04%	0.06%	0.07%	0.05%
9	0.03%	0.04%	0.06%	0.08%	0.04%
微调样本量 k	Pt2	Pt25	Ps3	Pt4	Pt5
1	0.11%	0.12%	0.13%	0.09%	0.18%
2	0.10%	0.13%	0.17%	0.08%	0.22%
3	0.11%	0.11%	0.14%	0.09%	0.21%
4	0.11%	0.11%	0.16%	0.12%	0.15%
5	0.12%	0.10%	0.14%	0.13%	0.16%
6	0.10%	0.10%	0.11%	0.11%	0.19%
7	0.10%	0.11%	0.13%	0.12%	0.16%
8	0.09%	0.12%	0.11%	0.09%	0.13%
9	0.09%	0.10%	0.14%	0.10%	0.18%

5.4.6.2 PTCN 深度与序列长度的影响

PTCN 是本章 PBM 建模和 RUL 预测模型的核心时序特征提取结构。需要说明的是，虽然二者均采用 PTCN 作为主干网络，但其建模目标不同。PBM 采用序列到序列的映射方式，重点在于刻画健康状态下运行条件与气路参数之间的动态响应关系；RUL 预测则采用序列到单点的映射方式，利用退化特征序列预测窗口末端对应的剩余使用寿命。因此，PBM 更关注完整时间序列的动态拟合能力，而 RUL 预测更强调退化趋势和寿命相关信息的提取能力。

为分析 PTCN 结构参数对模型性能的影响，本节分别对 PBM 和 RUL 预测模型开展消融试验。对于 PBM，设置网络深度为 1—5 层，输入序列长度为 8、16、32、64、128 和 256，并采用验证集损失评价建模效果；对于 RUL 预测模型，设置网络深度为 1—3 层，输入窗口长度为 10、15、20、25、30 和 35，并采用 RMSE 和 Score 作为评价指标。除网络深度和序列长度外，其余训练参数保持一致。

实验结果如图 5-8 和图 5-9 所示。对于 PBM，当 PTCN 采用 2 层结构、输入序列长度为 16 时，验证集损失最低，说明该配置能够在动态响应建模能力和模型复杂度之间取得较好平衡。对于 RUL 预测任务，当 PTCN 采用 3 层结构、输入窗口长度为 25 时，RMSE 和 Score 均达到最优，表明适当增加网络深度和时间窗口有助于捕捉退化特征的累积变化规律。但当窗口继续增大时，模型可能引入与当前寿命状态相关性较弱的历史信息，导致预测性能下降。

此外，由于 PTCN 采用因果卷积和扩张卷积，序列起始阶段需要填充以保证卷积计算完整，可能造成初始时间步预测误差偏大。为避免该影响干扰 PBM 评估，本章在计算健康基准损失时剔除了边界填充区域对应的预测结果。对于 RUL 预测模型，由于退化触发机制通常在发动机运行一段时间后才启动预测，因此初始填充效应对最终预测结果影响较小。综上，本章 PBM 最终采用 2 层、序列长度为 16 的 PTCN 结构，RUL 预测模型采用 3 层、窗口长度为 25 的 PTCN 结构。




图 5-8 不同窗口尺寸和 PTCN 深度对 PBM 验证集的影响




图 5-9 不同窗口大小和 PTCN 深度对 RUL 预测模型测试集的影响

5.4.6.3 融合互补注意力机制的影响

为验证融合互补注意力机制在 RUL 预测中的有效性,本节分别对时序注意力和通道注意力模块进行消融分析。共设置四种模型结构进行对比:无注意力机制的基准模型(N_A)、仅引入时序注意力的模型(T_A)、仅引入通道注意力的模型(C_A)以及同时融合时序注意力和通道注意力的模型(D_A)。

试验在 DS01、DS04 和 DS06 三个子数据集上开展,并采用 RMSE、MAE 和 Score 作为评价指标,结果如表 5-8 所示。由表可知,引入注意力机制后,模型整体预测性能均优于无注意力基准模型。其中,单独引入时序注意力或通道注意力均能在一定程度上降低预测误差,说明二者均有助于增强退化特征表达。相比之下,通道注意力带来的性能提升更为明显,表明关键传感器通道筛选对 RUL 预测具有重要作用。

表 5-8 注意力机制对模型性能的影响

模型	RMSE			MAE			Score		
	DS01	DS04	DS06	DS01	DS04	DS06	DS01	DS04	DS06
N_A	3.85	5.01	4.02	3.46	4.67	3.88	0.51	0.69	0.58
T_A	3.44	4.44	3.91	3.31	4.25	3.74	0.46	0.58	0.53
C_A	3.07	4.52	3.85	2.95	4.08	3.59	0.36	0.50	0.50
D_A	3.16	3.95	3.23	3.02	3.66	3.18	0.33	0.41	0.39

进一步对比可以发现,同时融合时序注意力和通道注意力后,模型在三个数据集上均取得最优或接近最优的预测结果。例如,在 DS04 数据集上,D_A 模型的 RMSE 和 Score 分别降低至 3.95 和 0.41,优于单一注意力结构。该结果说明,时

序注意力能够突出退化过程中的关键阶段，通道注意力能够强化与寿命衰减密切相关的敏感变量，二者具有互补作用。通过联合建模时间维度和特征通道维度的重要性，所提模型能够更充分地表征复杂退化模式，从而提升 RUL 预测精度。

5.4.7 触发机制的可解释性分析

为验证退化阶段触发机制的有效性，本节选取 DS01 数据集中的 08、09 和 10 号测试发动机，对真实退化模式变化与模型触发周期进行对比分析。根据 DS01 数据集设定，该子集主要模拟 HPT 效率退化，退化源较为明确，适合用于分析触发机制对退化阶段转换的识别能力。本节以 HPT 效率退化因子 HPT_eff_mod 作为真实退化参考，并结合健康基准残差趋势进行对照分析。在各传感器残差中，Tt5 对该退化过程响应最为明显，因此选取其作为关键分析变量。

如图 5-10 所示，模型识别得到的触发周期与真实退化模式转换周期基本一致。在触发周期附近，HPT_eff_mod 的退化速率出现明显变化，表明发动机由缓慢退化阶段进入更显著的性能退化阶段；同时，Tt5 残差趋势也同步增强，说明基于健康基准提取的退化残差能够较好反映真实健康参数变化。该结果表明，所提触发机制并非对单点异常波动做出响应，而是能够捕捉退化过程中的阶段性转换特征。

从工程应用角度看，触发机制的作用在于确定 RUL 预测模块的合理启动时机。在健康早期，残差波动较小且退化信息不足，过早开展 RUL 预测容易受到工况扰动和样本不确定性影响；而当残差趋势与真实退化参数同步发生显著变化时，说明发动机性能已明显偏离健康基准，此时启动 RUL 预测更具实际意义。




图 5-10 DS01 数据集中退化机制切换与退化模式的可视化分析

5.4.8 计算复杂度分析

为评估所提框架的计算效率，本节从时间复杂度和空间复杂度两个方面进行分析。设输入特征张量为 $X \in \mathbb{R}^{B \times C \times L}$ ，其中 B 为批量大小， C 为传感器特征通道数， L 为时间序列长度。所提模型的主要计算开销来自 PTCN 特征提取模块和融合互补注意力机制。

对于 PTCN 模块, 假设其包含 N 个并行残差分支, 每个分支包含两层扩张因果卷积。对于单层卷积, 若卷积核大小为 K , 其时间复杂度为 $O(B \times L \times C^2 \times K)$ 。由于扩张率仅改变卷积采样间隔, 并不会增加实际卷积计算次数, 因此 PTCN 核心模块的整体时间复杂度约为 $O(B \times N \times L \times C^2 \times K)$ 。该结构能够在时间维度上并行计算, 相比依赖逐步递推的循环神经网络具有更高的计算效率。

对于融合互补注意力机制, 其计算开销主要由通道注意力和时序注意力两部分组成。通道注意力采用双层全连接结构, 主要时间复杂度为 $O(B \times C^2)$; 时序注意力采用 Q 、 K 、 V 结构, 其主要计算量来自 QK^T 的点积运算, 时间复杂度为 $O(B \times C \times L^2)$ 。因此, 融合互补注意力机制的总时间复杂度可近似表示为 $O(B \times (C^2 + C \times L^2))$ 。

在空间复杂度方面, PTCN 模块的参数量主要由 $2N$ 层卷积结构决定, 其空间复杂度为 $O(N \times C^2 \times K)$ 。融合互补注意力机制的额外参数主要来自两条并行注意力分支, 其中通道注意力的双层全连接结构和时序注意力中的 Q 、 K 、 V 线性映射均主要与通道维度相关, 因此其额外空间复杂度约为 $O(C^2)$ 。总体来看, 模型复杂度主要受序列长度 L 、特征通道数 C 、卷积核大小 K 以及 PTCN 分支数 N 影响。PTCN 通过扩张因果卷积扩大感受野, 同时保持较低计算开销; 融合互补注意力机制虽然引入额外参数, 但参数规模相对有限, 不会显著增加整体计算负担。

从实际部署角度看, RUL 预测和发动机健康管理算法通常部署于地面监控与维修决策系统, 主要用于离线分析和周期性评估, 其实时性要求低于机载故障隔离等需要瞬时响应的任务。同时, 所提框架具有较好的并行计算特性。与 LSTM 等循环网络需要按时间步顺序计算不同, PTCN 可在整个时间序列上并行执行卷积运算, 注意力模块也可通过矩阵运算高效实现。因此, 该模型能够满足机队级运行数据的快速处理需求, 适用于航空公司发动机健康监测与维修决策场景。

5.5 本章小结

本章围绕复杂运行条件下航空发动机 RUL 预测问题, 提出了一种基于退化特征增强与融合互补注意力的 RUL 预测方法。针对原始传感器数据中工况变化、个体差异和性能退化相互耦合, 导致退化信息难以显式表征的问题, 本章基于第2章性能基线建模思想, 利用 PTCN 构建数据驱动 PBM, 并结合未建模旁路形成目标发动机的健康基准。与面向全寿命性能监视的 PPM 不同, 本章在 RUL 预测任务中去除了退化旁路, 避免模型将真实退化趋势作为补偿量吸收, 从而通过实测值与健康基准预测值之间的残差提取具有退化指向性的特征输入。

在方法设计方面, 本章构建了基于退化特征增强的 RUL 预测框架。首先, 利

用健康基准估计目标发动机在当前工况下的健康响应，并通过多维残差刻画其相对于健康状态的性能偏离；随后，设计退化阶段触发机制，根据残差趋势判断发动机是否进入具有明确寿命指示意义的退化阶段，避免在健康早期过早进行 RUL 预测；最后，在 PTCN 时序特征提取主干基础上，引入时序注意力和通道注意力机制，分别突出关键退化阶段和敏感传感器通道，从而增强模型对不同退化模式和退化速率的适应能力。

在仿真验证方面，本章基于 N-CMAPSS 数据集中的 DS01、DS04 和 DS06 三个子数据集开展试验，覆盖单一退化、部件内耦合退化和多部件耦合退化等不同场景。健康基准精度评估结果表明，基于 PBM 与未建模旁路构建的个性化健康基准能够准确表征目标发动机健康状态下的气路参数响应，为残差退化特征提取提供可靠基础。进一步的退化特征分析表明，残差能够有效捕捉发动机性能劣化过程，其中温度类传感器，尤其是热端相关参数，对退化过程表现出更高敏感性。RUL 预测对比结果表明，所提方法在 RMSE、MAE 和 Score 等指标上整体优于多种基准模型，验证了退化特征增强和融合互补注意力机制对预测精度与稳定性的提升作用。

第6章 结论

6.1 主要结论

本文围绕复杂运行条件下航空发动机性能监视、气路故障诊断和剩余使用寿命预测问题,针对发动机个体差异、性能退化、多源不确定性、故障样本稀缺以及退化特征难以显式表征等关键问题,开展了面向全寿命周期的智能健康管理方法研究。全文以性能基线建模为基础,依次构建了个性化性能监视方法、多源不确定性下的气路故障诊断方法、小样本条件下的故障样本生成与诊断增强方法,以及基于退化特征增强的 RUL 预测方法,形成了从健康基准构建、异常识别、故障隔离到寿命预测的完整技术路径。主要结论如下:

(1) 针对单台发动机个体差异和长期性能退化导致 PBM 失配的问题,提出了双旁路自适应性能监视方法。结果表明,未建模旁路能够有效补偿目标发动机初始个体差异,在小涵道比发动机仿真案例中,各气路参数 MAPE 均明显降低,其中 Tt25 和 Pt25 分别由 1.31%和 1.00%降低至 0.21%和 0.13%;在真实 QAR 数据中, Tt25、Tt3、Ps3 和 EGT 的 MAPE 也由 0.40%、0.35%、1.10%和 0.56%降低至 0.28%、0.25%、0.90%和 0.28%。同时,退化旁路能够跟踪长期服役过程中的性能漂移,并通过增量更新重新提升 PPM 对当前性能状态的适配能力,在真实 QAR 数据中分别于第 80 和第 192 个飞行循环触发更新;以第 81 个架次为例,更新后 Tt3、Ps3 和 EGT 的 MAPE 分别由 1.59%、2.28%和 1.28%降低至 0.44%、0.96%和 0.33%。上述结果表明,双旁路结构能够同时实现初始个体差异补偿和长期退化漂移跟踪,为后续故障诊断与 RUL 预测提供可靠的个性化健康参考。

(2) 针对多源不确定性条件下故障特征易受正常退化、个体差异和噪声扰动影响的问题,提出了基于 PPM 残差和双任务自编码器的气路故障诊断方法。结果表明,PPM 残差能够显著削弱个体差异和正常退化对故障判别的干扰。在连续 50 个飞行循环验证中,基于 PBM 的方法因难以准确表征目标发动机个体状态,虚警率达到 65.1%,而基于 PPM 残差的方法能够明显降低虚警风险;在连续 400 个飞行循环验证中,PPM-DTAE 的 FAR 进一步升高至 94.6%,说明长周期退化累积会严重破坏静态基准下的正常/故障边界。相比之下,PPM-DTAE 的 DR 达到 94.0%,明显高于 PPM-MLP 的 70.0%,表明 DTAE 能够增强弱故障和边缘故障的识别能力。噪声鲁棒性试验进一步表明,当噪声强度由 0 增加至 30%时,DTAE 的 DR 仍保持 0.99, IR 由 1.00 仅降至 0.98, FAR 由 0.001 升至 0.04。上述结果说明,PPM

残差与 DTAE 鲁棒特征学习相结合, 能够提升气路故障诊断在长周期退化和强噪声扰动条件下的稳定性。

(3) 针对目标域故障样本稀缺和跨域分布差异导致诊断模型训练困难的问题, 提出了基于迁移学习与高斯混合变分自编码器的故障样本生成与诊断增强方法。结果表明, GMVAE 能够较好地表征多工况正常样本分布, 其生成样本平均误差为 4.4×10^{-2} , 低于传统 VAE 的 5.6×10^{-2} ; 平均覆盖率为 0.93, 高于 VAE 的 0.86。在故障样本生成任务中, 当每类故障样本数量为 1、10 和 100 时, TL-GMVAE 生成样本的四类故障平均误差分别为 8.3×10^{-2} 、 8.9×10^{-2} 和 8.1×10^{-2} , 且最大误差均控制在 1.4×10^{-1} 以内, 说明该方法在极少故障样本条件下仍能生成较稳定的目标域故障样本。进一步的诊断验证表明, 引入生成样本后, R-DTAE 在 1、10 和 100 样本条件下的 DR 分别由 6.94%、26.21% 和 51.18% 提升至 18.71%、32.50% 和 68.30%, IR 分别由 19.08%、38.21% 和 44.60% 提升至 34.61%、55.73% 和 60.91%。与 TBDA、VAE 和 TL-VAE 相比, TL-GMVAE 在生成误差和覆盖率之间取得了更优平衡。上述结果表明, TL-GMVAE 能够有效扩充目标域故障特征空间, 提升小样本条件下故障检测和隔离性能。

(4) 针对 RUL 预测中原始传感器数据受工况变化、个体差异和退化信息耦合影响的问题, 提出了基于退化特征增强与融合互补注意力的 RUL 预测方法。结果表明, 基于 PBM 与未建模旁路构建的个性化健康基准能够保持较高预测精度, 在 DS01 子集中 08—10 号发动机各气路传感器 MAPE 整体较低, 其中相对最大的 Pt5 传感器 MAPE 仅为 0.21%, 为退化残差提取提供了可靠基础。进一步分析表明, 健康基准残差能够显式反映性能退化趋势, 其中 Tt45、Tt5 等热端温度参数对退化过程表现出更高敏感性。在 RUL 预测任务中, 所提方法在 DS01、DS04 和 DS06 三个子数据集上均取得了较优预测性能, 预测曲线能够较好跟随真实 RUL 衰减趋势, 且多次重复试验下预测波动范围较小, 说明模型具有较好的预测精度和稳定性。与 CNN、LSTM、Bi-LSTM、Transformer 等典型时序预测模型以及其他先进 RUL 预测方法相比, 所提方法在 RMSE、MAE 和 Score 等指标上整体达到最优或接近最优水平; 其中在 DS04 数据集上, 融合互补注意力模型的 RMSE 和 Score 分别降低至 3.95 和 0.41。消融试验进一步表明, 残差退化特征能够削弱工况和个体差异干扰, 时序注意力与通道注意力的融合能够同时强化关键退化阶段和敏感变量表达, 从而提升复杂退化场景下 RUL 预测的精度、稳定性和可解释性。

6.2 本文创新点

(1) 提出了面向个性化长周期监视的双旁路自适应性能监视方法。针对传统

PBM 难以同时适应单台发动机初始个体差异与长期性能退化漂移的问题, 本文在 PBM 基础上构建未建模旁路与退化旁路协同的个性化性能模型。未建模旁路用于补偿个体静态偏差、局部模型失配和未建模扰动, 退化旁路用于跟踪随服役过程累积的性能退化趋势, 从而实现机队共性规律、个体差异和长期退化状态的分层建模。该方法既保留了 PBM 的健康基准约束能力, 又增强了模型对目标发动机全寿命周期状态变化的持续适配能力。

(2) 提出了基于个性化残差与双任务自编码器的鲁棒气路故障诊断方法。针对多源不确定性下故障特征边界模糊、正常退化与微弱故障易混叠的问题, 本文以 PPM 残差作为诊断特征, 削弱工况变化、个体差异和正常退化对故障判别的干扰。在此基础上构建 DTAE, 通过重构任务保持残差特征的主要结构信息, 通过分类任务增强潜在特征的类别可分性, 并结合加噪与掩码机制提高模型对传感器扰动、噪声干扰和局部特征缺失的鲁棒性, 从而实现多源不确定性条件下更加稳定的故障检测与隔离。

(3) 提出了基于 TL-GMVAE 的小样本故障样本生成与诊断增强方法。针对目标域故障样本稀缺和跨域分布差异导致诊断模型训练不足的问题, 本文将正常样本分布建模、迁移学习和高斯混合潜空间生成机制相结合, 首先利用正常样本学习发动机健康状态下气路参数的潜在耦合关系, 再利用少量目标域故障样本引导生成模型向故障分布迁移, 从而生成具有目标域故障特征的扩展样本。该方法降低了对大量源域故障样本的依赖, 提高了小样本条件下故障特征空间的覆盖能力和诊断模型的泛化能力。

(4) 提出了基于退化特征增强的航空发动机 RUL 预测方法。针对原始传感器数据中工况响应、个体差异和退化信息相互耦合, 导致退化特征难以显式提取的问题, 本文以个性化健康基准残差构建退化特征, 在保留个体差异补偿能力的同时避免真实退化趋势被模型吸收。进一步引入退化阶段触发机制和融合互补注意力机制, 使模型能够聚焦具有寿命指示意义的退化阶段, 并从时间维度和通道维度强化关键退化信息表达, 形成从健康基准建模、退化特征显式提取到 RUL 预测的完整方法闭环。

6.3 未来展望

本文围绕航空发动机性能监视、气路故障诊断和剩余使用寿命预测开展了系统研究, 并在仿真数据、公开数据集和部分真实 QAR 数据上验证了所提方法的有效性。但面向实际工程应用, 航空发动机运行环境更加复杂, 数据质量、故障类型、退化模式和维修决策需求均具有更强的不确定性。后续研究可从以下几个方面进

一步展开：

（1）本文提出的双旁路自适应性能监视方法能够实现目标发动机的个性化性能跟踪，但旁路模型更新仍主要依赖新增运行样本及误差触发判据。后续可进一步开展更新样本质量评估和旁路更新置信判据方法，提高模型在长期在线应用过程中的稳定性与更新可信度。

（2）本文故障诊断方法主要面向已知气路故障类型开展检测与隔离，对未知故障、复合故障以及渐变型弱故障的识别能力仍需进一步提升。后续可结合开放集识别和复合故障解耦建模方法，使诊断模型能够对训练样本未覆盖的异常模式和复杂故障状态给出更加可靠的判别结果。

（3）本文提出的 TL-GMVAE 方法能够在小样本条件下生成目标域故障样本并提升诊断性能，但生成样本质量仍受少量真实故障样本分布信息的限制。后续可进一步引入生成样本不确定性评价和样本筛选机制，提高生成样本的物理一致性和分布合理性。

（4）本文 RUL 预测方法主要基于具有完整寿命标签的数据集开展验证，后续可进一步面向寿命标签不完备场景，研究弱监督、半监督和自监督 RUL 预测方法，将维护记录、告警信息、性能趋势和专家经验等信息作为辅助监督信号，提升寿命预测模型对不完整退化数据的适应能力。

参考文献

- [1] 林京, 张博瑶, 张大义, 等. 航空燃气涡轮发动机故障诊断研究现状与展望[J]. 航空学报, 2022, 43(8): 7-20.
- [2] 孙见忠, 王卓健, 闫洪胜, 等. 航空预测性维修研究进展[J]. 航空学报, 2025, 46(7): 6-29.
- [3] 林琳, 罗斌, 钟诗胜. 基于视情维修的机队维修决策方法[J]. 计算机集成制造系统, 2019, 25(3): 661-672.
- [4] Tahan M, Tsoutsanis E, Muhammad M, et al. Performance-based health monitoring, diagnostics and prognostics for condition-based maintenance of gas turbines: A review[J]. Applied Energy, 2017, 198: 122-144.
- [5] Li H, et al. Remaining useful life prediction using multi-scale deep convolutional neural network[J]. Applied Soft Computing Journal, 2020, 89.
- [6] Guo H, Wang S, Shi J, et al. Dynamically updated digital twin for prognostics and health management: Application in permanent magnet synchronous motor[J]. Chinese Journal of Aeronautics, 2024, 37(6): 244-261.
- [7] 杨森. 基于视情维修的电子装备PHM体系结构分析[J]. 计算机科学, 2017, 44(9): 17-22+33.
- [8] 上海航空测控技术研究所. 航空故障诊断与健康管理系统[M]. 北京: 航空工业出版社, 2013.
- [9] Scandura P A Jr, Christensen M, Lutz D, et al. Commercial Aviation Health Management[J]. System Health Management: With Aerospace Applications, 2011: 589-603.
- [10] 赵连春, 杰克. 马丁利. 飞机发动机控制: 设计、系统分析和健康监视[M]. 北京: 航空工业出版社, 2012.
- [11] 李应红, 尉询楷. 航空发动机的智能诊断、建模与预测方法[M]. 北京: 科学出版社, 2013.
- [12] Ranasinghe K, Sabatini R, Gardi A, et al. Advances in Integrated System Health Management for mission-essential and safety-critical aerospace applications[J]. Progress in Aerospace Sciences, 2022, 128: 100758.
- [13] Mercer C R, Simon D L, Hunter G W, et al. Fundamental technology development for gas-turbine engine health management[C]//AIAA Infotech@ Aerospace 2007 Conference. 2007 (E-16089).
- [14] Ravinder N. Experience in asset performance management analytics for decision support on Transmission & Distribution Assets[C]//2019 IEEE PES Asia-Pacific Power and Energy Engineering Conference (APPEEC). IEEE, 2019: 1-6.
- [15] Chen Y. Integrated and intelligent manufacturing: Perspectives and enablers[J]. Engineering, 2017, 3(5): 588-595.
- [16] Li S, Yang Y, Yang L, et al. Civil aircraft big data platform[C]//2017 IEEE 11th International Conference on Semantic Computing (ICSC). IEEE, 2017: 328-333.
- [17] Volponi A, Brotherton T, Luppold R. Development of an information fusion system for engine

- diagnostics and health management[C]//AIAA 1st Intelligent Systems Technical Conference. 2004: 6461.
- [18] Bastard G, Lacaille J, Coupard J, et al. Engine health management in safran aircraft engines[C]//Annual Conference of the PHM Society. 2016, 8(1).
- [19] Felke T, Hadden G, Miller D, et al. Architectures for integrated vehicle health management[M]//AIAA Infotech@ Aerospace 2010. 2010: 3433.
- [20] 王锦申, 吴宪, 林育森. 基于南方航空工程管理理念的 CFM56-7B 高压涡轮叶片裂纹研究与预测[J]. 航空维修与工程, 2024, (7): 14-21.
- [21] 徐庆宏, 任和, 马小骏. 民用飞机实时监控与健康管理工作[M]. 上海: 上海交通大学出版社, 2018.
- [22] Kilic U, Yalin G, Cam O. Digital twin for Electronic Centralized Aircraft Monitoring by machine learning algorithms[J]. Energy, 2023, 283: 129118.
- [23] Wang R, Chen R, Zhao Y, et al. A novel wasserstein autoencoder-enhanced thermo-mechanical coupled reduced-order model for high pressure turbine blades life monitoring[J]. Engineering Applications of Artificial Intelligence, 2025, 152: 110819.
- [24] Martínez-García M, Zhang Y, Suzuki K, et al. Deep recurrent entropy adaptive model for system reliability monitoring[J]. IEEE Transactions on Industrial Informatics, 2020, 17(2): 839-848.
- [25] Daroogheh N, Baniamerian A, Meskin N, et al. Prognosis and health monitoring of nonlinear systems using a hybrid scheme through integration of PFs and neural networks[J]. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2016, 47(8): 1990-2004.
- [26] Guimarães D M Q R M. Implementation of an engine condition trend monitoring (ECTM) program in a Part M organization: Pratt & Whitney PT6A-67D engine[D]. 2015.
- [27] Tumer I, Bajwa A. A survey of aircraft engine health monitoring systems[C]//35th joint propulsion conference and exhibit. 1999: 2528.
- [28] Simon D L. An integrated architecture for on-board aircraft engine performance trend monitoring and gas path fault diagnostics[C]//57th JANNAF Joint Propulsion Meeting. 2010 (NASA/TM-2010-216358).
- [29] 付松. 民用航空发动机气路性能异常检测与剩余寿命预测方法研究[D]. 哈尔滨: 哈尔滨工业大学, 2022. DOI: 10.27061/d.cnki.ghgdu.2022.000498.
- [30] Hu D, Wang H, Yang C, et al. Construction of digital twin model of engine in-cylinder combustion based on data-driven[J]. Energy, 2024, 293: 130543.
- [31] Wei Z, Zhang S, Jafari S, et al. Gas turbine aero-engines real time on-board modelling: A review, research challenges, and exploring the future[J]. Progress in Aerospace Sciences, 2020, 121: 100693.
- [32] Zolghadri A. The challenge of advanced model-based FDIR for real-world flight-critical applications[J]. Engineering Applications of Artificial Intelligence, 2018, 68: 249-259.
- [33] Dai Y, Shi M, Jin D, et al. Enhanced quasi-three-dimensional transient simulation technique incorporating component volume effects for aero engine[J]. Chinese Journal of Aeronautics, 2024, 37(12): 325-346.

- [34] Sellers J F, Daniele C J. DYNGEN: A program for calculating steady-state and transient performance of turbojet and turbofan engines[M]. National Aeronautics and Space Administration, 1975.
- [35] Daniele C J, Krosel S M, Szuch J R, et al. Digital computer program for generating dynamic turbofan engine models (DIGTEM)[R]. 1983.
- [36] Chapman J W, Lavelle T M, Litt J S, et al. A process for the creation of T-MATS propulsion system models from NPSS data[C]//50th AIAA/ASME/SAE/ASEE Joint Propulsion Conference. 2014: 3931.
- [37] Altarazi Y S M, Gires E, Yu J, et al. Performance and exhaust emissions rate of small-scale turbojet engine running on dual biodiesel blends using Gasturb[J]. Energy, 2021, 232: 120971.
- [38] Kopasakis G, Connolly J W, Seidel J A, et al. Propulsion system dynamic modeling of the NASA supersonic concept vehicle for AeroPropulsoServoElasticity[C]//50th AIAA/ASME/SAE/ASEE Joint Propulsion Conference. 2014: 3684.
- [39] 潘慕绚, 陈强龙, 周永权, 等. 涡扇发动机多动力学建模方法[J]. 航空学报, 2019, 40(5): 99-110.
- [40] 殷锴, 周文祥, 乔坤, 等. 航空发动机部件级模型实时性提高方法研究[J]. 推进技术, 2017, 38(1): 199-206.
- [41] Xiao D, Song S, Xiao H, et al. Predicting the performance status of aero-engines using a spatio-temporal decoupled digital twin modeling method[J]. Advanced Engineering Informatics, 2025, 65: 103218.
- [42] Wang Y, Liu F, Xi F, et al. Data Driven Comprehensive Performance Evaluation of Aeroengines: A Network Dynamic Approach[J]. Engineering, 2025, 46: 292-305.
- [43] Wanzhi M, Zhuorui P A N, Sixin W E N, et al. Aeroengine thrust estimation and embedded verification based on improved temporal convolutional network[J]. Chinese Journal of Aeronautics, 2024, 37(1): 106-117.
- [44] Xiao D, Xiao H, Li R, et al. Application of physical-structure-driven deep learning and compensation methods in aircraft engine health management[J]. Engineering Applications of Artificial Intelligence, 2024, 136: 109024.
- [45] Volponi A, Simon D L. Enhanced self tuning on-board real-time model (eSTORM) for aircraft engine performance health tracking[R]. 2008.
- [46] Xu M, Wang K, Li M, et al. An adaptive on-board real-time model with residual online learning for gas turbine engines using adaptive memory online sequential extreme learning machine[J]. Aerospace Science and Technology, 2023, 141: 108513.
- [47] 曹明, 黄金泉, 周健, 等. 民用航空发动机故障诊断与健康管理的现状、挑战与机遇 I: 气路、机械和 FADEC 系统故障诊断与预测[J]. 航空学报, 2022, 43(9): 9-41+2.
- [48] Tolani D, Yasar M, Chin S, et al. Anomaly detection for health management of aircraft gas turbine engines[C]//Proceedings of the 2005, American Control Conference, 2005. IEEE, 2005: 459-464.
- [49] 廖增步, 张瑞, 耿佳, 等. 小涵道比涡扇发动机机载气路故障诊断研究综述: 边界条件与研究难点[J]. 推进技术, 2024, 45(12): 29-45.

- [50] Liao Z, Zhan K, Zhao H, et al. Addressing class-imbalanced learning in real-time aero-engine gas-path fault diagnosis via feature filtering and mapping[J]. *Reliability Engineering & System Safety*, 2024, 249: 110189.
- [51] Huang Y, Tao J, Sun G, et al. A novel digital twin approach based on deep multimodal information fusion for aero-engine fault diagnosis[J]. *Energy*, 2023, 270: 126894.
- [52] 王启航, 黄金泉, 鲁峰. 基于变分贝叶斯粒子滤波的航空发动机气路故障诊断方法[J]. *机械制造与自动化*, 2022, 51(2): 181-185.
- [53] 黄郑, 周建新, 李家伟, 等. 基于改进型强跟踪卡尔曼滤波的燃气轮机组气路故障诊断研究[J]. *热能动力工程*, 2017, 32(5): 50-56+136-137.
- [54] Wang K, Guo Y, Zhao W, et al. Gas path fault detection and isolation for aero-engine based on LSTM-DAE approach under multiple-model architecture[J]. *Measurement*, 2022, 202: 111875.
- [55] 郭庆, 黄启廉, 陈金亮. 基于部件特性图优化的民航发动机性能退化建模[J]. *北京航空航天大学学报*, 2025, 51(6): 1935-1945.
- [56] 孙浩, 郭迎清, 赵万里. 基于 GMM 聚类方法构建经验模型的机载实时模型改进方法[J]. *西北工业大学学报*, 2020, 38(3): 507-514.
- [57] Wang H, Zheng J, Xiang J. Online bearing fault diagnosis using numerical simulation models and machine learning classifications[J]. *Reliability Engineering & System Safety*, 2023, 234: 109142.
- [58] Pan S J, Yang Q. A survey on transfer learning[J]. *IEEE Transactions on Knowledge and Data Engineering*, 2009, 22(10): 1345-1359.
- [59] Li C, Li S, Zhang A, et al. Meta-learning for few-shot bearing fault diagnosis under complex working conditions[J]. *Neurocomputing*, 2021, 439: 197-211.
- [60] Pan T, Chen J, Zhang T, et al. Generative adversarial network in mechanical fault diagnosis under small sample: A systematic review on applications and future perspectives[J]. *ISA Transactions*, 2022, 128: 1-10.
- [61] Ding H, Sun Y, Huang N, et al. RVGAN-TL: A generative adversarial networks and transfer learning-based hybrid approach for imbalanced data classification[J]. *Information Sciences*, 2023, 629: 184-203.
- [62] He W, Chen J, Zhou Y, et al. An intelligent machinery fault diagnosis method based on GAN and transfer learning under variable working conditions[J]. *Sensors*, 2022, 22(23): 9175.
- [63] Zhang Y, Xin Y, Liu Z, et al. Health status assessment and remaining useful life prediction of aero-engine based on BiGRU and MMoE[J]. *Reliability Engineering & System Safety*, 2022, 220: 108263.
- [64] Wang K, He A, Liu J, et al. An online learning framework for aero-engine sensor fault detection isolation and recovery[J]. *Aerospace Science and Technology*, 2025: 110241.
- [65] Wang H, Zhang Z, Li X, et al. Comprehensive dynamic structure graph neural network for aero-engine remaining useful life prediction[J]. *IEEE Transactions on Instrumentation and Measurement*, 2023, 72: 1-16.
- [66] Kordestani M, Orchard M E, Khorasani K, et al. An overview of the state of the art in aircraft

- prognostic and health management strategies[J]. IEEE Transactions on Instrumentation and Measurement, 2023, 72: 1-15.
- [67] Hanachi H, Mechefske C, Liu J, et al. Performance-based gas turbine health monitoring, diagnostics, and prognostics: A survey[J]. IEEE Transactions on Reliability, 2018, 67(3): 1340-1363.
- [68] Zhu S P, Huang H Z, Peng W, et al. Probabilistic physics of failure-based framework for fatigue life prediction of aircraft gas turbine discs under uncertainty[J]. Reliability Engineering & System Safety, 2016, 146: 1-12.
- [69] Oakley S Y, Nowell D. Prediction of the combined high-and low-cycle fatigue performance of gas turbine blades after foreign object damage[J]. International Journal of Fatigue, 2007, 29(1): 69-80.
- [70] 孙宇博, 雷娟娟. 航空发动机叶片 TC4 钛合金振动疲劳裂纹扩展研究及剩余寿命预测[J]. 表面技术, 2016, 45(9): 207-213.
- [71] 孙见忠. 面向单元体的航空发动机健康状态评估与预测方法研究[D]. 南京: 南京航空航天大学, 2012.
- [72] Zhao N, Wen X, Li S. A review on gas turbine anomaly detection for implementing health management[J]. Turbo Expo: Power for Land, Sea, and Air, 2016, 49682: V001T22A009.
- [73] Dong M, He D. A segmental hidden semi-Markov model (HSMM)-based diagnostics and prognostics framework and methodology[J]. Mechanical Systems and Signal Processing, 2007, 21(5): 2248-2266.
- [74] Zhai Q, Ye Z S. RUL prediction of deteriorating products using an adaptive Wiener process model[J]. IEEE Transactions on Industrial Informatics, 2017, 13(6): 2911-2921.
- [75] Ali J B, Chebel-Morello B, Saidi L, et al. Accurate bearing remaining useful life prediction based on Weibull distribution and artificial neural network[J]. Mechanical Systems and Signal Processing, 2015, 56: 150-172.
- [76] Tian Z. An artificial neural network method for remaining useful life prediction of equipment subject to condition monitoring[J]. Journal of Intelligent Manufacturing, 2012, 23(2): 227-237.
- [77] Pham H T, Yang B S, Nguyen T T. Machine performance degradation assessment and remaining useful life prediction using proportional hazard model and support vector machine[J]. Mechanical Systems and Signal Processing, 2012, 32: 320-330.
- [78] Chen Z, Cao S, Mao Z. Remaining useful life estimation of aircraft engines using a modified similarity and supporting vector machine (SVM) approach[J]. Energies, 2017, 11(1): 28.
- [79] 周俊. 数据驱动的航空发动机剩余使用寿命预测方法研究[D]. 南京: 南京航空航天大学, 2017.
- [80] Liu J, Li Q, Chen W, et al. Remaining useful life prediction of PEMFC based on long short-term memory recurrent neural networks[J]. International Journal of Hydrogen Energy, 2019, 44(11): 5470-5480.
- [81] Zhang Y, Xiong R, He H, et al. Long short-term memory recurrent neural network for remaining useful life prediction of lithium-ion batteries[J]. IEEE Transactions on Vehicular Technology, 2018, 67(7): 5695-5705.

- [82] Zhang C, Lim P, Qin A K, et al. Multiobjective deep belief networks ensemble for remaining useful life estimation in prognostics[J]. *IEEE Transactions on Neural Networks and Learning Systems*, 2016, 28(10): 2306-2318.
- [83] Zhu J, Chen N, Peng W. Estimation of bearing remaining useful life based on multiscale convolutional neural network[J]. *IEEE Transactions on Industrial Electronics*, 2018, 66(4): 3208-3216.
- [84] Deutsch J, He D. Using deep learning-based approach to predict remaining useful life of rotating components[J]. *IEEE Transactions on Systems, Man, and Cybernetics: Systems*, 2017, 48(1): 11-20.
- [85] Chen J, Jing H, Chang Y, et al. Gated recurrent unit based recurrent neural network for remaining useful life prediction of nonlinear deterioration process[J]. *Reliability Engineering & System Safety*, 2019, 185: 372-382.
- [86] Tian Z. An artificial neural network method for remaining useful life prediction of equipment subject to condition monitoring[J]. *Journal of Intelligent Manufacturing*, 2012, 23(2): 227-237.
- [87] Khelif R, Chebel-Morello B, Malinowski S, et al. Direct remaining useful life estimation based on support vector regression[J]. *IEEE Transactions on Industrial Electronics*, 2016, 64(3): 2276-2285.
- [88] Li X, Ding Q, Sun J Q. Remaining useful life estimation in prognostics using deep convolution neural networks[J]. *Reliability Engineering & System Safety*, 2018, 172: 1-11.
- [89] Babu G S, Zhao P, Li X L. Deep convolutional neural network based regression approach for estimation of remaining useful life[C]//*International Conference on Database Systems for Advanced Applications*. Cham: Springer International Publishing, 2016: 214-228.
- [90] Wu Y, Yuan M, Dong S, et al. Remaining useful life estimation of engineered systems using vanilla LSTM neural networks[J]. *Neurocomputing*, 2018, 275: 167-179.
- [91] Zheng S, Ristovski K, Farahat A, et al. Long short-term memory network for remaining useful life estimation[C]//*2017 IEEE International Conference on Prognostics and Health Management (ICPHM)*. IEEE, 2017: 88-95.
- [92] Liu J Q, Xie J, Zuo H F, et al. Residual lifetime prediction for aeroengines based on Wiener process with random effects[J]. *Acta Aeronautica et Astronautica Sinica*, 2015, 36(2): 564-574.
- [93] Le Son K, Fouladirad M, Barros A, et al. Remaining useful life estimation based on stochastic deterioration models: A comparative study[J]. *Reliability Engineering & System Safety*, 2013, 112: 165-175.
- [94] Zhou H, Huang J, Lu F. Reduced kernel recursive least squares algorithm for aero-engine degradation prediction[J]. *Mechanical Systems and Signal Processing*, 2017, 95: 446-467.
- [95] Giantomassi A, Ferracuti F, Benini A, et al. Hidden Markov model for health estimation and prognosis of turbofan engines[C]//*International design engineering technical conferences and computers and information in engineering conference*. 2011, 54808: 681-689.
- [96] Li Y, Chen Y, Hu Z, et al. Remaining useful life prediction of aero-engine enabled by fusing knowledge and deep learning models[J]. *Reliability Engineering & System Safety*, 2023, 229: 108869.
- [97] Han B, Yin P, Zhang Z, et al. Remaining useful life prediction of turbofan engines based on dual attention mechanism guided parallel CNN-LSTM[J]. *Measurement Science and Technology*, 2024, 36(1): 016160.

- [98] Mitici M, De Pater I, Barros A, et al. Dynamic predictive maintenance for multiple components using data-driven probabilistic RUL prognostics: The case of turbofan engines[J]. Reliability Engineering & System Safety, 2023, 234: 109199.
- [99] Bae J, Xi Z. Learning of physical health timestep using the LSTM network for remaining useful life estimation[J]. Reliability Engineering & System Safety, 2022, 226: 108717.
- [100] Faizanbasha A, Rizwan U. Deep learning-stochastic ensemble for RUL prediction and predictive maintenance with dynamic mission abort policies[J]. Reliability Engineering & System Safety, 2025, 259: 110919.
- [101] Wen J, Ren J, Zhao Z, et al. Residual-based adversarial feature decoupling for remaining useful life prediction of aero-engines under variable operating conditions[J]. Expert Systems with Applications, 2024, 255: 124538.
- [102] Xu D, Xiao X, Liu J, et al. Spatio-temporal degradation modeling and remaining useful life prediction under multiple operating conditions based on attention mechanism and deep learning[J]. Reliability Engineering & System Safety, 2023, 229: 108886.
- [103] Wang C, Lu N, Cheng Y, et al. A data-driven aero-engine degradation prognostic strategy[J]. IEEE Transactions on Cybernetics, 2019, 51(3): 1531-1541.
- [104] Costa N, Sánchez L. Variational encoding approach for interpretable assessment of remaining useful life estimation[J]. Reliability Engineering & System Safety, 2022, 222: 108353.
- [105] Kamei S, Taghipour S. A comparison study of centralized and decentralized federated learning approaches utilizing the transformer architecture for estimating remaining useful life[J]. Reliability Engineering & System Safety, 2023, 233: 109130.
- [106] Xiang F, Zhang Y, Zhang S, et al. Bayesian gated-transformer model for risk-aware prediction of aero-engine remaining useful life[J]. Expert Systems with Applications, 2024, 238: 121859.
- [107] Liu H, Sun Y, Ding W, et al. Enhancing non-stationary feature learning for remaining useful life prediction of aero-engine under multiple operating conditions[J]. Measurement, 2024, 227: 114242.
- [108] Lin L, Wu J, Fu S, et al. Channel attention & temporal attention based temporal convolutional network: A dual attention framework for remaining useful life prediction of the aircraft engines[J]. Advanced Engineering Informatics, 2024, 60: 102372.
- [109] Zhang Q, Liu Q, Ye Q. An attention-based temporal convolutional network method for predicting remaining useful life of aero-engine[J]. Engineering Applications of Artificial Intelligence, 2024, 127: 107241.
- [110] 廉晓纯, 吴虎. 航空发动机原理[M]. 陕西: 西北工业大学出版社, 2005.
- [111] 陈芊. 高稳定高安全性航空发动机模型智能控制方法研究[D]. 南京: 南京航空航天大学, 2023.
- [112] Fan J, Zhang K, Huang Y, et al. Parallel spatio-temporal attention-based TCN for multivariate time series prediction[J]. Neural Computing and Applications, 2023, 35(18): 13109-13118.
- [113] He K, Zhang X, Ren S, et al. Spatial pyramid pooling in deep convolutional networks for visual recognition[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015, 37(9): 1904-1916.

- [114] Lin T Y, Dollár P, Girshick R, et al. Feature pyramid networks for object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. Hawaii, USA, 2017: 2117-2125.
- [115] Sun W, Wu C, Xie C, et al. Fine-tuning enables state of health estimation for lithium-ion batteries via a time series foundation model[J]. Energy, 2025, 318: 134177.
- [116] Zhou D W, Wang Q W, Qi Z H, et al. Class-incremental learning: A survey[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024, 46(12): 9851-9873.
- [117] Masana M, Liu X, Twardowski B, et al. Class-incremental learning: survey and performance evaluation on image classification[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 45(5): 5513-5533.
- [118] Liao Z, Zhang R, Zhao H, et al. Towards domain shifts: Stream fine-tuning via feed-forward fault data generation for on-board aero-engine gas-path diagnosis[J]. Measurement, 2024, 237: 115207. Available: <https://github.com/SinceIToldU/Dataset-for-onboard-aeroengine-gas-path-diagnosis>
- [119] Liao Z, Wang J, Liu J, et al. Uncertainties in gas-path diagnosis of gas turbines: Representation and impact analysis[J]. Aerospace Science and Technology, 2021, 113: 106724.
- [120] Simon D L, Rinehart A W. Sensor selection for aircraft engine performance estimation and gas path fault diagnostics[J]. Journal of Engineering for Gas Turbines and Power, 2016, 138(7): 071201.
- [121] Yang K, Tu Q, Zeng Y, et al. Parameter selection for aeroengine transient state gas path analysis[J]. Journal of the Global Power and Propulsion Society, 2022, 6: 61-73.
- [122] Zhang C, Zhou Y, Lu F, et al. Assessing the performance and interpretability of the CNN-LSTM-Attention model for daily streamflow forecasting in typical basins of the eastern Qinghai-Tibet Plateau[J]. Scientific Reports, 2025, 15(1): 82.
- [123] Zhang G, Gao X, Wang L, et al. Probabilistic autoencoder with multi-scale feature extraction for multivariate time series anomaly detection[J]. Applied Intelligence, 2023, 53(12): 15855-15872.
- [124] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [125] Zhou H, Zhang S, Peng J, et al. Informer: Beyond efficient transformer for long sequence time-series forecasting[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2021, 35(12): 11106-11115.
- [126] Fentaye A D, Baheta A T, Gilani S I, et al. A review on gas turbine gas-path diagnostics: State-of-the-art methods, challenges and opportunities[J]. Aerospace, 2019, 6(7): 83.
- [127] Zhang Y, Yang Q. A survey on multi-task learning[J]. IEEE Transactions on Knowledge and Data Engineering, 2021, 34(12): 5586-5609.
- [128] Simon D L, Borguet S, Léonard O, et al. Aircraft engine gas path diagnostic methods: Public benchmarking results[J]. Journal of Engineering for Gas Turbines and Power, 2014, 136(4): 041201.
- [129] 陈肖楠, 王奕首, 卿新林. 基于混合驱动的航空发动机气路故障诊断技术综述[J]. 系统工程与电子技术, 2025, 47(6): 1880-1892.
- [130] 吴轲, 吴军, 舒启明, 等. 基于深度学习的旋转机械小样本故障诊断方法研究综述[J]. 中

国舰船研究, 2025, 20(2): 3-19.

[131] 范苍宁, 刘鹏, 肖婷, 等. 深度域适应综述: 一般情况与复杂情况[J]. 自动化学报, 2021, 47(3): 515-548.

[132] Xu J, Wang Y, Wang Z, et al. Transient gas path fault diagnosis of aero-engine based on domain adaptive offline reinforcement learning[J]. Aerospace Science and Technology, 2024, 155: 109701.

[133] Kingma D P, Welling M. An introduction to variational autoencoders[J]. Foundations and Trends® in Machine Learning, 2019, 12(4): 307-392.

[134] Sampaio R A, Garcia J D, Poggi M, et al. Regularization and optimization in model-based clustering[J]. Pattern Recognition, 2024, 150: 110310.

[135] Weiss K, Khoshgoftaar T M, Wang D D. A survey of transfer learning[J]. Journal of Big data, 2016, 3(1): 9.

[136] Zhou T, Xiang H C, Zhang F, et al. Multi-source aero-engine fault diagnosis using explainable boosted tree with spatiotemporal attention and adaptive feature selection[J]. Sensors, 2026, 26(9): 2820.

[137] Cover T, Hart P. Nearest neighbor pattern classification[J]. IEEE Transactions on Information Theory, 1967, 13(1): 21-27.

[138] Sajjadi M S M, Bachem O, Lucic M, et al. Assessing generative models via precision and recall[J]. Advances in neural information processing systems, 2018, 31.

[139] Naeem M F, Oh S J, Uh Y, et al. Reliable fidelity and diversity metrics for generative models[C]//International Conference on Machine Learning. PMLR, 2020: 7176-7185.

[140] Iwana B K, Uchida S. An empirical survey of data augmentation for time series classification with neural networks[J]. PLOS ONE, 2021, 16(7): e0254841.

[141] Chawla N V, Bowyer K W, Hall L O, et al. SMOTE: synthetic minority over-sampling technique[J]. Journal of Artificial Intelligence Research, 2002, 16: 321-357.

[142] Saxena A, Goebel K, Simon D, Eklund N. Damage propagation modeling for aircraft engine run-to-failure simulation[C]// International Conference on Prognostics and Health Management. 2008: 1-9.

[143] Qin Y, Cai N, Gao C, et al. Remaining useful life prediction using temporal deep degradation network for complex machinery with attention-based feature extraction[J]. IEEE Transactions on Instrumentation and Measurement, 2022.

[144] Ensarioğlu K, et al. Remaining useful life estimation of turbofan engines with deep learning[J]. Applied Sciences, 2023, 13(21): 11893.

[145] Arias Chao M, Kulkarni C, Goebel K, Fink O. Aircraft engine run-to-failure dataset under real flight conditions[J]. Data, 2021, 6(1): 5.

[146] 罗舒杨, 周奇, 黄旭丰, 等. 基于多尺度时间卷积网络的航空发动机寿命预测[J]. 空间控制技术与应用, 2023, 49(4): 86-95.

[147] Chen Z, Wu M, Zhao R, Guretno F, Yan R, Li X. Machine remaining useful life prediction via an attention-based deep learning approach[J]. IEEE Transactions on Industrial Electronics, 2021, 68(3):

2521-2531.

[148] Woo S, Park J, Lee J Y, Kweon I S. CBAM: Convolutional block attention module[C]//European Conference on Computer Vision. 2018: 3-19.

[149] Meher-Homji C B, Chaker M, Motiwala H. Gas turbine performance deterioration[C]//Proceedings of the 30th Turbomachinery Symposium. 2001.

[150] Goeing J, et al. Influence of combined compressor and turbine deterioration on the overall performance of a high-bypass jet engine[J]. Global Power and Propulsion Society Journal, 2020.

[151] Xiong J, Fink O, Zhou J, et al. Controlled physics-informed data generation for deep learning-based remaining useful life prediction under unseen operation conditions[J]. Mechanical Systems and Signal Processing, 2023, 197: 110359.

[152] Qin L, Zhang S, Sun T, et al. An interpretable neuro-dynamic scheme with feature-temporal attention for remaining useful life estimation[J]. IEEE Transactions on Industrial Informatics, 2023, 20(4): 5505-5516.

[153] Xiang F, Zhang Y, Zhang S, et al. Bayesian gated-transformer model for risk-aware prediction of aero-engine remaining useful life[J]. Expert Systems with Applications, 2024, 238: 121859.

致 谢

声 明

本人郑重声明：所呈交的学位论文，是本人在导师指导下，独立进行研究工作所取得的成果。尽我所知，除文中已经注明引用的内容外，本学位论文的研究成果不包含任何他人享有著作权的内容。对本论文所涉及的研究工作做出贡献的其他个人和集体，均已在文中以明确方式标明。

签 名：_____ 日 期：_____

声 明

个人简历、在学期间完成的相关学术成果

个人简历

1997 年 10 月 20 日出生于江苏省徐州市。

2016 年 9 月考入西北工业大学动力与能源学院飞行器动力工程专业，2020 年 7 月本科毕业并获得工学学士学位。

2020 年 9 月考入西北工业大学动力与能源学院航空宇航推进理论与工程专业，2023 年 4 月硕士毕业并获得工学硕士学位。

2023 年 9 月面授进入清华大学航空发动机研究院攻读工学博士至今。

在学期间完成的相关学术成果

学术论文：

以第一作者身份发表：

- [1] An online learning framework for aero-engine sensor fault detection isolation and recovery[J]. Aerospace Science and Technology, 2025: 110241. (IF: 5.8, SCI 收录, 检索号: WOS:001485592600001)
- [2] Gas Path Fault Diagnosis Method Under Small Samples With Interclass Imbalance[J]. Journal of Engineering for Gas Turbines and Power, 2025, 147(7): 071021. (IF:2.1, SCI 收录, 检索号: WOS:001506802400013)
- [3] Remaining Useful Life Prediction of Aero-engine Using Pyramid Temporal Convolutional Network with Fused Complementary Attention[J]. Reliability Engineering & System Safety, 2026: 112254. (IF:11, SCI 收录, 检索号: WOS:001689701800001)
- [4] Gas Path Fault Diagnosis Method for Aero-Engine Under Multi-Source Uncertainty[C]. Proceedings of the ASME Turbo Expo 2026: Volume 4: Controls, Diagnostics, and Instrumentation. Milan, Italy. June 15–19, 2026. (EI 收录)
- [5] Gas Path Fault Diagnosis Method Under Small Samples With Interclass Imbalance[C]. Proceedings of the ASME Turbo Expo 2024: Volume 4: Controls, Diagnostics, and Instrumentation. London, United Kingdom. June 24–28, 2024.

（EI 收录）

[6] 多模型架构下基于 DAE 的航空发动机传感器故障诊断[C]. 第八届空天动力大会

以非第一作者身份发表：

[7] Feature enhancement based aero-engine lubricant consumption prediction: a bitcn-bigru-attention approach[J]. Alexandria Engineering Journal, 2025, 129: 137-167. （IF: 6.8, SCI 收录， 检索号: WOS:001513634800001）

[8] Enhancing multimodal fault diagnosis in mechanical systems via mixture of experts[J]. Complex & Intelligent Systems, 2025, 11(10): 425. （IF: 4.6, SCI 收录， 检索号: WOS:001559487000001）

[9] Multimodal mechanical wear fault diagnosis: Fusion of signal characterization and image information[J]. Results in Engineering, 2025: 107204. （IF: 7.9, ESCI 收录， 检索号: WOS:001582581900005）

专利：

以第一作者身份发表：

[1] 航空发动机故障数据的生成方法、装置和计算机设备（CN120260154B）

[2] 航空发动机多任务学习的级联建模方法和装置（CN120162878A）

[3] 航空发动机多传感器的传感器故障处理方法和装置（CN120316609A）

以非第一作者身份发表：

[4] 模型参数的优化方法、装置、设备、存储介质和程序产品（CN120124509B）

[5] 氢燃料发动机的燃料供应装置及控制方法（CN118327818A）

竞赛：

[1] 2025 首届空天动力研究生菁英赛全国三等奖（第一完成人）